



การปรับปรุงเทคนิคการวิเคราะห์องค์ประกอบหลักสำหรับการรู้จำใบหน้า



วิทยานิพนธ์เสนอปัณฑิตวิทยาลัย มหาวิทยาลัยนเรศวร

เพื่อเป็นส่วนหนึ่งของการศึกษา หลักสูตรวิทยาศาสตรมหาบัณฑิต

สาขาวิชาวิทยาการคอมพิวเตอร์

ปีการศึกษา 2562

ลิขสิทธิ์เป็นของมหาวิทยาลัยนเรศวร

การปรับปรุงเทคนิคการวิเคราะห์องค์ประกอบหลักสำหรับการรู้จำใบหน้า



วิทยานิพนธ์เสนอปัณฑิตวิทยาลัย มหาวิทยาลัยนเรศวร  
เพื่อเป็นส่วนหนึ่งของการศึกษา หลักสูตรวิทยาศาสตรมหาบัณฑิต  
สาขาวิชาวิทยาการคอมพิวเตอร์  
ปีการศึกษา 2562  
เลขที่ใช้เป็นของมหาวิทยาลัยนเรศวร

วิทยานิพนธ์ เรื่อง "การปรับปรุงเทคนิคการวิเคราะห์องค์ประกอบหลักสำหรับการรู้จำใบหน้า"

ของ กองสдал หาญเชิงชัย

ได้รับการพิจารณาให้นับเป็นส่วนหนึ่งของการศึกษาตามหลักสูตร

วิทยาศาสตรมหาบัณฑิต สาขาวิชาการคอมพิวเตอร์

### คณะกรรมการสอบวิทยานิพนธ์

ประธานกรรมการสอบวิทยานิพนธ์

(ผู้ช่วยศาสตราจารย์ ดร.กันต์พงษ์ วรรตโนปัญญา)

ประธานที่ปรึกษาวิทยานิพนธ์

(ผู้ช่วยศาสตราจารย์ ดร.จรัสศรี รุ่งรัตนากุล)

กรรมการผู้ทรงคุณวุฒิภายใน

(ดร.วันสรีร์ มาศกรร)

กรรมการผู้ทรงคุณวุฒิภายใน

(ผู้ช่วยศาสตราจารย์ ดร.ธนาธร พอค้า)

กรรมการผู้ทรงคุณวุฒิภายใน

(รองศาสตราจารย์ ดร.ไกรศักดิ์ เกษร)

อนุมัติ

(ศาสตราจารย์ ดร.ไพบูล มุณีสว่าง)

คณบดีบัณฑิตวิทยาลัย

<b>ชื่อเรื่อง</b>	การปรับปรุงเทคนิคการวิเคราะห์องค์ประกอบหลักสำหรับการรู้จำใบหน้า
<b>ผู้วิจัย</b>	กังสดาล หาญเชิงชัย
<b>ประธานที่ปรึกษา</b>	ผู้ช่วยศาสตราจารย์ ดร. จรัสศรี รุ่งรัตนากุบล
<b>ประเภทสารนิพนธ์</b>	วิทยานิพนธ์ วท.ม. สาขาวิชาวิทยาการคอมพิวเตอร์, มหาวิทยาลัยนเรศวร, 2562
<b>คำสำคัญ</b>	เมทริกซ์ระดับภูมิภาค, เทคนิค ELSSP, การวิเคราะห์องค์ประกอบหลักแบบสองมิติ (2DPCA), การรู้จำใบหน้า

### บทคัดย่อ

การวิเคราะห์องค์ประกอบหลักแบบสองมิติ (2DPCA) ถูกใช้อย่างแพร่หลายในหลาย ๆ แอปพลิเคชันโดยเฉพาะการจดจำใบหน้า ปัจจัยสำคัญในการปรับปรุงประสิทธิภาพของวิธี 2DPCA นั้นมาจากการสิทธิภาพของเมทริกซ์ความแปรปรวนร่วม ในวิทยานิพนธ์นี้เขียนว่า ไอเกนเวกเตอร์ (eigenvector) ที่มีประสิทธิภาพสามารถสกัดได้จากเมทริกซ์ความแปรปรวนร่วมที่มีประสิทธิภาพ วิทยานิพนธ์ฉบับนี้จึงเสนอให้การหาไอเกนเวกเตอร์อย่างมีประสิทธิภาพ โดยทำการปรับปรุงวิธีการ 2DPCA สำหรับการรู้จำใบหน้า 2 แบบ 1) ปรับปรุงวิธีการ 2DPCA สำหรับการรู้จำใบหน้าภายใต้ผลกระทบจากการส่องสว่างของแสง โดยใช้ค่าเฉลี่ยแบบเฉพาะถี่นแทนการใช้ค่าเฉลี่ยเพียงตัวเดียว เพื่อกำจัดแสงเงาของแต่ละรูปภาพ เนื่องจากแต่ละรูปภาพได้รับผลกระทบจากการส่องสว่างของแสง ไม่เท่ากัน ดังนั้นการใช้ค่าเฉลี่ยแบบเฉพาะถี่จึงเหมาะสมสมสำหรับรูปภาพที่ได้รับผลกระทบจากการส่องสว่างของแสง 2) ปรับปรุงวิธีการ 2DPCA สำหรับการรู้จำใบหน้าที่มีรูปแบบที่หลากหลายให้มีประสิทธิภาพมากขึ้น โดยทำการปรับปรุง 2 ส่วนได้แก่ (1) การคำนวณเมทริกซ์ระดับภูมิภาคสำหรับการคำนวณหาความสัมพันธ์สองทิศทางและ (2) การแปลงโดยใช้เทคนิค ELSSP สำหรับการคำนวณหาตัวแทนของเมทริกซ์ความแปรปรวนร่วมที่มีประสิทธิภาพ และผลการทดลองแสดงให้เห็นว่าประสิทธิภาพของวิธีการที่เสนอัสนั้นสูงกว่าวิธีการพื้นฐาน ได้แก่ 2DPCA I-2DPCA Bi2DPCA และวิธี 2D<sup>2</sup>PCA บนพื้นฐานของสามชุดข้อมูลที่รู้จักกันดี - ORL Face, Yale Face และ Yale Face B+

<b>Title</b>	MODIFIED PRINCIPAL COMPONENT ANALYSIS FOR FACE RECOGNITION
<b>Author</b>	KANGSADAN HANCHERNGCHAI
<b>Advisor</b>	Assistant Professor Jaratsri Rungrattanaubol, Ph.D.
<b>Academic Paper</b>	Thesis M.S. in Computer Science, Naresuan University, 2019
<b>Keywords</b>	Regional Matrix, ELSSP Conversion, Principal Component Analysis, Two-dimensional PCA (2DPCA), Face Recognition

## ABSTRACT

Two-dimensional principal component analysis (2DPCA) is widely used in many applications, especially, face recognition. A key factor to improve the performance of the 2DPCA method comes from the efficiency of the covariance matrix. In this thesis believes that effective eigenvector can be extracted when the effective covariance matrix is given. The contribution of this thesis consists of two case parts including 1) Modify 2DPCA method for face recognition under the illumination effect using individual local mean, which replaces a single mean in 2DPCA method. The individual local mean can provide a more appropriate means to each image, which can reduce the illumination effect effectively. Therefore, using individual local mean is especially suited for images that are affected by the illumination effect. 2) Modify 2DPCA method for face recognition. The Improved of this consists of two main parts including (1) regional matrix calculation for computing the two-directional correlations and (2) ELSSP conversion for extracting the effective representation of the covariance matrix. The experimental results show that the performance of the proposed method is higher than the baseline methods including 2DPCA, I-2DPCA, Bi2DPCA and 2D<sup>2</sup>PCA methods on a basis of three well-known datasets—ORL Face, Yale Face, and Yale Face B+.

## ประกาศคุณูปการ

วิทยานิพนธ์ฉบับนี้สำเร็จได้ด้วยความกรุณาของผู้ช่วยศาสตราจารย์ ดร. Jarvis Siri รุ่งรัตนากุบล ประธานที่ปรึกษาวิทยานิพนธ์ ที่ได้ให้คำแนะนำนำตลอดระยะเวลาในการทำวิทยานิพนธ์ฉบับนี้ และขอ กราบขอบพระคุณคณะกรรมการสอบวิทยานิพนธ์อันประกอบไปด้วย รองศาสตราจารย์ ดร.ไกรศักดิ์ เกษร ผู้ช่วยศาสตราจารย์ ดร.ธนธรรม พ่อค้า ดร.วันสุรีย์ มาศกรรัม และผู้ช่วยศาสตราจารย์ ดร.กันต์พงษ์ วรรัตน์ปัญญา กรรมการผู้ทรงคุณวุฒิภายนอก ที่ได้กรุณาให้คำแนะนำนำตลอดจนแก้ไขข้อบกพร่องของ วิทยานิพนธ์ด้วยความเอาใจใส่ จนทำให้วิทยานิพนธ์ฉบับนี้สำเร็จลุล่วงได้อย่างสมบูรณ์

กราบขอบพระคุณ ดร.ธรรวิเชษฐ์ อิติจิรูญโรจน์ ที่ได้กรุณาเสียสละเวลาอันมีค่าให้คำปรึกษา และแนะนำในการทำให้วิทยานิพนธ์ฉบับนี้สำเร็จลุล่วง

ขอขอบคุณที่ฯ เพื่อนๆ น้องๆ ในสาขาวิชาวิทยาการคอมพิวเตอร์และเทคโนโลยีสารสนเทศ ทุกคนที่เคยเป็นกำลังใจในการทำงานวิจัยตลอดมา

ขอกราบขอบพระคุณ บิดา มารดา ครอบครัวของผู้วิจัย ที่เคยให้กำลังใจและให้การสนับสนุน ในทุกๆ ด้านเป็นอย่างดีที่สุดจนบรรลุผลในระหว่างการเรียนและการทำวิทยานิพนธ์

งานวิจัยฉบับนี้ได้รับทุนอุดหนุนการวิจัยจากงบประมาณรายได้สำหรับนิสิตระดับบัณฑิตศึกษา ประจำปีงบประมาณ 2562 และทุนสนับสนุนงานวิจัยจากคณะวิทยาศาสตร์และภาควิชาวิทยาการ คอมพิวเตอร์และเทคโนโลยีสารสนเทศ

กั้งสดาล หาญเชิงชัย

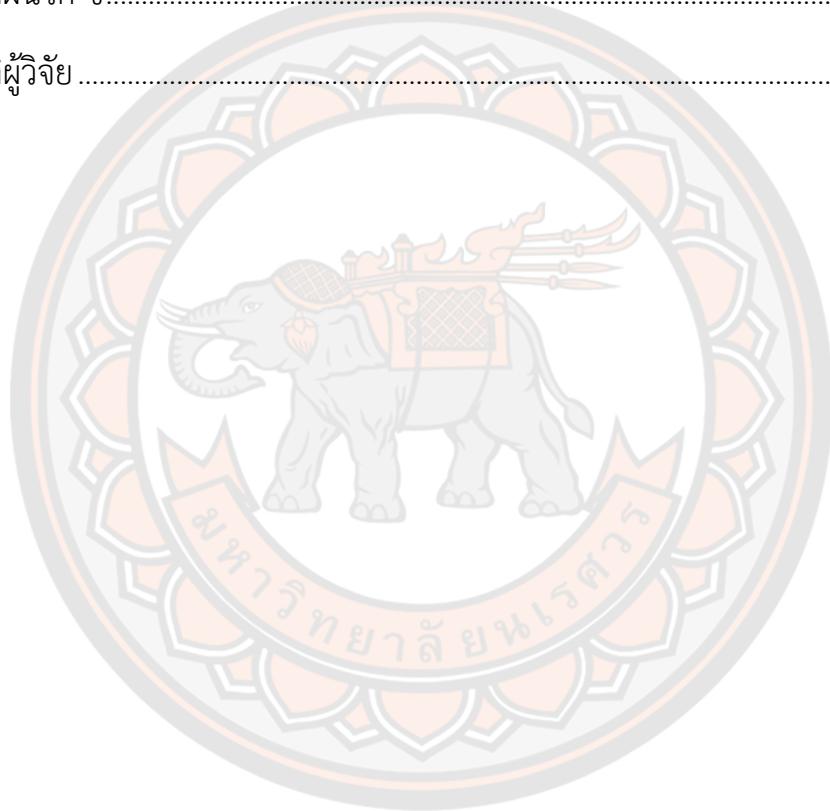
## สารบัญ

หน้า

บทคัดย่อภาษาไทย .....	๑
บทคัดย่อภาษาอังกฤษ .....	๒
ประกาศคุณูปการ .....	๓
สารบัญ .....	๔
สารบัญตาราง .....	๕
สารบัญรูปภาพ .....	๖
บทที่ ๑ .....	๑
บทนำ .....	๑
1.1 ความเป็นมาของปัจจุบัน .....	๑
1.2 จุดมุ่งหมายของการศึกษา .....	๓
1.3 ขอบเขตของงานวิจัย .....	๓
1.4 ประโยชน์ที่คาดว่าจะได้รับ .....	๕
1.5 นิยามศัพท์เฉพาะ .....	๕
1.6 แผนการดำเนินงานวิจัย .....	๖
บทที่ ๒ .....	๗
เอกสารและงานวิจัยที่เกี่ยวข้อง .....	๗
2.1 ทฤษฎีที่เกี่ยวข้อง .....	๗
2.1.1 การรู้จำใบหน้า .....	๗
2.1.2 ไอเกนเฟส .....	๘

2.2 งานวิจัยที่เกี่ยวข้อง .....	8
2.2.1 การวิเคราะห์องค์ประกอบหลักสำหรับการรู้จำใบหน้า .....	8
2.2.2 การวิเคราะห์องค์ประกอบหลัก 2 มิติ.....	12
2.2.3 การวิเคราะห์องค์ประกอบหลัก 2 มิติแบบ 2 ทิศทาง .....	15
2.2.4 การวิเคราะห์องค์ประกอบหลัก 2 มิติแบบ 2 ทิศทางโดยอาศัยสมการเชิงเส้น สำหรับการสร้างไอเกนเฟส.....	18
2.2.5 การฉายปริญามิย่อยของผลรวมเชิงเส้นแบบถ่วงน้ำหนักโดยอาศัยค่าไอเกน..	20
2.2.6 การวิเคราะห์องค์ประกอบหลัก 2 มิติ สำหรับการรู้จำใบหน้าภายใต้ ผลกระทบจากการส่องสว่างของแสง .....	20
บทที่ 3 .....	24
วิธีดำเนินงานวิจัย .....	24
3.1 การพัฒนาวิธีการ M-2DPCA แบบที่ 1 (M1-2DPCA) .....	25
3.2 การพัฒนาวิธีการ M-2DPCA แบบที่ 2 (M2-2DPCA) .....	29
3.3 เครื่องมือที่ใช้ในงานวิจัย .....	33
บทที่ 4 .....	34
ผลการวิจัย .....	34
4.1 การวัดประสิทธิภาพของจำนวนไอเกนเวกเตอร์ที่ใช้งาน .....	34
4.2 การวัดประสิทธิภาพของการรู้จำใบหน้า .....	39
4.3 การวัดประสิทธิภาพของเวลาที่ใช้ในการประมวลผล .....	41
บทที่ 5 .....	43
บทสรุป .....	43
5.1 สรุปผลการวิจัย .....	43

5.2 อภิปรายผล.....	43
5.3 ข้อเสนอแนะ .....	44
บรรณานุกรม .....	45
ภาคผนวก.....	47
ภาคผนวก ก.....	48
ภาคผนวก ข.....	52
ประวัติผู้วิจัย .....	65



## สารบัญตาราง

หน้า

ตาราง 1 แผนการดำเนินงานวิจัย .....	6
ตาราง 3 แสดงผลการทดลองของจำนวนไอกenen เวกเตอร์ที่เหมาะสมของแต่ละฐานข้อมูล .....	37
ตาราง 4 แสดงผลการทดลองของจำนวนไอกenen เวกเตอร์ที่เหมาะสมของแต่ละฐานข้อมูล เปรียบเทียบกับค่าความถูกต้อง .....	38
ตาราง 5 แสดงผลการทดลองวัดประสิทธิภาพของการรู้จำใบหน้า.....	39
ตาราง 6 แสดงผลการทดลองวัดประสิทธิภาพของเวลาที่ใช้ในการประมวลผล.....	41
ตาราง 7 แสดงผลการทดลองวัดประสิทธิภาพของการรู้จำใบหน้าสำหรับฐานข้อมูล The ORL Face Database .....	49
ตาราง 8 แสดงผลการทดลองวัดประสิทธิภาพของการรู้จำใบหน้าสำหรับฐานข้อมูล Yale Face Database .....	50
ตาราง 9 แสดงผลการทดลองวัดประสิทธิภาพของการรู้จำใบหน้าสำหรับฐานข้อมูล Yale Face Database B+.....	51

## สารบัญรูปภาพ

หน้า

ภาพ 1 ตัวอย่างรูปภาพที่มีผลกระทบจากการส่องสว่างของแสง (Illumination Effects) .....	3
ภาพ 2 ตัวอย่างรูปภาพจากชุดข้อมูลของ ORL face database .....	4
ภาพ 3 ตัวอย่างรูปภาพจากชุดข้อมูลของ Yale face database.....	4
ภาพ 4 ตัวอย่างรูปภาพจากชุดข้อมูลของ Yale face database B+ .....	5
ภาพ 5 กระบวนการรู้จำใบหน้า.....	7
ภาพ 6 ขั้นตอนการทำงานของวิธีการ PCA สำหรับการรู้จำใบหน้า.....	9
ภาพ 7 วิธีการสกัดไオเกนเวกเตอร์และค่าไอเกนของวิธีการ PCA.....	9
ภาพ 8 ขั้นตอนการแปลงรูปภาพ.....	10
ภาพ 9 ขั้นตอนการคำนวณค่าเฉลี่ยของวิธีการ PCA.....	10
ภาพ 10 ตัวอย่างผลลัพธ์ของการลบด้วยค่าเฉลี่ยจากการวิธีการ PCA .....	11
ภาพ 11 ขั้นตอนการทำงานของ 2DPCA สำหรับการรู้จำใบหน้า.....	13
ภาพ 12 วิธีการสกัดไอเกนเวกเตอร์และค่าไอเกนของ 2DPCA .....	13
ภาพ 13 ตัวอย่างผลลัพธ์ของการคำนวณค่าเฉลี่ยของวิธีการ 2DPCA.....	14
ภาพ 14 ตัวอย่างผลลัพธ์ของการลบด้วยค่าเฉลี่ยของวิธีการ 2DPCA.....	14
ภาพ 15 ขั้นตอนการทำงานของวิธีการ 2D <sup>2</sup> PCA สำหรับการรู้จำใบหน้า.....	15
ภาพ 16 วิธีการสกัดไอเกนเวกเตอร์และค่าไอเกนของวิธีการ 2D <sup>2</sup> PCA .....	16
ภาพ 17 ขั้นตอนการทำงานของวิธีการ Bi2DPCA สำหรับการรู้จำใบหน้า .....	18
ภาพ 18 วิธีการสกัดไอเกนเวกเตอร์และค่าไอเกนของวิธีการ Bi2DPCA .....	18
ภาพ 19 การแปลงภาพสีเป็นภาพระดับสีเทา .....	20

ภาพ 20 ขั้นตอนการทำงานของวิธีการ I-2DPCA สำหรับการรู้จำใบหน้า .....	21
ภาพ 21 วิธีการสกัดไอกenen เวกเตอร์และค่าไอกenen ของวิธีการ I-2DPCA.....	21
ภาพ 22 ตัวอย่างผลลัพธ์ของการคำนวณค่าเฉลี่ยของวิธีการ I-2DPCA.....	21
ภาพ 23 ตัวอย่างผลลัพธ์ของการลบด้วยค่าเฉลี่ยของวิธีการ I-2DPCA .....	22
ภาพ 24 ขั้นตอนการทำงานของวิธีการ M-2DPCA สำหรับการรู้จำใบหน้า .....	25
ภาพ 25 ตัวอย่างรูปภาพที่ปราศจากค่าเฉลี่ย .....	26
ภาพ 26 วิธีการสกัดไอกenen เวกเตอร์และค่าไอกenen ของวิธีการ M-2DPCA แบบที่ 1 .....	26
ภาพ 27 ตัวอย่างผลลัพธ์ของการคำนวณค่าเฉลี่ย .....	27
ภาพ 28 ตัวอย่างผลลัพธ์ของการลบด้วยค่าเฉลี่ย.....	28
ภาพ 29 ตัวอย่างการหาความสัมพันธ์.....	29
ภาพ 30 วิธีการสกัดไอกenen เวกเตอร์และค่าไอกenen ของวิธีการ M-2DPCA แบบที่ 2 .....	29
ภาพ 31 การคำนวณเมทริกซ์ระดับภูมิภาค.....	30
ภาพ 32 เสนอการใช้เทคนิค ELSSP แทนการใช้เทคนิคการหาค่าเฉลี่ย .....	31
ภาพ 33 กราฟแสดงค่าความถูกต้องของแต่ละวิธีการเมื่อเปรียบเทียบกับจำนวนไอกenen เพส ที่ใช้ในฐานข้อมูล The ORL Face Database .....	35
ภาพ 34 กราฟแสดงค่าความถูกต้องของแต่ละวิธีการเมื่อเปรียบเทียบกับจำนวนไอกenen เพส ที่ใช้ในฐานข้อมูล Yale Face Database .....	35
ภาพ 35 กราฟแสดงค่าความถูกต้องของแต่ละวิธีการเมื่อเปรียบเทียบกับจำนวนไอกenen เพส ที่ใช้ในฐานข้อมูล Yale Face Database B+ .....	36
ภาพ 36 ตัวอย่างรูปภาพที่ปราศจากค่าเฉลี่ย .....	40

## บทที่ 1

### บทนำ

#### 1.1 ความเป็นมาของปัญหา

การรู้จำใบหน้า (Face Recognition) ได้รับความสนใจอย่างแพร่หลายตั้งแต่อดีตจนถึงปัจจุบัน และถูกนำมาประยุกต์ใช้อย่างมากในเรื่องของความปลอดภัย เช่น การค้นหาบุคคล การระบุตัวตน เป็นต้น การรู้จำใบหน้า คือ การนำภาพใบหน้าของบุคคลมาทำการเปรียบเทียบกับฐานข้อมูลใบหน้า ของบุคคลที่มีการจัดเก็บไว้เพื่อระบุว่าใบหน้าที่ตรวจจับได้ตรงกับบุคคลใดในฐานข้อมูล ในปัจจุบัน เทคนิคที่นิยมใช้ในการรู้จำใบหน้ามีด้วยกันหลายวิธี เช่น การวิเคราะห์องค์ประกอบหลัก (Principal Component Analysis: PCA) และการวิเคราะห์การจำแนกประเภทเชิงเส้น (Linear Discriminant Analysis: LDA) เป็นต้น

จากการศึกษาค้นคว้างานวิจัยที่เกี่ยวข้องพบว่า PCA ได้รับความนิยมและนำมาใช้ในเรื่องของการรู้จำใบหน้าอย่างแพร่หลาย PCA เป็นวิธีการเชิงคณิตศาสตร์ที่ถูกนำมาใช้เพื่อการจำแนกข้อมูล เพื่อการลดมิติข้อมูล และเพื่อการบีบอัดข้อมูลให้มีขนาดเล็กลงโดยไม่มีผลกระทบของการสูญเสียข้อมูล นอกจากนี้ PCA ยังสามารถใช้เพื่อวิเคราะห์ข้อมูล และช่วยอธิบายข้อมูลในรูปแบบของความสัมพันธ์ว่าข้อมูลนั้นเหมือนหรือแตกต่างกัน เพราะเหตุนี้จึงทำให้วิธีการ PCA ได้รับความนิยมในการนำมาประยุกต์ใช้ในงานต่าง ๆ โดยเฉพาะการรู้จำใบหน้า

ในปี 1987 Sirovich และ Kirby (Sirovich & Kirby, 1987) ได้ใช้วิธีการ PCA ในการรู้จำใบหน้าของมนุษย์เป็นครั้งแรก เนื่องจากวิธีการ PCA สามารถถอดคุณลักษณะเฉพาะได้ดี นอกจากนี้ยังได้มีการเรียกชุดของไอโgen เวกเตอร์ (Eigenvectors) ที่ใช้ในการรู้จำใบหน้าของมนุษย์ว่าไอโgenเฟส (Eigenface) เป็นครั้งแรก และทำให้ไอโgenเฟสเป็นที่รู้จักอย่างกว้างขวางในปัจจุบัน ต่อมาในปี 2004 Jian และคณะ (Jian, Zhang, Frangi, & Jing-yu, 2004) ได้ศึกษาหลักการทำงานของวิธีการ PCA เพื่อการรู้จำใบหน้าและพบว่าวิธีการ PCA แบบดั้งเดิมมีการแปลงรูปภาพให้อยู่ในรูปของเวกเตอร์ (Vector) จึงทำให้ใช้เวลาในการประมวลผลมาก จึงได้พัฒนาเทคนิคที่ชื่อว่า two-dimensional principal component analysis (2DPCA) ที่สามารถใช้รูปภาพนำเข้าในการคำนวณโดยที่ไม่ต้องแปลงให้อยู่ในรูปของเวกเตอร์เหมือนวิธีการ PCA เพื่อให้ง่ายต่อการคำนวณหาเมทริกซ์ความแปรปรวนร่วม (Covariance Matrix) และยังทำให้ประหยัดเวลาในการคำนวณหาไอโgen เวกเตอร์มากกว่าวิธีการ PCA แบบเดิม หลังจากนั้นในปี 2005 Zhang และ Zhou (Zhang & Zhou, 2005)

ได้ศึกษาวิธีการ 2DPCA และพบว่าวิธีการ 2DPCA นั้นคำนวนหาเมทริกซ์ความแปรปรวนร่วมเพียงทิศทางเดียว (แค่) จึงส่งผลให้มีอุกเงนเกตอร์ เฉพาะส่วนของทิศทางนั้น ในขณะที่เมทริกซ์ประกอบไปด้วย例外และหลัก ดังนั้น Zhang และ Zhou จึงได้เสนอ Two-directional and two-dimensional PCA ( $2D^2PCA$ ) ที่พัฒนาต่อยอดมาจากการ 2DPCA โดยการใช้เมทริกซ์ความแปรปรวนร่วม 2 ทิศทาง เพื่อให้มีอุกเงนเฟสของทั้ง 2 ทิศทาง ทำให้มีค่าความถูกต้องมากกว่าวิธีการ 2DPCA ขณะที่ในปี 2008 Kim และคณะ (Kim et al., 2008) ได้พัฒนา bidirectional 2DPCA (Bi2DPCA) ซึ่งต่อยอดมาจากการ 2DPCA ที่ใช้เมทริกซ์ความแปรปรวนร่วมทั้ง 2 ทิศทาง เช่นเดียวกับวิธีการ  $2D^2PCA$  แต่วิธีการ Bi2DPCA นั้นได้สกัดอุกเงนเฟสโดยใช้วิธีการแปลงเชิงเส้น (Linear Transformation) ขณะที่วิธีการอื่น ๆ ใช้เทคนิคการฉายภาพ (Projection Technique) เหตุนี้จึงทำให้ Bi2DPCA มีค่าความถูกต้องมากกว่าวิธีการ 2DPCA

จากการทบทวนวรรณกรรมที่เกี่ยวข้อง ผู้วิจัยพบว่ามีงานวิจัยจำนวนมากที่ให้ความสนใจในการประยุกต์ใช้วิธีการในกลุ่มของ PCA สำหรับการรู้จำใบหน้า อย่างไรก็ตาม วิธีการในกลุ่มของ PCA สำหรับการรู้จำใบหน้าที่กล่าวมานี้ยังไม่สามารถตอบโจทย์ในเรื่องของผลกระทบจากการส่องสว่างของแสง (Illumination Effects) เพราะรูปภาพที่ได้รับผลกระทบจากการส่องสว่างของแสงนั้นส่งผลต่อการสกัดคุณลักษณะเฉพาะที่ไม่สมบูรณ์ ซึ่งปัญหานี้ทำให้ได้ผลลัพธ์ที่คลาดเคลื่อน ดังนั้น ในปี 2015 Woraratpanya และคณะ (Woraratpanya et al., 2015) ได้นำเสนอการปรับปรุงวิธีการ 2DPCA เพื่อแก้ผลกระทบจากการส่องสว่างของแสงในระบบรู้จำใบหน้า (2DPCA for Face Recognition under Illumination Effects: I-2DPCA) โดยทำการปรับปรุงการคำนวนเมทริกซ์ความแปรปรวนร่วม และยังได้นำเสนอแนวทางการเลือกอุกเงนเกตอร์ แบบใหม่ ทำให้ได้ผลลัพธ์ที่ดีขึ้นสำหรับการรู้จำภายใต้ผลกระทบจากการส่องสว่างของแสง ถึงแม้ว่าวิธีการ I-2DPCA จะประสบความสำเร็จ แต่ปัญหาของวิธีการ I-2DPCA คือ ไม่สามารถสกัดอุกเงนเฟสที่ตอบโจทย์สำหรับรูปภาพที่มีผลกระทบจากการส่องสว่างของแสงทั้งภาพได้ เพราะในความเป็นจริงผลกระทบจากการส่องสว่างของแสงในแต่ละภาพไม่เท่ากัน ดังตัวอย่างที่แสดงในภาพ 1 ที่แสดงให้เห็นผลกระทบจากการส่องสว่างของแสงที่หลากหลาย ซึ่งทำให้อุกเงนเฟสที่ได้รับส่งผลกระทบต่อรูปที่มีผลกระทบจากการส่องสว่างของแสง หากแก้ไขปัญหานี้ได้จะทำให้ได้ผลลัพธ์ที่ดียิ่งขึ้น



ภาพ 1 ตัวอย่างรูปภาพที่มีผลกระทบจากการส่องสว่างของแสง (Illumination Effects)

ดังนั้น ในวิทยานิพนธ์นี้ผู้วิจัยจึงมีแนวคิดที่จะปรับปรุงวิธีการ 2DPCA สำหรับการรุ้งจำใบหน้า และปรับปรุงให้มีประสิทธิภาพมากขึ้นโดยจะเปรียบเทียบประสิทธิภาพการทำงานกับวิธีการทั้งหมด 4 แบบ ได้แก่ 2DPCA แบบดั้งเดิม  $2D^2$ PCA Bi2DPCA และ I-2DPCA สำหรับการรุ้งจำใบหน้า

## 1.2 จุดมุ่งหมายของการศึกษา

1. เพื่อศึกษาหลักการทำงานของวิธีการ 2DPCA สำหรับการรุ้งจำใบหน้า
2. เพื่อปรับปรุงวิธีการ 2DPCA สำหรับการรุ้งจำใบหน้าภายใต้ผลกระทบจากการส่องสว่างของแสงให้มีประสิทธิภาพมากขึ้น
3. เพื่อปรับปรุงวิธีการ 2DPCA สำหรับการรุ้งจำใบหน้าสำหรับใบหน้าที่มีรูปแบบที่หลากหลาย ให้มีประสิทธิภาพมากขึ้น

## 1.3 ขอบเขตของงานวิจัย

ผู้วิจัยจะทำการวิจัย โดยใช้ข้อมูลจากชุดข้อมูลทั้งหมด 3 ชุดข้อมูลดังต่อไปนี้

1. ภาพใบหน้ามุษย์ จำนวนทั้งหมด 400 รูป (40 คน คนละ 10 รูป) เป็นภาพถ่ายที่มีหลากหลายมุมมอง ขนาด  $92 \times 112$  พิกเซล จากชุดข้อมูลชื่อ ORL face database (Samaria, Samaria, Harter, & Site, 1994) แสดงดังภาพ 2



ภาพ 2 ตัวอย่างรูปภาพจากชุดข้อมูลของ ORL face database

2. ภาพใบหน้ามนุษย์ จำนวนทั้งหมด 165 รูป (15 คน คนละ 11 รูป) เป็นภาพถ่ายหน้าตรงที่มีความหลากหลายทางอารมณ์และแสงเงา ขนาด  $195 \times 231$  พิกเซล จากชุดข้อมูลชื่อ Yale face database (Belhumeur, Hespanha, & Kriegman, 1996) แสดงดังภาพ 3



ภาพ 3 ตัวอย่างรูปภาพจากชุดข้อมูลของ Yale face database

3. ภาพใบหน้ามนุษย์ จำนวนทั้งหมด 2,280 รูป (38 คน คนละ 60 รูป) เป็นภาพถ่ายหน้าตรง และได้รับผลกระทบจากการส่องสว่างของแสง ขนาด  $168 \times 192$  พิกเซล จากชุดข้อมูลชื่อ Yale face database B+ (Georghiades, Belhumeur, & Kriegman, 2001) แสดงดังภาพ 4



ภาพ 4 ตัวอย่างรูปภาพจากชุดข้อมูลของ Yale face database B+

#### 1.4 ประโยชน์ที่คาดว่าจะได้รับ

1. ได้ความรู้เกี่ยวกับการรู้จำใบหน้าด้วยวิธีการ 2DPCA
2. ได้กระบวนการ 2DPCA ที่ได้ปรับปรุงให้มีประสิทธิภาพมากขึ้นสำหรับการรู้จำใบหน้า ภายใต้การส่องสว่างของแสง
3. ได้กระบวนการ 2DPCA ที่ได้ปรับปรุงให้มีประสิทธิภาพมากขึ้นสำหรับการรู้จำใบหน้า สำหรับใบหน้าที่มีรูปแบบที่หลากหลายให้มีประสิทธิภาพมากขึ้น

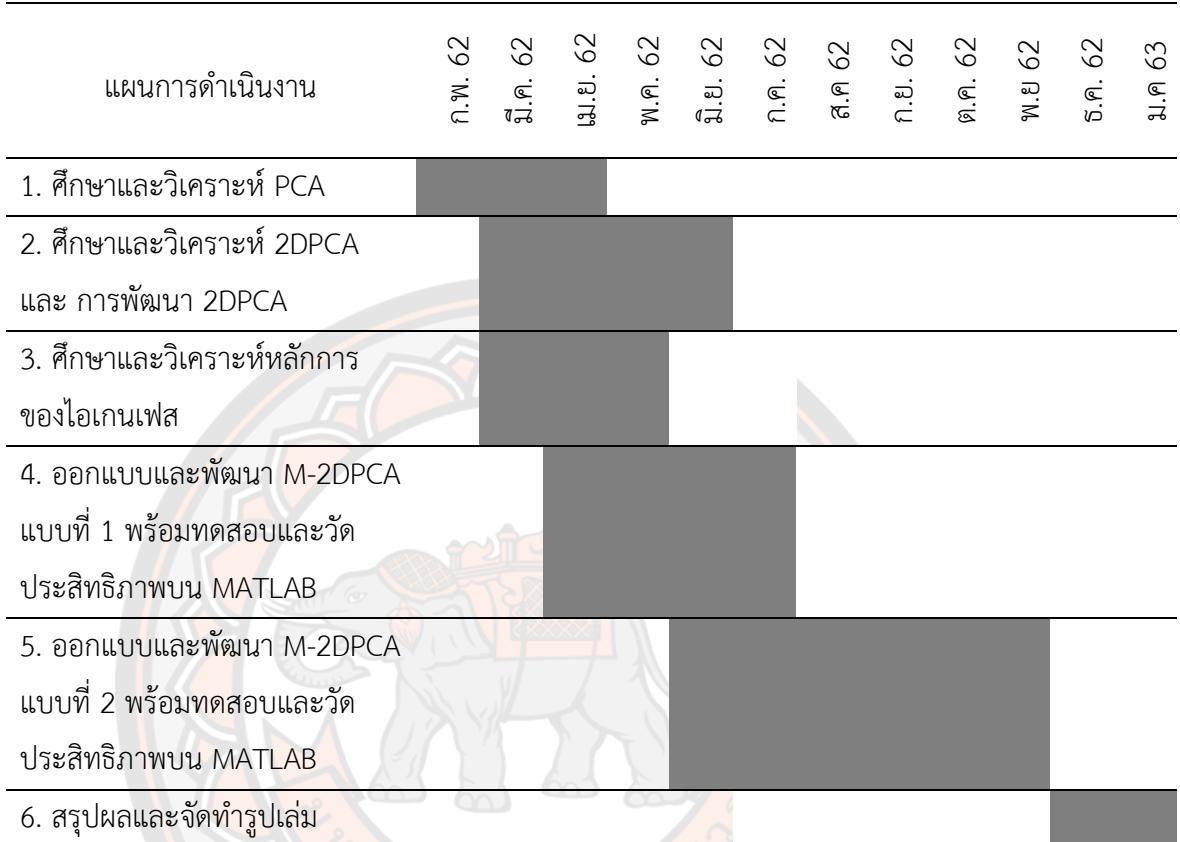
#### 1.5 นิยามศัพท์เฉพาะ

การรู้จำใบหน้า (Face Recognition) หมายถึง กระบวนการการวิเคราะห์ใบหน้า และเปรียบเทียบลักษณะใบหน้ากับฐานข้อมูลของใบหน้า เพื่อระบุว่าใบหน้าที่วิเคราะห์ได้ตรงกับบุคคลใด การวิเคราะห์องค์ประกอบหลัก (Principal Component Analysis) หมายถึง เทคนิคเชิงคณิตศาสตร์อย่างหนึ่งที่นำมาใช้ในการจำแนกข้อมูล การลดส่วนเกิน และการบีบอัดพื้นที่ว่างให้เล็กลง ไอเกนเฟส (Eigenface) หมายถึง ชุดเวกเตอร์ที่ใช้ในกระบวนการและการรู้จำใบหน้าของมนุษย์ เรียกอีกอย่างว่า ไอเกนเวกเตอร์

Modified 2DPCA (M-2DPCA) หมายถึง ปรับปรุงวิธีการ 2DPCA สำหรับการรู้จำใบหน้า 2DPCA หมายถึง การวิเคราะห์องค์ประกอบหลัก 2 มิติ

## 1.6 แผนการดำเนินงานวิจัย

## ตาราง 1 แผนการดำเนินงานวิจัย



## บทที่ 2

### เอกสารรายงานวิจัยที่เกี่ยวข้อง

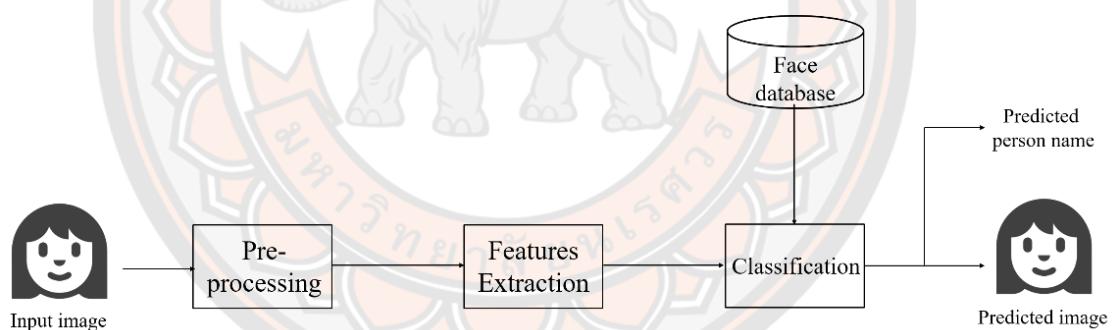
ในงานวิจัยนี้ผู้วิจัยได้ศึกษาแนวคิดและทฤษฎีรวมไปถึงงานวิจัยที่เกี่ยวข้อง เพื่อนำมาประยุกต์ใช้ในการทำงานวิจัยประกอบด้วยเนื้อหาดังต่อไปนี้

- 3.1 ทฤษฎีที่เกี่ยวข้อง
- 3.2 งานวิจัยที่เกี่ยวข้อง

#### 2.1 ทฤษฎีที่เกี่ยวข้อง

##### 2.1.1 การรู้จำใบหน้า

กระบวนการการรู้จำใบหน้า (Face Recognition Process) นั้นแบ่งออกเป็น 3 ขั้นตอนหลักได้แก่ การประมวลผลภาพเบื้องต้น (Pre-Processing) การสกัดหาคุณลักษณะเฉพาะ (Features Extraction) และการจำแนก (Classification) แสดงดังภาพ 5



ภาพ 5 กระบวนการรู้จำใบหน้า

1. การประมวลผลภาพเบื้องต้น คือ การรับเปลี่ยนลักษณะบางอย่างของรูปภาพ นำเข้าเพื่อให้มีความเหมาะสมสมต่อการนำไปใช้ เช่น การแปลงภาพเป็นภาพระดับสีเทา (Grayscale) เป็นต้น

2. การสกัดหาคุณลักษณะเฉพาะ คือ การสกัดคุณลักษณะเฉพาะของรูปภาพเพื่อให้ร่ายต่อการจำแนก ซึ่งสามารถเลือกใช้ได้หลากหลายวิธี เช่น การวิเคราะห์องค์ประกอบหลัก และการวิเคราะห์การจำแนกประเภทเชิงเส้น เป็นต้น

3. การจำแนก คือ การจำแนกรูปภาพบุคคลจากกลุ่มของคุณลักษณะเฉพาะภาพบุคคลนี้เป็นบุคคลใด ซึ่งเทคนิคการจำแนกนั้นมีได้หลากหลายวิธีด้วยกัน เช่น การค้นหาเพื่อนบ้านใกล้สุด k อันดับ (K-nearest neighbor: K-NN) ต้นไม้ตัดสินใจ (Decision tree) และการหาระยะทางแบบยุคคลิด (Euclidean Distance) เป็นต้น

### 2.1.2 ไอเกนเฟส

ไอเกนเฟสได้ถูกพัฒนาโดย Sirovich และ Kirby (Sirovich & Kirby, 1987) ซึ่ง ไอเกนเฟสเป็นชื่อเรียกชุดของไอเกนเวกเตอร์ ที่ใช้ในการรู้จำใบหน้าของมนุษย์ และเป็นวิธีที่ไม่ออาศัยกับลักษณะใบหน้า เช่น ไม่สนใจความห่างของตาหรือปาก เป็นต้น นอกจากนี้ ไอเกนเฟสยังสามารถใช้ในงานด้านอื่น ๆ เช่น การวิเคราะห์ลายมือ การอ่านริมฝีปาก หรือแม้กระทั่งการวิเคราะห์รูปทางการแพทย์ เป็นต้น

การสร้างแบบจำลองไอเกนเฟสสามารถทำได้จากการทางสถิติ โดยใช้เมทริกซ์ความแปรปรวนร่วมเพื่อนำไปหาลักษณะเฉพาะหรือเวกเตอร์ลักษณะเฉพาะ ซึ่งเป็นแนวทางหนึ่งในทฤษฎีของการวิเคราะห์องค์ประกอบหลัก

## 2.2 งานวิจัยที่เกี่ยวข้อง

การรวบรวมงานวิจัยที่เกี่ยวข้องในส่วนนี้มุ่งเน้นที่จะค้นคว้าเกี่ยวกับที่มาของวิธีการวิเคราะห์องค์ประกอบหลักและวิจัยที่เกี่ยวกับการพัฒนาวิธีการวิเคราะห์องค์ประกอบหลักสำหรับการรู้จำใบหน้า เพื่อเข้าใจแนวคิดและกระบวนการของการพัฒนาวิธีการวิเคราะห์องค์ประกอบหลักและนำไปประยุกต์ใช้ปัจจุบันเพื่อเพิ่มประสิทธิภาพการทำงานต่อไป

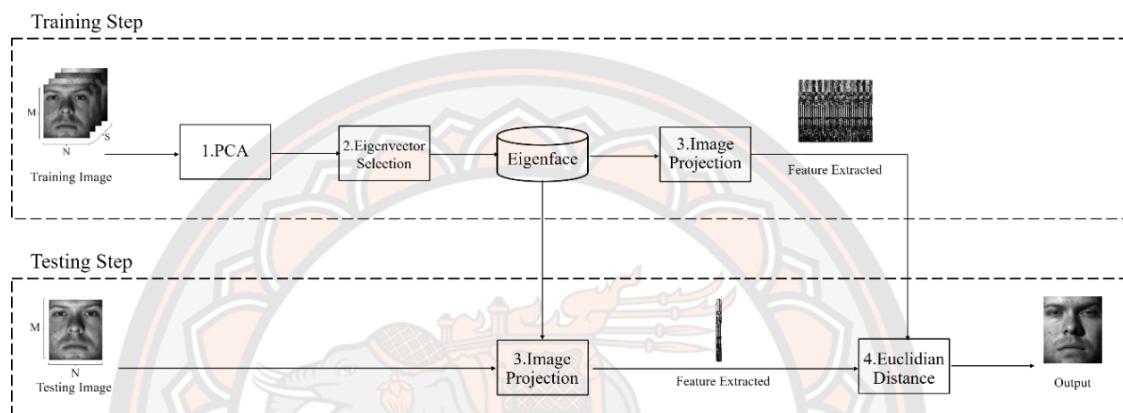
### 2.2.1 การวิเคราะห์องค์ประกอบหลักสำหรับการรู้จำใบหน้า

L. Sirovich and M. Kirby, 1987 ได้นำเสนองานวิจัยที่เกี่ยวกับการนำการวิเคราะห์องค์ประกอบหลัก มาประยุกต์ใช้ในการรู้จำใบหน้าของมนุษย์ครั้งแรก เนื่องจากกระบวนการของ PCA สามารถสกัดคุณลักษณะเฉพาะและยังสามารถช่วยอธิบายข้อมูลในรูปแบบของความสัมพันธ์ว่าข้อมูลนั้นเหมือนหรือแตกต่างกัน นอกจากนี้ งานวิจัยนี้ใช้ PCA ใน การพัฒนาชุดของไอเกนเวกเตอร์ที่ใช้ในการรู้จำใบหน้าของมนุษย์โดยเรียกชุดไอเกนเวกเตอร์เหล่านี้ว่า ไอเกนเฟส

หลักการทำงานของวิธีการ PCA สำหรับการรู้จำใบหน้า คือการวิเคราะห์ข้อมูลและเก็บข้อมูลในรูปแบบความสัมพันธ์ เมื่อพิจารณาองค์ประกอบของรูปภาพซึ่งประกอบด้วย 2 ส่วนได้แก่ 1) บริเวณที่ข้อมูลมีการเปลี่ยนแปลงมากหรือเรียกว่า ข้อมูลที่มีความถี่สูง (High Frequency) เช่น เส้นขอบ รูปร่าง และลวดลาย เป็นต้น 2) บริเวณที่ข้อมูลไม่มีการเปลี่ยนแปลงหรือเรียกว่า ข้อมูลที่มีความถี่ต่ำ (Low Frequency) เช่น เนื้อสี แสงเงา เป็นต้น PCA จะพยายามกำหนดข้อมูลที่มีความถี่ต่ำ

เพื่อหาความสัมพันธ์ในส่วนของข้อมูลที่มีความถี่สูงหรือกล่าวได้ว่า PCA จะหาความสัมพันธ์ในส่วนของรูปร่างของใบหน้า หรือโครงหน้า ซึ่งเป็นองค์ประกอบหลักสำหรับการรู้จำใบหน้า โดยใช้การคำนวณหาความแปรปรวนร่วม

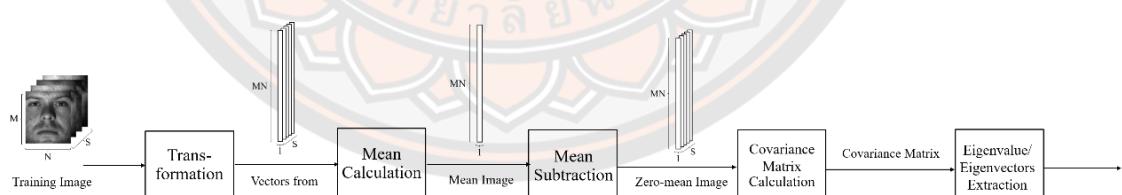
โดยกระบวนการทำงานการรู้จำใบหน้าด้วยวิธีการ PCA นี้ จะแบ่งการทำงานออกเป็น 2 กระบวนการหลัก คือ กระบวนการฝึกสอน (Training Step) และกระบวนการทดสอบ (Testing Step) ดังภาพ 6



ภาพ 6 ขั้นตอนการทำงานของวิธีการ PCA สำหรับการรู้จำใบหน้า

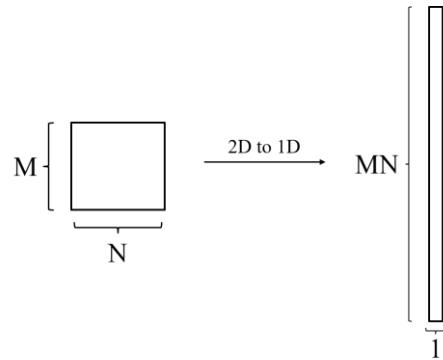
#### กระบวนการฝึกสอน

ขั้นตอนที่ 1 กระบวนการ PCA โดยการนำเข้าชุดรูปภาพฝึกสอน เพื่อผ่านขั้นตอนวิธี PCA ดังแสดงในภาพ 7 เพื่อสกัดคุณลักษณะเฉพาะของแต่ละบุคคล



ภาพ 7 วิธีการสกัดไอกenen เวกเตอร์และค่าไอกenen ของวิธีการ PCA

1) การแปลงรูปภาพ (Transformation) ซึ่งเป็นการนำรูปภาพขนาด  $M \times N$  พิกเซล ให้อยู่ในรูปของเวกเตอร์ขนาด  $MN \times 1$  พิกเซล ดังภาพ 8



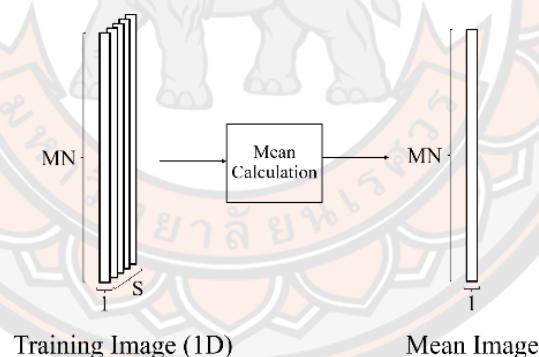
ภาพ 8 ขั้นตอนการแปลงรูปภาพ

2) การคำนวณค่าเฉลี่ย (Mean Calculation) เพื่อหาตัวแทนที่เป็นข้อมูลที่มีความถี่ต่ำ โดยคำนวณค่าเฉลี่ย ( $\bar{F}$ ) ของเวกเตอร์ของรูปภาพทั้งหมด ดังสมการที่ 1 และผลลัพธ์ที่ได้ดังภาพ 9

$$\bar{F} = \frac{1}{S} \sum_{i=1}^S F_i \quad (1)$$

เมื่อ  $F_i$  คือ เวกเตอร์ของรูปภาพที่มีขนาด  $MN \times 1$  พิกเซล

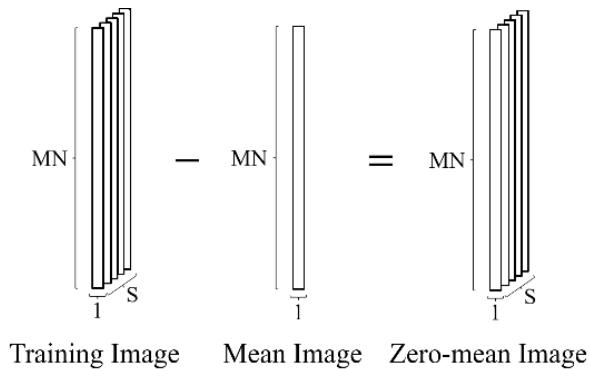
$S$  คือ จำนวนรูปภาพฝึกสอน



ภาพ 9 ขั้นตอนการคำนวณค่าเฉลี่ยของวิธีการ PCA

2) การลบด้วยค่าเฉลี่ย (Mean Subtraction) เพื่อกำจัดข้อมูลที่มีความถี่ต่ำและพิจารณาเฉพาะข้อมูลที่มีความถี่สูง โดยการนำรูปภาพนำเข้าที่อยู่ในรูปเวกเตอร์ ( $F_i$ ) แต่ละรูปลบกับรูปเวกเตอร์ค่าเฉลี่ย ดังสมการที่ 2 ซึ่งผลลัพธ์ที่ได้เรียกว่า รูปภาพที่ปราศจากค่าเฉลี่ย (Zero-Mean Image :  $\Delta_i$ ) แสดงในภาพ 10

$$\Delta_i = F_i - \bar{F} \quad (2)$$



ภาพ 10 ตัวอย่างผลลัพธ์ของการลบด้วยค่าเฉลี่ยจากวิธีการ PCA

3) การคำนวณเมทริกซ์ความแปรปรวนร่วม (Covariance Matrix Calculation) เพื่อเก็บความสัมพันธ์ของข้อมูลที่มีความถี่สูงและหาความสัมพันธ์ระหว่างรูปภาพให้อยู่ในรูปของเมทริกซ์ โดยนำรูปภาพที่ปราศจากค่าเฉลี่ยไปคำนวณหาเมทริกซ์ความแปรปรวนร่วม ( $\psi$ ) ดังสมการที่ 3-4

$$Cov(\Delta_i, \Delta_j) = \frac{1}{S-1} \sum_{i=1}^S \sum_{j=1}^S \Delta_i \Delta_j \quad (3)$$

$$\psi = \begin{bmatrix} Cov(\Delta_1, \Delta_1) & Cov(\Delta_1, \Delta_2) & \dots & Cov(\Delta_1, \Delta_S) \\ Cov(\Delta_2, \Delta_1) & Cov(\Delta_2, \Delta_2) & \dots & Cov(\Delta_2, \Delta_S) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(\Delta_S, \Delta_1) & Cov(\Delta_S, \Delta_2) & \dots & Cov(\Delta_S, \Delta_S) \end{bmatrix} \quad (4)$$

4) การสกัดໄอเกนເວກເຕອຣ໌ และค່າໄອເກນ (Eigenvector and Eigenvalue Extraction) หลังจากที่ได้ค่าของเมทริกซ์ความแปรปรวนร่วม ก็จะนำค่านี้ไปคำนวณหาໄอเกนເວກເຕອຣ໌ และค່າໄອເກນ ดังสมการที่ 5

$$AV = V\psi \quad (5)$$

เมื่อ  $V$  คือ ໄอเกนເວກເຕອຣ໌

$A$  คือ ค່າໄອເກນ

ขั้นตอนที่ 2 การเลือกจำนวนของໄอเกนເວກເຕອຣ໌ (Eigenvectors Selection) เลือกໄอเกนເວກເຕອຣ໌ โดยเลือกจำนวนໄอเกนເວກເຕອຣ໌ตัวที่ 1 ถึงตัวที่  $p$ ,  $\tilde{A} = \{a_1, a_2, \dots, a_p\}$ , เมื่อ  $p$  คือ จำนวนของໄอเกนເວກເຕອຣ໌ ที่ต้องใช้ในการสร้างໄอเกนເຟສ ໂດຍທີ່ຄ່າ  $p$  ທີ່ແມະສມຈະຖືກພິຈານາຈາກກາຮາດລອງໂດຍເຮັມຈາກເລືອກໄอเกນເວກເຕອຣ໌ตัวที่ 1 ຈາກນັ້ນຈະພິຈານາຄ່າຄວາມຖຸກຕ້ອງແລະເພີ່ມຄ່າ  $p$  ທີ່ລະ 1 ສຸດທ້າຍຈະເລືອກຄ່າ  $p$  ທີ່ມີຄ່າຄວາມຖຸກຕ້ອງທີ່ສຸດ

ขั้นตอนที่ 3 การฉายภาพ (Image Projection) คือ คำนวณไอเกนเฟส ( $\Gamma_i$ ) โดยการฉายภาพรูปภาพฝึกสอน ( $I_i$ ) กับเวกเตอร์  $\tilde{A}$  ดังสมการที่ 6

$$\Gamma_i = I_i \tilde{A} \quad (6)$$

#### กระบวนการทดสอบ

นำเข้ารูปภาพทดสอบ จากนั้นลบกับรูปภาพค่าเฉลี่ย ( $\bar{F}$ ) และทำการฉายภาพ (Image Projection) เช่นเดียวกับขั้นตอนที่ 3 ของกระบวนการฝึกสอน

ขั้นตอนที่ 4 ระยะทางแบบยุคลิด นำค่าที่ได้จากการฉายภาพฝึกมาเปรียบเทียบกับค่าที่ได้จากการฉายภาพของรูปภาพทดสอบโดยวิธีการวัดระยะทางแบบยุคลิด ( $d_{i,j}$ ) ดังสมการที่ 7 เพื่อความคล้ายคลึงของรูปภาพทดสอบว่าตรงกับบุคคลใดในฐานข้อมูลของชุดรูปภาพฝึกสอน

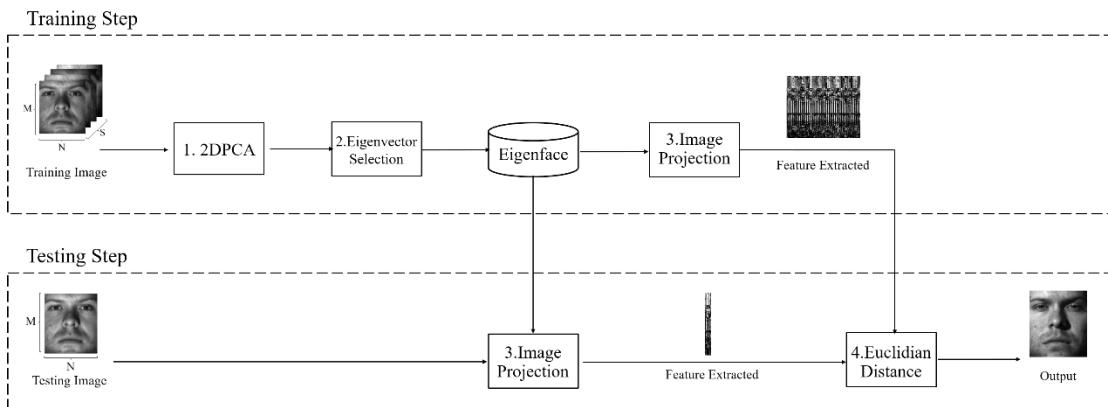
$$d_{i,j} = \sqrt{\sum_{p=1}^P (\Gamma_i(p) - \Gamma_j(p))^2} \quad (7)$$

เมื่อ  $\Gamma_i$  คือ ไอเกนเฟสของชุดรูปภาพฝึกสอน  
 $\Gamma_j$  คือ ไอเกนเฟสของชุดรูปภาพทดสอบ  
 $P$  คือ ความยาวของไอเกนเฟส

#### 2.2.2 การวิเคราะห์องค์ประกอบหลัก 2 มิติ

Jian Yang, et al. 2004 ได้ศึกษา PCA และพบว่า PCA มีการแปลงรูปภาพให้อยู่ในรูปของเวกเตอร์ จึงทำให้ใช้เวลาในการประมวลผลนาน จึงได้พัฒนา two-dimensional principal component analysis (2DPCA) ที่สามารถใช้รูปภาพในการจำแนกข้อมูลได้โดยไม่ต้องแปลงให้อยู่ในรูปของเวกเตอร์เหมือนกับ PCA จึงทำให้ง่ายต่อการคำนวณหาความแปรปรวนร่วมทำให้ประหยัดเวลาในการคำนวณหาไอเกนเวกเตอร์ และผลลัพธ์ของค่าความถูกต้องของ 2DPCA มากกว่า PCA

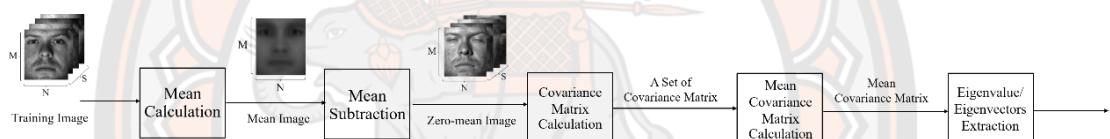
โดยกระบวนการทำงานการรักษาไว้หน้าด้วยวิธีการ 2DPCA นี้ จะแบ่งการทำงานออกเป็น 2 กระบวนการหลัก คือ กระบวนการฝึกสอน และกระบวนการทดสอบ ดังภาพ 11



ภาพ 11 ขั้นตอนการทำงานของ 2DPCA สำหรับการรู้จำใบหน้า

### กระบวนการฝึกสอน

ขั้นตอนที่ 1 กระบวนการ 2DPCA โดยการนำเข้าชุดรูปภาพฝึกสอน เพื่อผ่านขั้นตอนวิธี 2DPCA ดังแสดงในภาพ 12 เพื่อสกัดคุณลักษณะเฉพาะของใบหน้าของแต่ละบุคคล



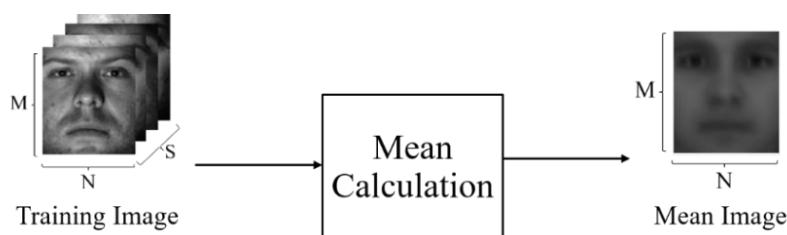
ภาพ 12 วิธีการสกัดไอกenenเวกเตอร์และค่าไอกenenของ 2DPCA

1) การคำนวณค่าเฉลี่ย (Mean Calculation) คือ การคำนวณหาค่าเฉลี่ยของรูปภาพทั้งหมด โดยรูปภาพนำเข้าต้องเป็นภาพระดับสีเทา ผลลัพธ์ที่ได้ คือ รูปภาพค่าเฉลี่ยของรูปภาพทั้งหมด หรือเรียกว่า รูปภาพค่าเฉลี่ย ( $\bar{I}$ ) ดังสมการที่ 8 และผลลัพธ์ที่ได้จะแสดงเห็นในภาพ 13

$$\bar{I} = \frac{1}{S} \sum_{i=1}^S I_i \quad (8)$$

เมื่อ  $I_i$  คือ รูปภาพฝึกสอนขนาด  $M \times N$  พิกเซล

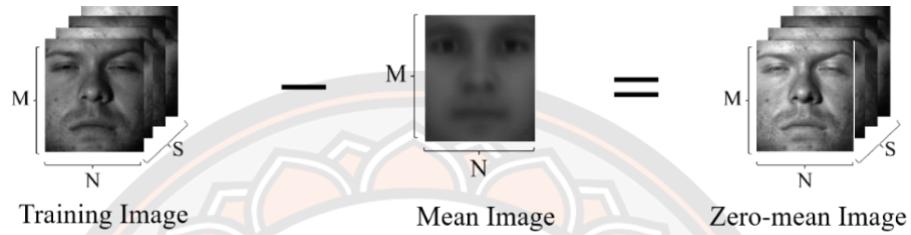
$S$  คือ จำนวนรูปภาพฝึกสอน



ภาพ 13 ตัวอย่างผลลัพธ์ของการคำนวณค่าเฉลี่ยของวิธีการ 2DPCA

2) การลบด้วยค่าเฉลี่ย (Mean Subtraction) คือ การนำข้อมูลรูปภาพมาลบกับรูปภาพค่าเฉลี่ย ( $\bar{I}$ ) ดังสมการที่ 9 และผลลัพธ์ที่ คือ รูปภาพที่ปราศจากค่าเฉลี่ย ( $\Lambda_i$ ) ดังภาพ 14

$$\Lambda_i = I_i - \bar{I} \quad (9)$$



ภาพ 14 ตัวอย่างผลลัพธ์ของการลบด้วยค่าเฉลี่ยของวิธีการ 2DPCA

3) การคำนวณเมทริกซ์ความแปรปรวนร่วม (Covariance Matrix Calculation) คือ การนำรูปภาพที่ปราศจากค่าเฉลี่ย ( $\Lambda_i$ ) ไปคำนวณหาเมทริกซ์ความแปรปรวนร่วม ดังสมการที่ 10 และผลลัพธ์ที่ได้ คือ ชุดของเมทริกซ์ความแปรปรวนร่วม ( $\psi_i$ )

$$\psi_i = \Lambda_i \Lambda_i^T \quad (10)$$

4) การคำนวณค่าเฉลี่ยของเมทริกซ์ความแปรปรวนร่วม (Mean Covariance Matrix Calculation) คือ การนำชุดของเมทริกซ์ความแปรปรวนร่วมไปคำนวณหาค่าเฉลี่ย ดังสมการที่ 11 และผลลัพธ์ที่ได้จะเรียกว่าค่าเฉลี่ยของเมทริกซ์ความแปรปรวนร่วม ( $\bar{\psi}$ )

$$\bar{\psi}(m, n) = \frac{1}{S} \sum_{i=1}^S \psi_i(m, n) \quad (11)$$

5) การสกัดໄอเกนเวกเตอร์ และค่าໄอเกน (Eigenvector and Eigenvalue Extraction) คือ การนำค่าเฉลี่ยของเมทริกซ์ความแปรปรวนร่วมไปคำนวณหาໄอเกนเวกเตอร์ และค่าໄอเกน ดังสมการที่ 12

$$AV = V\bar{\psi} \quad (12)$$

เมื่อ  $V$  คือ ໄอเกนเวกเตอร์

$A$  คือ ค่าໄอเกน

ขั้นตอนที่ 2 มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงใน บทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 2

**ขั้นตอนที่ 3** มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงใน บทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 3

#### กระบวนการทดสอบ

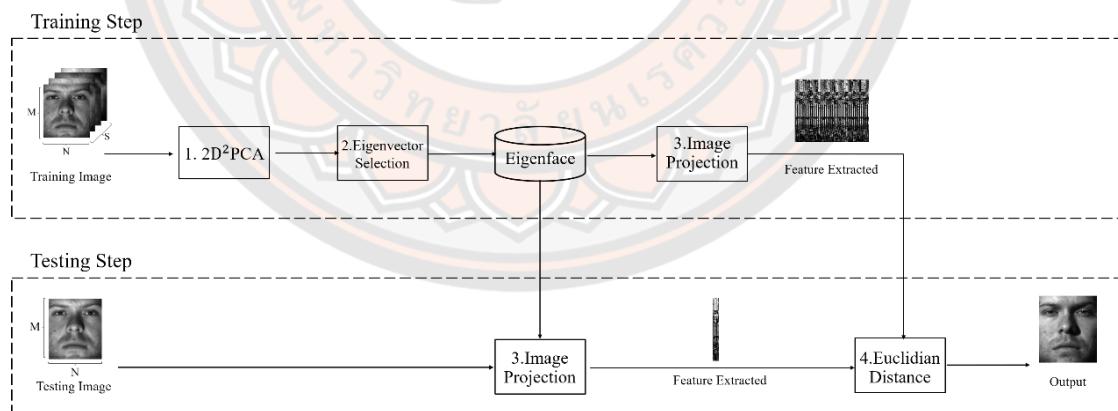
นำเข้ารูปภาพทดสอบ จากนั้นลบกับรูปภาพค่าเฉลี่ย ( $\bar{I}$ ) และทำการฉายภาพ (Image Projection) เช่นเดียวกับขั้นตอนที่ 3 ของกระบวนการฝึกสอน

**ขั้นตอนที่ 4** มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงใน บทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 4

#### 2.2.3 การวิเคราะห์องค์ประกอบหลัก 2 มิติแบบ 2 ทิศทาง

Daoqiang Zhang และ Zhi-Hua Zhou, 2005 ได้ศึกษาหลักการทำงานของ วิธีการ 2DPCA และพบว่าวิธีการ 2DPCA นั้นคำนวนหาเมทริกซ์ความแปรปรวนร่วมเพียงทิศทางเดียว (แนว) จึงส่งผลให้มีอุปกรณ์เฉพาะส่วนของทิศทางนั้น ในขณะที่เมทริกซ์ประกอบไปด้วย แนวและหลัก ดังนั้น Zhang และ Zhou จึงได้เสนอ Two-directional two-dimensional PCA ( $2D^2PCA$ ) ที่พัฒนาต่อยอดมาจากการ 2DPCA โดยการใช้เมทริกซ์ความแปรปรวนร่วม 2 ทิศทาง เพื่อให้มีอุปกรณ์เฉพาะของทั้ง 2 ทิศทาง ทำให้มีค่าความถูกต้องมากกว่าวิธีการ 2DPCA

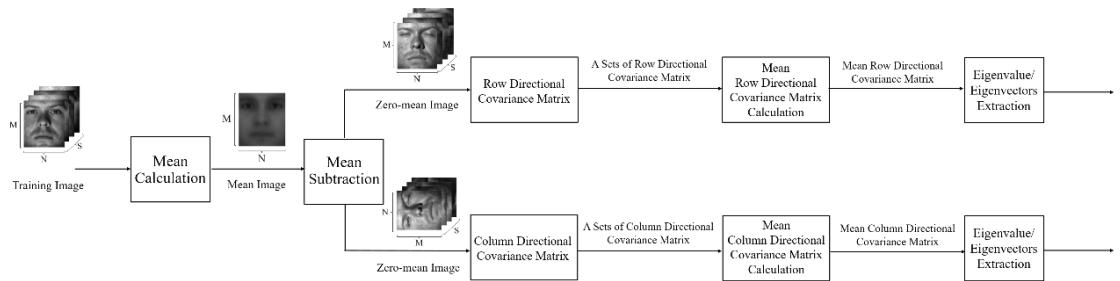
โดยกระบวนการทำงานการรู้จำใบหน้าด้วยวิธีการ  $2D^2PCA$  นี้ จะแบ่งการทำงานออกเป็น 2 กระบวนการหลัก คือ กระบวนการฝึกสอน และกระบวนการทดสอบ ดังภาพ 15



ภาพ 15 ขั้นตอนการทำงานของวิธีการ  $2D^2PCA$  สำหรับการรู้จำใบหน้า

#### กระบวนการฝึกสอน

**ขั้นตอนที่ 1** กระบวนการ  $2D^2PCA$  โดยการนำเข้าชุดรูปภาพฝึกสอน เพื่อผ่านขั้นตอนวิธี  $2D^2PCA$  ดังแสดงในภาพ 16 เพื่อสกัดคุณลักษณะเฉพาะของใบหน้าของแต่ละบุคคล



ภาพ 16 วิธีการสกัดไอกenen เวกเตอร์และค่าไอกenen ของวิธีการ 2D<sup>2</sup>PCA

1) การคำนวณค่าเฉลี่ย (Mean Calculation) สามารถคำนวณเช่นเดียวกับวิธีการ 2DPCA จากสมการที่ 8 และผลลัพธ์ที่ได้รูปภาพค่าเฉลี่ย ( $\bar{I}$ ) ดังภาพ 13 ในบทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 1 ข้อที่ 1

2) การลบด้วยค่าเฉลี่ย (Mean Subtraction) คือ การนำข้อมูลรูปภาพมาลบกับรูปภาพค่าเฉลี่ย ( $\bar{I}$ ) สามารถคำนวณได้จากสมการที่ 9 และผลลัพธ์ที่ คือ รูปภาพที่ปราศจากค่าเฉลี่ย ( $\Lambda_i$ ) ดังภาพ 14 ในบทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 1 ข้อที่ 2

3) การคำนวณเมทริกซ์ความแปรปรวนร่วม (Covariance Matrix Calculation) นำรูปภาพที่ปราศจากค่าเฉลี่ย ( $\Lambda_i$ ) ไปคำนวณหาเมทริกซ์ความแปรปรวนร่วม 2 ทิศทาง (แนวและหลัก) ดังสมการที่ 13 และ 14 ผลลัพธ์ที่ได้ คือ ชุดของเมทริกซ์ความแปรปรวนร่วมของทั้ง 2 ทิศทาง

$$\psi_i = \Lambda_i \Lambda_i^T \quad (13)$$

$$\varphi_i = \Lambda_i^T \Lambda_i \quad (14)$$

เมื่อ  $\psi_i$  คือ เมทริกซ์ความแปรปรวนร่วมของแนว

$\varphi_i$  คือ เมทริกซ์ความแปรปรวนร่วมของหลัก

4) การคำนวณค่าเฉลี่ยของเมทริกซ์ความแปรปรวนร่วม (Mean Covariance Matrix Calculation) คือ การนำชุดของเมทริกซ์ความแปรปรวนร่วมทั้ง 2 ทิศทาง ไปคำนวณหาค่าเฉลี่ยของแต่ละทิศทาง ดังสมการที่ 15 และ 16 ซึ่งผลลัพธ์ที่ได้เรียกว่า ค่าเฉลี่ยของเมทริกซ์ความแปรปรวนร่วมของแนว ( $\bar{\psi}$ ) และค่าเฉลี่ยของเมทริกซ์ความแปรปรวนร่วมของหลัก ( $\bar{\varphi}$ )

$$\bar{\psi}(m, n) = \frac{1}{S} \sum_{i=1}^S \psi_i(m, n) \quad (15)$$

$$\bar{\varphi}(m, n) = \frac{1}{S} \sum_{i=1}^S \varphi_i(m, n) \quad (16)$$

เมื่อ  $\psi_i$  คือ เมทริกซ์ความแปรปรวนร่วมของแผล

$\varphi_i$  คือ เมทริกซ์ความแปรปรวนร่วมของหลัก

$S$  คือ จำนวนรูปภาพฝึกสอนทั้งหมด

5) การสกัดໄอเกนเวกเตอร์ และค่าໄอเกน (Eigenvector and Eigenvalue Extraction) คือ การนำค่าเฉลี่ยของเมทริกซ์ความแปรปรวนร่วมของทั้ง 2 ทิศทางไปคำนวณหาໄอเกนเวกเตอร์ และ ค่าໄอเกน ดังสมการที่ 17 และ 18

$$A_r V_r = V_r \bar{\psi} \quad (17)$$

$$A_c V_c = V_c \bar{\varphi} \quad (18)$$

เมื่อ  $V_r$  คือ ໄอเกนเวกเตอร์ ที่คำนวณจากเมทริกซ์ความแปรปรวนร่วมของแผล

$A_r$  คือ ค่าໄอเกน ที่คำนวณจากเมทริกซ์ความแปรปรวนร่วมของแผล

$V_c$  คือ ໄอเกนเวกเตอร์ ที่คำนวณจากเมทริกซ์ความแปรปรวนร่วมของหลัก

$A_c$  คือ ค่าໄอเกน ที่คำนวณจากเมทริกซ์ความแปรปรวนร่วมของหลัก

ขั้นตอนที่ 2 การเลือกจำนวนของໄอเกนเวกเตอร์ (Eigenvectors Selection) เลือกໄอเกน เวกเตอร์โดยทำการเลือก 2 ครั้ง 1) เลือกໄอเกนเวกเตอร์ ที่คำนวณจากเมทริกซ์ความแปรปรวนร่วม ของแผล เลือกจากตัวแรกถึง  $p$  เวกเตอร์  $\tilde{A}_r = \{a_1, a_2, \dots, a_p\}$  เมื่อ  $p$  คือจำนวนของໄอเกน เวกเตอร์ ที่ต้องใช้ในการสร้างໄอเกนเฟส 2) เลือกໄอเกนเวกเตอร์ ที่คำนวณจากเมทริกซ์ความ แปรปรวนร่วมของหลัก เลือกจากตัวแรกถึง  $q$  เวกเตอร์  $\tilde{A}_c = \{a_1, a_2, \dots, a_q\}$  เมื่อ  $q$  คือจำนวน ของໄอเกนเวกเตอร์ ที่ต้องใช้ในการสร้างໄอเกนเฟส โดยที่ค่า  $p$  และ  $q$  ที่เหมาะสมจะถูกพิจารณา จากการทดลองโดยเริ่มจากเลือกໄอเกนเวกเตอร์ตัวที่ 1 จากนั้นจะพิจารณาค่าความถูกต้องและเพิ่มค่า  $p$  และ  $q$  ทีละ 1 สุดท้ายจะเลือกค่า  $p$  และ  $q$  ที่มีค่าความถูกต้องที่สุด

ขั้นตอนที่ 3 การฉายภาพ (Image Projection) คำนวณໄอเกนเฟส ( $\Gamma$ ) โดยการฉายภาพรูปภาพ ฝึกสอน ( $I_i$ ) กับໄอเกนเวกเตอร์ ดังสมการที่ 19

$$\Gamma_i = \tilde{A}_c^T I_i \tilde{A}_r \quad (19)$$

#### กระบวนการทดสอบ

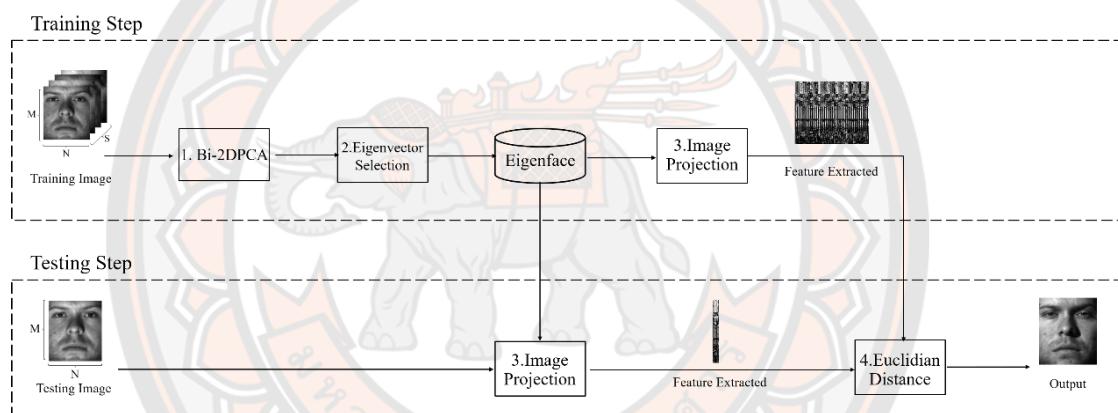
นำเข้ารูปภาพทดสอบ จากนั้นลบกับรูปภาพค่าเฉลี่ย ( $\bar{I}$ ) และทำการฉายภาพ (Image Projection) เช่นเดียวกับขั้นตอนที่ 3 ของกระบวนการฝึกสอน

ขั้นตอนที่ 4 มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงในบทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 4

#### 2.2.4 การวิเคราะห์องค์ประกอบหลัก 2 มิติแบบ 2 ทิศทางโดยอาศัยสมการเชิงเส้นสำหรับการสร้างไอกenenเฟส

Youngh-Gil Kim, et al. 2008 ได้นำเสนอการพัฒนาวิธีการ Bi2DPCA เป็น bidirectional 2DPCA (Bi2DPCA) ที่ใช้เมทริกซ์ความแปรปรวนร่วม 2 ทิศทาง (แนวและหลัก) และสร้างไอกenenเฟสโดยใช้วิธีการแปลงเชิงเส้น (Linear Transformation) ทำให้ได้ผลลัพธ์ที่ดีและมีเสถียรภาพมากกว่าวิธีการ 2DPCA

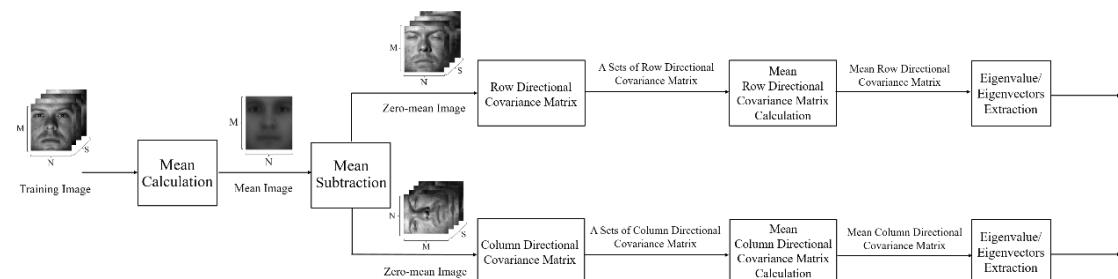
โดยกระบวนการทำงานการรู้จำใบหน้าด้วยวิธีการ Bi2DPCA นี้ จะแบ่งการทำงานออกเป็น 2 กระบวนการหลัก คือ กระบวนการฝึกสอน และกระบวนการทดสอบ ดังภาพ 17



ภาพ 17 ขั้นตอนการทำงานของวิธีการ Bi2DPCA สำหรับการรู้จำใบหน้า

#### กระบวนการฝึกสอน

ขั้นตอนที่ 1 กระบวนการ Bi2DPCA โดยการนำเข้าชุดรูปภาพฝึกสอน เพื่อผ่านขั้นตอนวิธี Bi2DPCA ดังแสดงในภาพ 18 เพื่อสกัดคุณลักษณะเฉพาะของใบหน้าของแต่ละบุคคล



ภาพ 18 วิธีการสกัดไอกenenเฟกเตอร์และค่าไอกenenของวิธีการ Bi2DPCA

1) การคำนวณค่าเฉลี่ย (Mean Calculation) สามารถคำนวณเช่นเดียวกับวิธีการ 2DPCA จากสมการที่ 8 และผลลัพธ์ที่ได้ คือ รูปภาพค่าเฉลี่ย ( $\bar{I}$ ) ดังภาพ 13 ในบทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 1 ข้อที่ 1

2) การลบด้วยค่าเฉลี่ย (Mean Subtraction) คือ การนำข้อมูลรูปภาพมาลบกับรูปภาพค่าเฉลี่ย ( $\bar{I}$ ) สามารถคำนวณได้จากสมการที่ 9 และผลลัพธ์ คือ รูปภาพที่ปราศจากค่าเฉลี่ย ( $\Lambda_i$ ) ดังภาพ 14 ในบทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 1 ข้อที่ 2

3) การคำนวณเมทริกซ์ความแปรปรวนร่วม (Covariance Matrix Calculation) นำรูปภาพที่ปราศจากค่าเฉลี่ย ( $\Lambda_i$ ) ไปคำนวณหาเมทริกซ์ความแปรปรวนร่วม 2 ทิศทาง (ແລວและหลัก) สามารถคำนวณได้จากสมการที่ 13 และ 14 ในบทที่ 2 หัวข้อที่ 2.2.3 ขั้นตอนที่ 1 ข้อที่ 3

4) การคำนวณค่าเฉลี่ยของเมทริกซ์ความแปรปรวนร่วม (Mean Covariance Matrix Calculation) คือ การนำชุดของเมทริกซ์ความแปรปรวนร่วมทั้ง 2 ทิศทาง ไปคำนวณหาค่าเฉลี่ยของแต่ละทิศทาง สามารถคำนวณได้จากสมการที่ 15 และ 16 ในบทที่ 2 หัวข้อที่ 2.2.3 ขั้นตอนที่ 1 ข้อที่ 4 และผลลัพธ์ที่ คือ ค่าเฉลี่ยของเมทริกซ์ความแปรปรวนร่วมของແລວ ( $\bar{\psi}$ ) และ ค่าเฉลี่ยของเมทริกซ์ความแปรปรวนร่วมของหลัก ( $\bar{\varphi}$ )

5) การสกัดໄอเกนເວກເຕອ່ງและค່າໄອເກນ (Eigenvector and Eigenvalue Extraction) คือ การนำค่าเฉลี่ยของเมทริกซ์ความแปรปรวนร่วมของทั้ง 2 ทิศทางไปคำนวณหาໄอเกนເວກເຕອ່ງ และ ค່າໄອເກນ สามารถคำนวณได้จากสมการที่ 17 และ 18 ในบทที่ 2 หัวข้อที่ 2.2.3 ขั้นตอนที่ 1 ข้อที่ 5

**ขั้นตอนที่ 2 การเลือกจำนวนของໄอเกนເວກເຕອ່ງ มีวิธีการเลือกจำนวนໄอเกนເວກເຕອ່ງแบบเดียวกับวิธีการของ 2D<sup>2</sup>PCA ดังแสดงในบทที่ 2 หัวข้อที่ 2.2.3 ขั้นตอนที่ 2**

**ขั้นตอนที่ 3 การฉายภาพ คำนวณໄอเกนເຟ (Γ) จากการฉายภาพรูปภาพຝຶກສອນ ( $I_i$ ) กັບໄອເກນເວກເຕອ່ງ โดยໃຫ້ເຕັມນີກແປລັງເຊີງເສັ້ນ (linear transform) ดังສາມາດที่ 20**

$$\Gamma_i = I_i^T \tilde{A}_r + I_i \tilde{A}_c \quad (20)$$

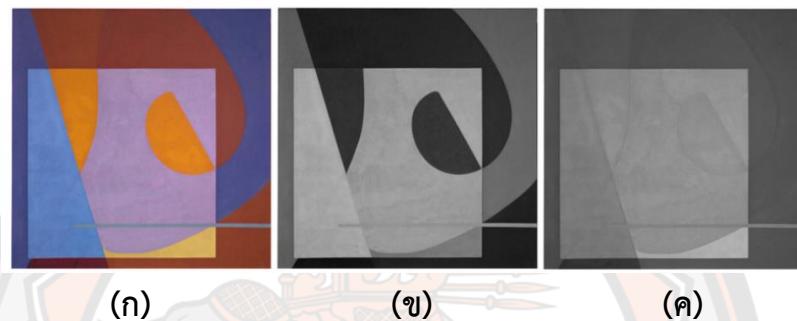
#### กระบวนการทดสอบ

นำเข้ารูปภาพทดสอบ จากนั้นลบกับรูปภาพค่าเฉลี่ย ( $\bar{I}$ ) และทำการฉายภาพ (Image Projection) เช่นเดียวกับขั้นตอนที่ 3 ของกระบวนการຝຶກສອນ

**ขั้นตอนที่ 4 มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงในบทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 4**

### 2.2.5 การฉายปริภูมิย่อของผลรวมเชิงเส้นแบบถ่วงน้ำหนักโดยอัศัยค่าไオเกน

Ja-Won Seo, et al. 2013 ได้นำเสนอการฉายปริภูมิย่อของผลรวมเชิงเส้นแบบถ่วงน้ำหนักโดยอัศัยค่าไオเกน (Eigenvalue-weighted Linear Sum of Subspace Projections: ELSSP) มาประยุกต์ใช้ในเรื่องการแปลงภาพสี (RGB) เป็นภาพระดับสีเทาแทนการใช้เทคนิคการหาค่าเฉลี่ย เนื่องจากการใช้เทคนิคการหาค่าเฉลี่ยในการแปลงภาพสีเป็นภาพระดับสีเทานั้นไม่สามารถคงรายละเอียดบางส่วนไว้ได้ แสดงดังภาพ 19 (ค) ส่วนวิธีการ ELSSP นั้นยังคงรักษารายละเอียดได้ดังภาพ 19 (ข)



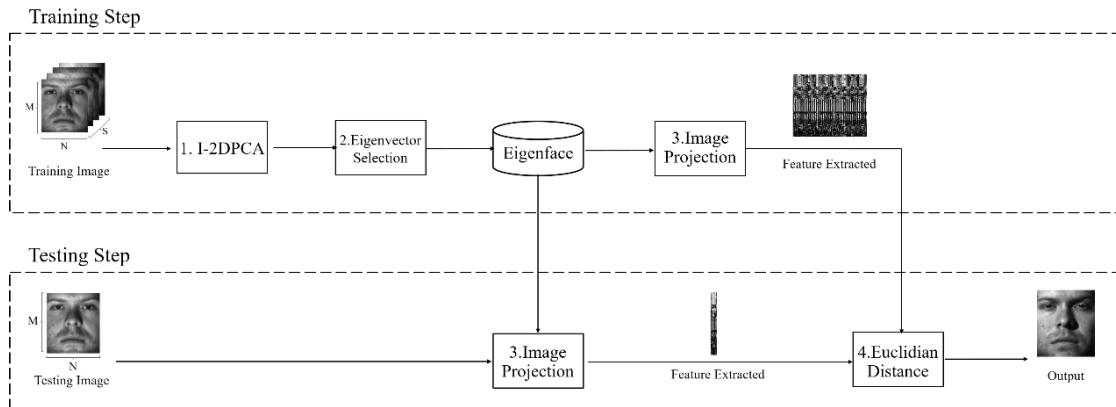
ภาพ 19 การแปลงภาพสีเป็นภาพระดับสีเทา

(ก) ภาพสี (ข) แปลงโดยใช้เทคนิค ELSSP และ (ค) แปลงโดยใช้เทคนิคการหาค่าเฉลี่ย

### 2.2.6 การวิเคราะห์องค์ประกอบหลัก 2 มิติ สำหรับการรู้จำใบหน้าภายใต้ผลกระทบจาก การส่องสว่างของแสง

Kuntpong Woraratpanya, et al. 2015 ได้นำเสนอการพัฒนาวิธีการ 2DPCA เพื่อแก้ผลกระทบจากการส่องสว่างของแสงในระบบบัญชีจำใบหน้า (2DPCA for Face Recognition under Illumination Effects: I-2DPCA) โดยได้พัฒนา 2 ส่วน ได้แก่ 1) แก้ไขการคำนวณเมทริกซ์ความแปรปรวนร่วม 2) เสนอแนวทางการเลือกไオเกนเวกเตอร์แบบใหม่ ทำให้ได้ผลลัพธ์ที่ดีขึ้นสำหรับการรู้จำภายใต้ผลกระทบจากการส่องสว่างของแสง

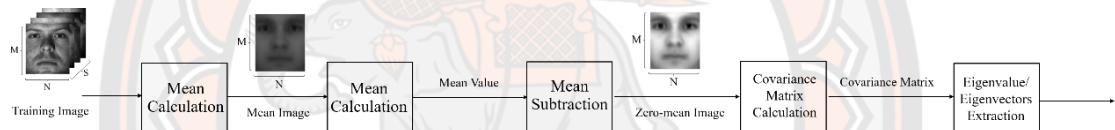
โดยกระบวนการทำงานการรู้จำใบหน้าด้วยวิธีการ I-2DPCA นี้ จะแบ่งการทำงานออกเป็น 2 กระบวนการหลัก คือ กระบวนการฝึกสอน และกระบวนการทดสอบ ดังภาพ 20



ภาพ 20 ขั้นตอนการทำงานของวิธีการ I-2DPCA สำหรับการรู้จำใบหน้า

### กระบวนการฝึกสอน

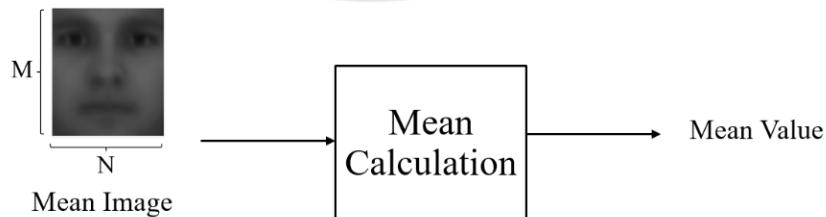
ขั้นตอนที่ 1 กระบวนการ I-2DPCA โดยการนำเข้าชุดรูปภาพฝึกสอน เพื่อผ่านขั้นตอนวิธี I-2DPCA ดังแสดงในภาพ 21 เพื่อสกัดคุณลักษณะเฉพาะของใบหน้าของแต่ละบุคคล



ภาพ 21 วิธีการสกัดไอกenen เวกเตอร์และค่าไอกenen ของวิธีการ I-2DPCA

1) การคำนวณค่าเฉลี่ย (Mean Calculation) สามารถคำนวณเช่นเดียวกับวิธีการ 2DPCA จากสมการที่ 8 และผลลัพธ์ที่ได้ คือ รูปภาพค่าเฉลี่ย ( $\bar{I}$ ) ขนาด  $M \times N$  พิกเซล ดังภาพ 13 ในบทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 1 ข้อที่ 1

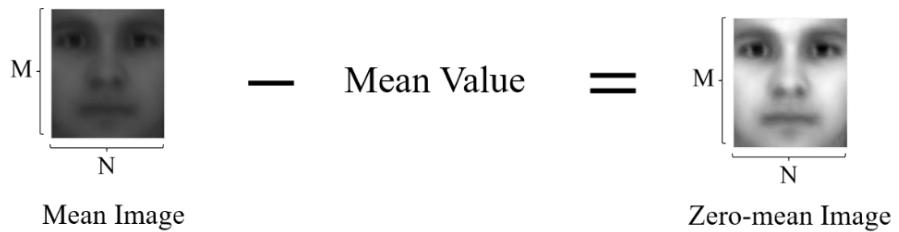
2) การคำนวณค่าเฉลี่ย (Mean Value Calculation) คือ การนำรูปภาพค่าเฉลี่ย ( $\bar{I}$ ) ไปคำนวณค่าเฉลี่ยอีกรังส์ และผลลัพธ์ที่ได้ คือ ค่าเฉลี่ยที่เป็นตัวเลข (Mean Value:  $\mathcal{E}$ ) ดังภาพ 22



ภาพ 22 ตัวอย่างผลลัพธ์ของการคำนวณค่าเฉลี่ยของวิธีการ I-2DPCA

3) การลบด้วยค่าเฉลี่ย (Mean Subtraction) คือ การนำรูปภาพค่าเฉลี่ย ( $\bar{I}_t$ ) ลบกับค่าเฉลี่ยที่เป็นตัวเลข ( $\mathcal{E}$ ) ดังสมการที่ 21 และผลลัพธ์ที่ได้เรียกว่า รูปภาพที่ปราศจากค่าเฉลี่ย ( $\Lambda$ ) ดังภาพ 23

$$\Lambda = \bar{I}_l - \varepsilon \quad (21)$$



ภาพ 23 ตัวอย่างผลลัพธ์ของการลบด้วยค่าเฉลี่ยของวิธีการ I-2DPCA

ช่วงการลบด้วยค่าเฉลี่ยแบบนี้ทำให้ได้ผลลัพธ์ที่ชัดเจนยิ่งขึ้นและนอกจากนี้ยังช่วยลดเวลาในการคำนวณ

4) คำนวณเมทริกซ์ความแปรปรวนร่วม (Covariance Matrix Calculation) คือ การนำรูปภาพที่ปราศจากค่าเฉลี่ย ( $\Lambda$ ) ไปคำนวณเมทริกซ์ความแปรปรวนร่วม ( $\psi$ ) สามารถคำนวณได้จากสมการที่ 10 ดังแสดงในบทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 1 ข้อที่ 4

5) การสกัดໄอเกนเวกเตอร์ และค่าໄอเกน (Eigenvector and Eigenvalue Extraction) คือ การนำเมทริกซ์ความแปรปรวนร่วมไปคำนวณหาໄอเกนเวกเตอร์ และค่าໄอเกน สามารถคำนวณได้จากสมการที่ 12 ดังแสดงในบทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 1 ข้อที่ 5

ขั้นตอนที่ 2 การเลือกจำนวนของໄอเกนเวกเตอร์ (Eigenvectors Selection) เลือกໄอเกนเวกเตอร์แบบช่วง โดยเลือกจากตัว  $m$  ถึง  $n$  เวกเตอร์  $\tilde{A} = \{a_m, a_{m+1}, a_{m+2}, \dots, a_n\}$  เมื่อ  $m$  และ  $n$  คือช่วงของໄอเกนเวกเตอร์ที่ต้องใช้ในการสร้างໄอเกนเฟส

ขั้นตอนที่ 3 มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงในบทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 3

#### กระบวนการทดสอบ

นำเข้ารูปภาพทดสอบ จากนั้นลบกับรูปภาพค่าเฉลี่ย ( $\bar{I}$ ) และทำการฉายภาพ (Image Projection) เช่นเดียวกับขั้นตอนที่ 3 ของกระบวนการฝึกสอน

ขั้นตอนที่ 4 มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงในบทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 4

จากการศึกษาวิธีการ PCA 2DPCA 2D<sup>2</sup>PCA Bi2DPCA และ I-2DPCA จะเห็นว่า ทุกวิธีการนั้นประสบความสำเร็จในการรักษาใบหน้า แต่มีเพียงวิธีการเดียว คือ วิธีการ I-2DPCA ที่ประสบความสำเร็จในการรักษาใบหน้าภายใต้ผลกระทบจากการส่องสว่างของแสงและลดเวลาในการคำนวณ เมื่อผู้จัยได้พิจารณาวิธีการ I-2DPCA จะเห็นว่ากระบวนการของวิธีการนี้สกัดໄอเกนเฟสที่ตอบโจทย์

สำหรับรูปภาพที่ได้รับผลกระทบจากการส่องสว่างของแสงทั้งรูปภาพ แต่ในความเป็นจริงผลกระทบจากการส่องสว่างของแสงในแต่ละภาพไม่เท่ากัน ทำให้โอลิเกนเฟสที่ได้รับส่งผลกระทบต่อรูปที่มีผลกระทบจากการส่องสว่างของแสง หากแก้ไขปัญหานี้ได้จะทำให้ได้ผลลัพธ์ที่ดียิ่งขึ้น



## บทที่ 3

### วิธีดำเนินงานวิจัย

ในบทนี้กล่าวถึงกระบวนการพัฒนาขั้นตอนการปรับปรุงวิธีการ 2DPCA ซึ่งจะเรียกว่า Modified 2DPCA สำหรับการรุ้งจำใบหน้า (M-2DPCA) ซึ่งได้จำแนกออกเป็น 2 รูปแบบ ได้แก่

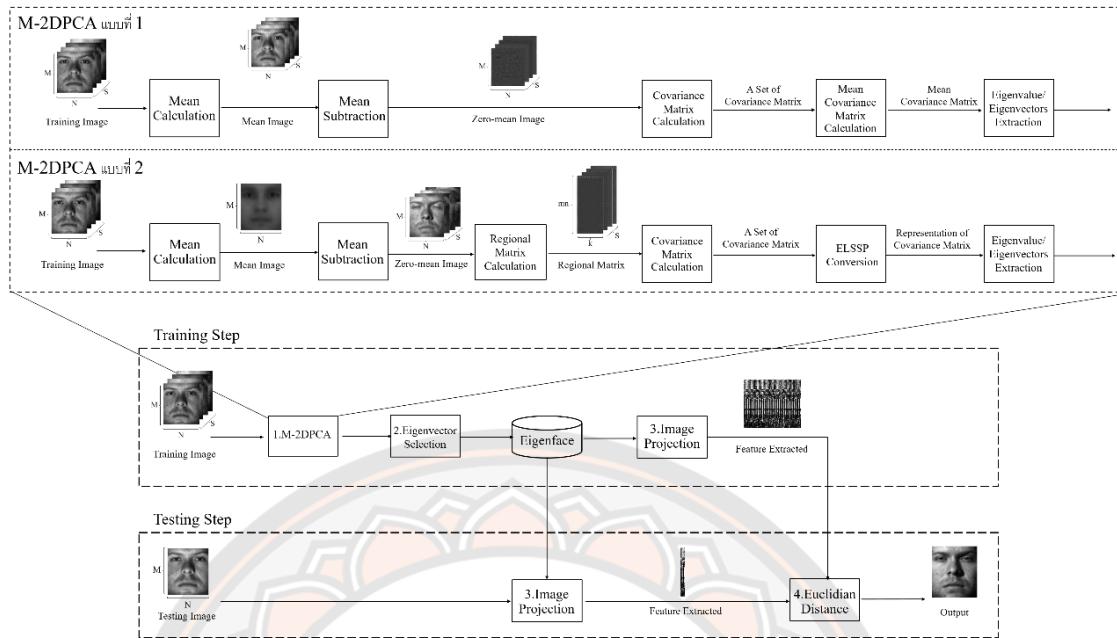
3.1 การพัฒนาวิธีการ M-2DPCA แบบที่ 1 (M1-2DPCA)

3.2 การพัฒนาวิธีการ M-2DPCA แบบที่ 2 (M2-2DPCA)

วิธีการ M-2DPCA แบบที่ 1 (M1-2DPCA) ได้นำเสนอในงานการประชุมวิชาการระดับนานาชาติ 2019 -16<sup>th</sup> International Joint Conference on Computer Science and Software Engineering (JCSSE2019) โดยใช้ชื่อว่า An Individual Local Mean-based 2DPCA for Face Recognition under Illumination Effects ( Hancherngchai, Titijaroonroj, & Rungrattanaubol, 2019)

และวิธีการ M-2DPCA แบบที่ 2 (M2-2DPCA) ได้นำเสนอในงานการประชุมวิชาการระดับนานาชาติ 2020 - 12<sup>th</sup> International Conference on Knowledge and Smart Technology (KST'2020) โดยใช้ชื่อว่า Regional Covariance Matrix-Based Two-Dimensional PCA for Face Recognition (Hancherngchai, Titijaroonroj, & Rungrattanaubol, 2020)

กระบวนการทำงานของวิธีการ M-2DPCA ประกอบด้วย 2 กระบวนการ คือ กระบวนการกระบวนการฝึกสอน และกระบวนการทดสอบ แสดงดังภาพ 24

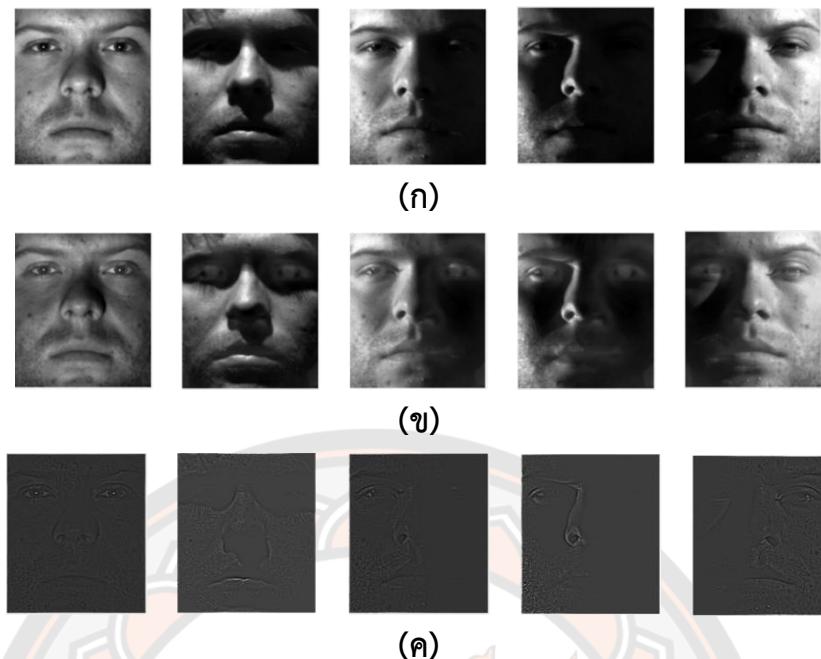


ภาพ 24 ขั้นตอนการทำงานของวิธีการ M-2DPCA สำหรับการรู้จำใบหน้า

ผู้จัดได้มุ่งเน้นไปที่การศึกษาและรวบรวมข้อมูลจากเอกสารและงานวิจัยที่เกี่ยวข้อง เพื่อพัฒนาวิธีการ M-2DPCA ให้มีประสิทธิภาพมากขึ้น โดยมุ่งเน้นไปที่การพัฒนาหาความสัมพันธ์ของเมทริกซ์ความแปรปรวนร่วม

### 3.1 การพัฒนาวิธีการ M-2DPCA แบบที่ 1 (M1-2DPCA)

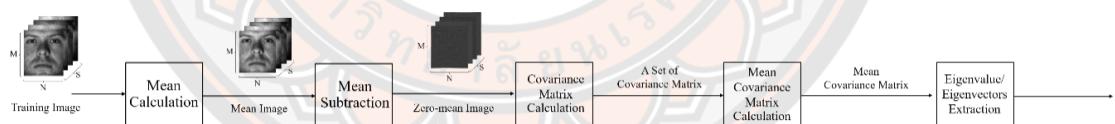
จากการศึกษางานวิจัยที่เกี่ยวข้องพบว่าวิธีการ 2DPCA แบบดั้งเดิมถูกพัฒนาเพื่อลดเวลาในการคำนวนและมุ่งเน้นไปที่ฐานข้อมูลทั่วไปที่ไม่มีแสงเงามาเกี่ยวข้อง เมื่อนำวิธีการ 2DPCA แบบดั้งเดิมมาทดลองกับฐานข้อมูลที่มีแสงเงามาเกี่ยวข้องจะทำให้มีความสามารถแก้ไขปัญหาผลกระทบจากการส่องสว่างของแสงได้ เนื่องจากรูปภาพค่าเฉลี่ยเพียงรูปเดียวไม่สามารถกำจัดแสงและเงาของรูปภาพได้ทุกรูปภาพ และดังภาพ 25 (ข) ผู้จัดจึงได้ทำการพัฒนาวิธีการ M-2DPCA แบบที่ 1 (M1-2DPCA) เพื่อแก้ไขปัญหานี้โดยเฉพาะ และดังภาพ 25 (ค) โดยอาศัยแนวคิดที่ว่า “ถ้าสามารถแก้ไขปัญหาผลกระทบจากการส่องสว่างของแสงในแต่ละรูปภาพได้ จะทำให้โครงข้อมูลใบหน้าในแต่ละรูปภาพที่ชัดเจนขึ้น และสามารถรู้จำใบหน้าได้อย่างมีประสิทธิภาพมากขึ้น” กระบวนการทำงานของวิธีการ M1-2DPCA สำหรับการรู้จำใบหน้ามีดังนี้



ภาพ 25 ตัวอย่างรูปภาพที่ปราศจากค่าเฉลี่ย  
 (ก) รูปภาพนำเข้า (ข) วิธีการ 2DPCA แบบดั้งเดิม (ค) วิธีการ M1-2DPCA

#### กระบวนการฝึกสอน

ขั้นตอนที่ 1 วิธีการ M-2DPCA แบบที่ 1 นำเข้ารูปภาพฝึกสอน จากนั้นใช้วิธีการ M1-2DPCA ดังภาพ 26 เพื่อสกัดคุณลักษณะเฉพาะของใบหน้าของแต่ละบุคคล



ภาพ 26 วิธีการสกัดໄອเกนเวกเตอร์และค่าໄอเกนของวิธีการ M-2DPCA แบบที่ 1

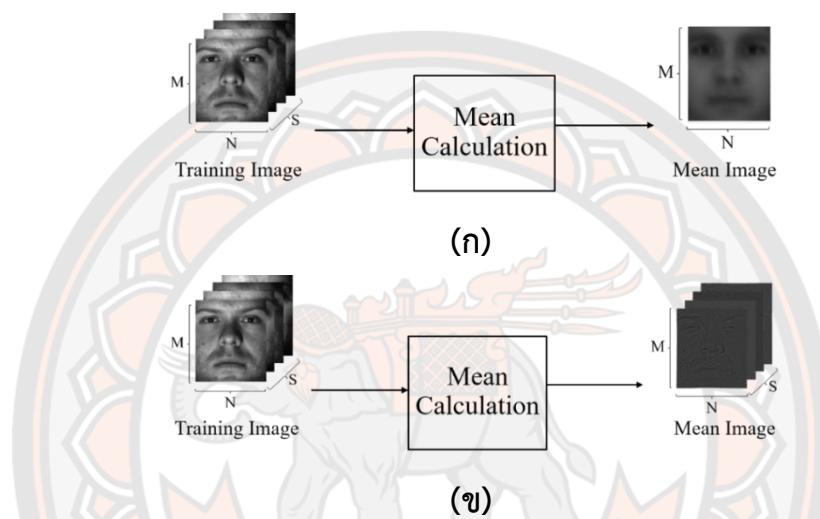
1) การคำนวณค่าเฉลี่ย โดยที่รูปภาพนำเข้าต้องเป็นภาพระดับสีเทา ซึ่งวิธีการ 2DPCA แบบดั้งเดิมนั้นได้คำนวณค่าเฉลี่ยโดยใช้รูปภาพทั้งหมด ดังสมการที่ 8 ในหัวข้อที่ 2.2.2 และผลลัพธ์ที่ได้แสดงดังภาพ 27 (ก) แต่การคำนวณแบบนี้ไม่สามารถแก้ไขปัญหาผลกระทบจากการส่องสว่างของแสงได้ เนื่องจากรูปภาพค่าเฉลี่ยเพียงรูปเดียวไม่สามารถกำจัดแสงและเงาของรูปภาพได้ทุกรูปภาพ ผู้วิจัยจึงได้พัฒนาวิธีการ M1-2DPCA ที่มีการคำนวณค่าเฉลี่ยภายในรูปภาพแต่ละรูป เรียกว่าการหาค่าเฉลี่ยแบบเฉพาะถิ่น (Individual Local Mean) เพื่อให้มีรูปภาพค่าเฉลี่ยของรูปภาพนั้นโดยเฉพาะ สามารถคำนวณได้ จากสมการที่ 22 และผลลัพธ์ที่ได้ คือ รูปภาพของค่าเฉลี่ยของแต่ละรูปภาพ หรือเรียกว่า รูปภาพค่าเฉลี่ย ( $\bar{I}_i$ ) แสดงดังภาพ 27 (ข)

$$\bar{I}_i(m, n) = \frac{1}{(2w+1)^2} \sum_{u=m-w}^{m+w} \sum_{v=n-w}^{n+w} I_i(u, v) \quad (22)$$

เมื่อ  $I_i$  คือ รูปภาพฝึกสอนที่มีขนาด  $M \times N$  พิกเซล

$w$  คือ ขนาดของตัวกรอง

$S$  คือ จำนวนรูปภาพฝึกสอน

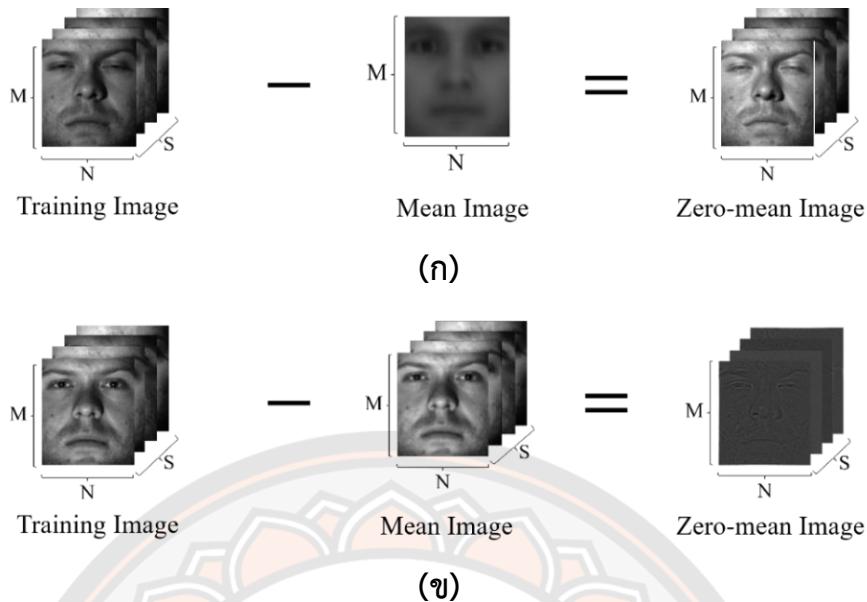


ภาพ 27 ตัวอย่างผลลัพธ์ของการคำนวณค่าเฉลี่ย

(ก) วิธีการ 2DPCA แบบดั้งเดิม (ข) วิธีการ M1-2DPCA

2) การลบด้วยค่าเฉลี่ย คือ การนำรูปภาพฝึกสอน ( $I_i$ ) แต่ละรูปภาพมาลบกับ รูปภาพของค่าเฉลี่ยของแต่ละรูปภาพ ( $\bar{I}_i$ ) ดังสมการที่ 23 และผลลัพธ์ คือ รูปภาพที่ปราศจากค่าเฉลี่ย ( $\Lambda_i$ ) ดังภาพ 28 (ๆ)

$$\Lambda_i = I_i - \bar{I}_i \quad (23)$$



ภาพ 28 ตัวอย่างผลลัพธ์ของการลบด้วยค่าเฉลี่ย

(ก) วิธีการ 2DPCA แบบดั้งเดิม (ข) วิธีการ M1-2DPCA

ซึ่งการคำนวณหาค่าเฉลี่ยแบบเฉพาะถิ่นในที่นี้ทำให้สามารถลบแสงเงาออกจากรูปภาพได้ และนอกจากรูปภาพแล้วยังลบเนื้อสือจากรูปภาพอีกด้วย ผลลัพธ์ที่ได้เปรียบเสมือนการดึงเส้น (edge) ออกจากรูปภาพ หรือ เหลือเฉพาะโครงหน้า

เมื่อเปรียบเทียบรูปภาพที่ปราศจากค่าเฉลี่ย ของวิธีการ 2DPCA แบบดั้งเดิมและวิธีการ M-2DPCA แบบที่ 1 จะเห็นว่ารูปภาพที่ปราศจากค่าเฉลี่ยของวิธีการ 2DPCA แบบดั้งเดิมนั้นสามารถกำจัดแสงและเงาออกจากภาพบางส่วนเท่านั้นได้ เนื่องจากรูปภาพค่าเฉลี่ยเพียงรูปเดียวไม่สามารถกำจัดแสงและเงาของรูปภาพได้ทุกรูปภาพ ในขณะที่วิธีการ M-2DPCA แบบที่ 1 นั้นสามารถกำจัดได้จนเหลือเพียงโครงของใบหน้า เพราะมีรูปภาพค่าเฉลี่ยของรูปภาพนั้นโดยเฉพาะ

ขั้นตอนต่อจากนี้มีวิธีการทำงานแบบเดียวกับวิธีการ 2DPCA ดังแสดงในบทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 1 ข้อที่ 3 ถึง ข้อที่ 5

**ขั้นตอนที่ 2** มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงใน บทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 2

**ขั้นตอนที่ 3** มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงใน บทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 3

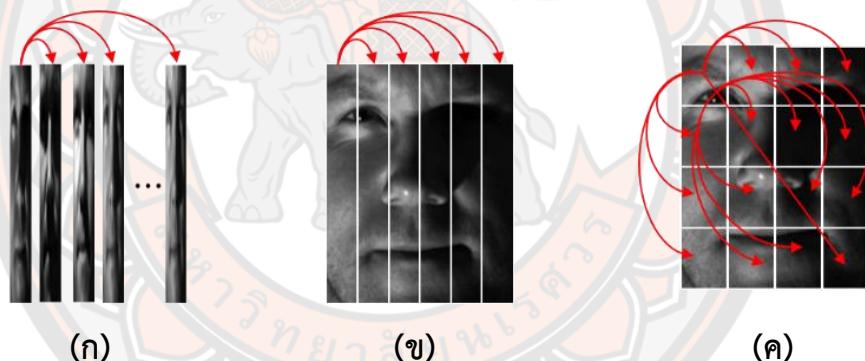
### กระบวนการทดสอบ

นำเข้ารูปภาพทดสอบ จากนั้นลบกับรูปภาพค่าเฉลี่ย ( $\bar{I}$ ) และทำการฉายภาพ (Image Projection) เช่นเดียวกับขั้นตอนที่ 3 ของกระบวนการฝึกสอน

ขั้นตอนที่ 4 มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงใน บทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 4

### 3.2 การพัฒนาวิธีการ M-2DPCA แบบที่ 2 (M2-2DPCA)

ผู้วิจัยได้พัฒนาวิธีการ M-2DPCA แบบที่ 2 (M2-2DPCA) สำหรับการรักษาใบหน้า เพื่อตอบโจทย์ที่หลักหลายทั้งภาพทั่วไปและรวมไปถึงปัญหาของผลกระทบจากการส่องสว่างของแสง โดยมีแนวคิดว่า “ถ้าสามารถคำนวนหาความสัมพันธ์ที่ดีในเมทริกซ์ความแปรปรวนร่วมได้ จะนำไปสู่โภเกนเฟสที่ดี และเมื่อได้โภเกนเฟสที่ดี ผลลัพธ์ที่ได้ก็จะมีประสิทธิภาพที่ดีเช่นกัน” ตัวอย่างเช่น วิธีการ PCA หากความสัมพันธ์ระหว่างรูปภาพในรูปแบบเวกเตอร์ ดังภาพ 29 (ก) วิธีการ 2DPCA หากความสัมพันธ์ภายในรูปภาพแบบทิศทางเดียว (แนวหรือหลัก) ดังภาพ 29 (ข) วิธีการ 2D<sup>2</sup>PCA และวิธีการ Bi2DPCA ก็หากความสัมพันธ์ภายในรูปภาพเช่นเดียวกับวิธีการ 2DPCA แต่ได้คำนวนหาความสัมพันธ์ 2 ครั้ง แนว และหลัก จึงเรียกว่าการหาความสัมพันธ์แบบ 2 ทิศทาง ส่วนวิธีการ M-2DPCA แบบที่ 2 เสนอการหาความสัมพันธ์ 2 ทิศทางทั้งแนว และหลักโดยคำนวนเพียง 1 ครั้ง แสดงดังภาพ 29 (ค)

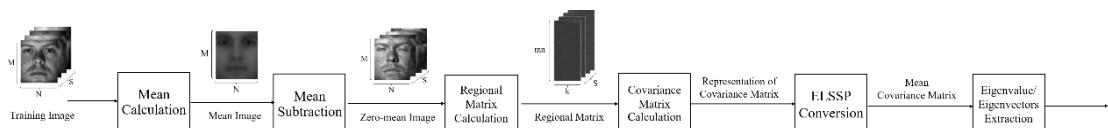


ภาพ 29 ตัวอย่างการหาความสัมพันธ์

(ก) วิธีการ PCA (ข) วิธีการ 2DPCA และ (ค) วิธีการ M-2DPCA แบบที่ 2

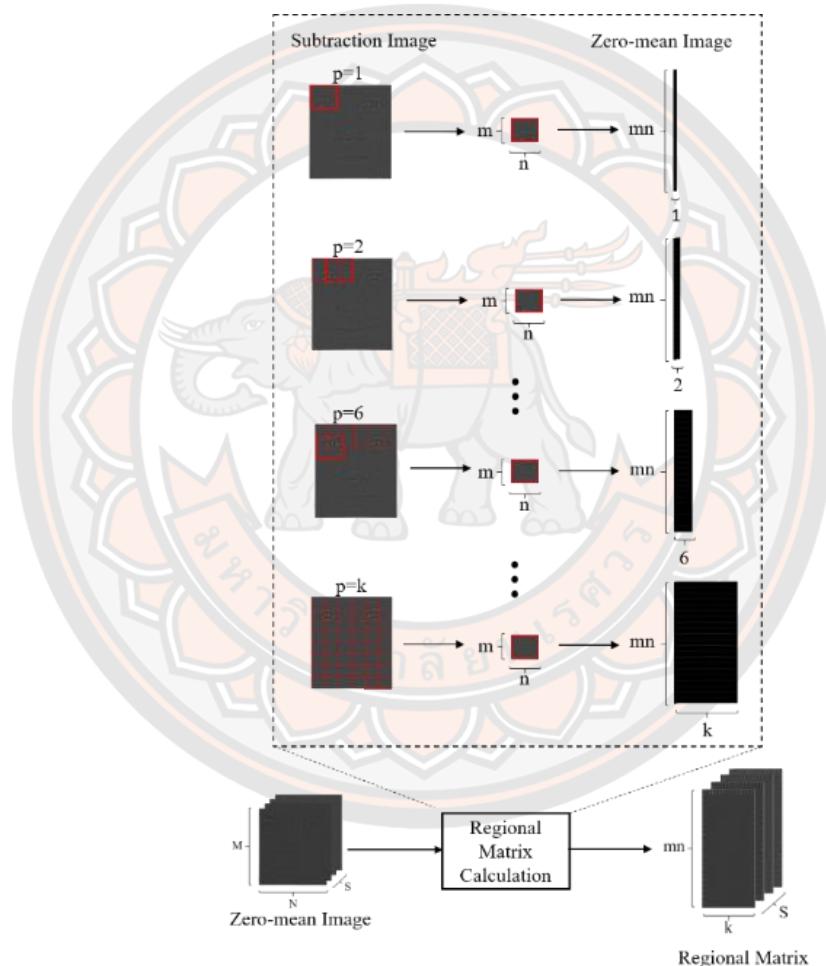
### กระบวนการฝึกสอน

ขั้นตอนที่ 1 วิธีการ M-2DPCA แบบที่ 2 นำเข้ารูปภาพฝึกสอนจากนั้นใช้วิธีการ M2-2DPCA ดังภาพ 30 เพื่อสกัดคุณลักษณะเฉพาะของใบหน้าของแต่ละบุคคล



ภาพ 30 วิธีการสกัดโภเกนเวกเตอร์และค่าโภเกนของวิธีการ M-2DPCA แบบที่ 2

- 1) การคำนวณค่าเฉลี่ย สามารถคำนวณเข่นเดียวกับวิธีการ 2DPCA จากสมการที่ 8 และผลลัพธ์ที่ได้รูปภาพค่าเฉลี่ย ( $\bar{I}$ ) ดังภาพ 13 ในบทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 1 ข้อที่ 1
- 2) การลบด้วยค่าเฉลี่ย คือ การนำข้อมูลรูปภาพมาลบกับรูปภาพค่าเฉลี่ย ( $\bar{I}$ ) สามารถคำนวณได้จากสมการที่ 9 และผลลัพธ์ที่ คือ รูปภาพที่ปราศจากค่าเฉลี่ย ( $\Lambda_i$ ) ดังภาพ 14 ในบทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 1 ข้อที่ 2
- 3) การคำนวณเมทริกซ์ระดับภูมิภาค (Regional Matrix Calculation) คือการแปลงรูปภาพที่ปราศจากค่าเฉลี่ย ( $\Lambda_i$ ) แต่ละตำแหน่งในรูปภาพให้อยู่ในรูปของเวกเตอร์ ดังภาพ 31



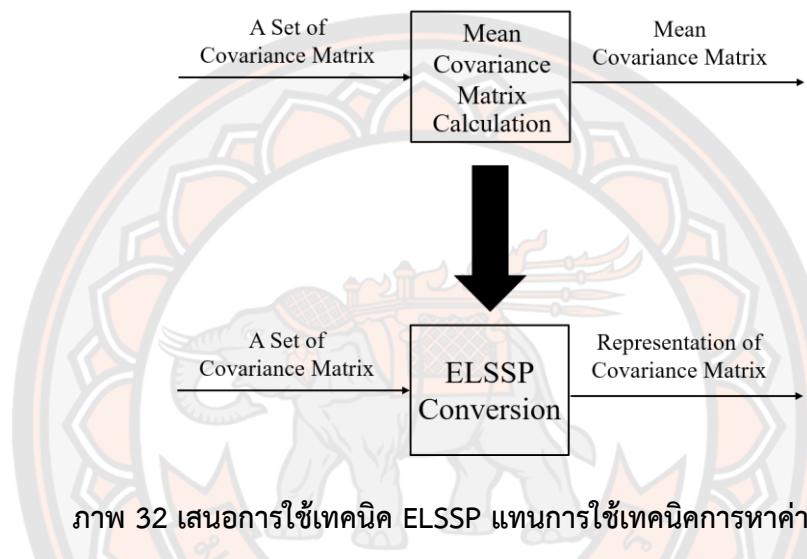
ภาพ 31 การคำนวณเมทริกซ์ระดับภูมิภาค

จากรูปภาพ 31 กำหนดให้  $p$  คือส่วนของรูปภาพขนาด  $m \times n$  และ  $k$  คือ จำนวนของส่วนของรูปภาพทั้งหมด

- 4) การคำนวณเมทริกซ์ความแปรปรวนร่วม (Covariance Matrix Calculation) คือ เมทริกซ์ระดับภูมิภาค ( $\Lambda_i$ ) ขนาด  $mn \times k$  ไปคำนวณหาเมทริกซ์ความแปรปรวนร่วมซึ่งสามารถ

คำนวณได้ดังสมการที่ 10 และผลลัพธ์ที่ได้ คือ ชุดของเมทริกซ์ความแปรปรวนร่วม ( $\psi_i$ ) ดังแสดงในบทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 1 ข้อที่ 4

5) การหาตัวแทนของเมทริกซ์ความแปรปรวนร่วมโดยใช้เทคนิค ELSSP (ELSSP Conversion:  $\psi_{rep}$ ) แทนการใช้เทคนิคการหาค่าเฉลี่ย (Seo & Kim, 2013) เนื่องจากเทคนิคค่าเฉลี่ยนั้นอาจทำให้เกิดการสูญเสียข้อมูลบางส่วนที่สำคัญได้ ดังนั้นผู้วิจัยจึงเสนอการใช้เทคนิค ELSSP แทนการใช้เทคนิคการหาค่าเฉลี่ยแบบดั้งเดิม ดังภาพ 32 การใช้เทคนิค ELSSP ประกอบด้วย 7 ขั้นตอนดังนี้



ภาพ 32 เสนอการใช้เทคนิค ELSSP แทนการใช้เทคนิคการหาค่าเฉลี่ย

ขั้นตอนที่ 1 แปลงเมทริกซ์ความแปรปรวนร่วม ( $\psi_i$ ) ให้อยู่ในรูปแบบของเวกเตอร์หรือเรียกว่า เวกเตอร์ความแปรปรวนร่วม ( $v_i$ ) ดังแสดงในหัวข้อที่ 2.2.1

ขั้นตอนที่ 2 คำนวณหาค่าเฉลี่ย ( $\bar{v}$ ) จากเวกเตอร์ความแปรปรวนร่วม จากสมการที่ 1 ดังแสดงในหัวข้อที่ 2.2.1

ขั้นตอนที่ 3 การลับด้วยค่าเฉลี่ย ( $\tilde{v}_i$ ) นำเวกเตอร์ความแปรปรวนร่วมแต่ละตัวลบกับค่าเฉลี่ยเวกเตอร์ จากสมการที่ 2 ดังแสดงในหัวข้อที่ 2.2.1 ผลลัพธ์ที่ได้เรียกว่า เชตของเวกเตอร์ความแปรปรวนร่วมที่ปราศจากค่าเฉลี่ย (Zero-mean covariance vectors:  $\tilde{V}$ ) ดังสมการที่

$$\tilde{V} = [\tilde{v}_1, \tilde{v}_2, \tilde{v}_3, \dots, \tilde{v}_S] \quad (24)$$

ขั้นตอนที่ 4 คำนวณเมทริกซ์ความแปรปรวนร่วม ( $\psi_{ELSSP}$ ) ของเชตของเวกเตอร์ความแปรปรวนร่วมที่ปราศจากค่าเฉลี่ย จากสมการที่ 3 และ 4 ดังแสดงในบทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 4

ขั้นตอนที่ 5 การสกัดไอโgenเวกเตอร์ ( $A_{ELSSP}$ ) และค่าไอโgen ( $U_{ELSSP}$ ) สามารถคำนวณได้จากสมการที่ 5 ดังแสดงในบทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 5

ขั้นตอนที่ 6 สร้างรูปภาพเวกเตอร์ ( $X$ ) จากไอโgenเวกเตอร์ และค่าไอโgen ดังสมการที่ 25

$$X = U_{ELSSP} \times (A_{ELSSP}^T \times \tilde{V}^T) \quad (25)$$

รูปภาพเวกเตอร์ ( $X$ ) สามารถเขียนได้ดังสมการที่ 26

$$X = [\vec{x}_1, \vec{x}_2, \vec{x}_3, \dots, \vec{x}_S] \quad (26)$$

ขั้นตอนที่ 7 คำนวณหาตัวแหนงของเมทริกซ์ความแปรปรวนร่วม ( $\psi_{rep}$ ) โดยการปรับขนาดของ  $X$  จาก  $kk \times 1$  เป็น  $k \times k$  ดังสมการที่ 27

$$\psi_{rep} = f_{resize}(X) \quad (27)$$

6. การสกัดไอโgenเวกเตอร์ และค่าไอโgen (Eigenvector and Eigenvalue Extraction) คือการนำค่าเฉลี่ยของเมทริกซ์ความแปรปรวนร่วมไปคำนวณหาไอโgenเวกเตอร์ และค่าไอโgen ดังสมการที่ 28

$$AV = V\psi_{rep} \quad (28)$$

ขั้นตอนที่ 2 มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงใน บทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 2

ขั้นตอนที่ 3 มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงใน บทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 3

#### กระบวนการทดสอบ

นำเข้ารูปภาพทดสอบ จากนั้นลบกับรูปภาพค่าเฉลี่ย ( $\bar{I}$ ) และทำการฉายภาพ (Image Projection) เช่นเดียวกับขั้นตอนที่ 3 ของกระบวนการฝึกสอน

ขั้นตอนที่ 4 มีวิธีการทำงานแบบเดียวกับวิธีการ PCA ดังแสดงใน บทที่ 2 หัวข้อที่ 2.2.1 ขั้นตอนที่ 4

### 3.3 เครื่องมือที่ใช้ในงานวิจัย

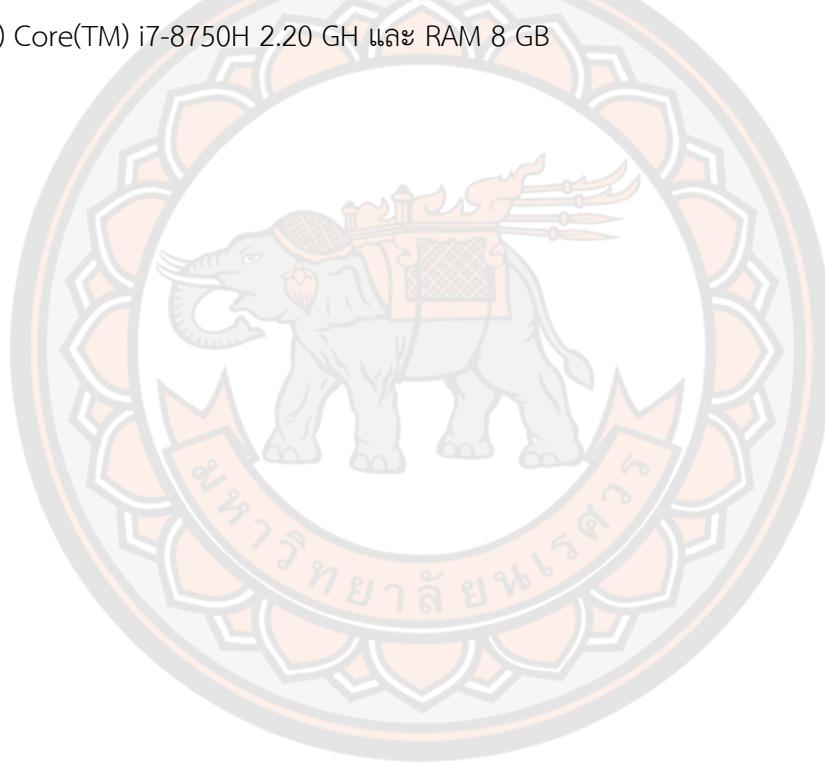
ผู้วิจัยได้ทำการวัดประสิทธิภาพ โดยใช้วิธีการคำนวณหาค่าความถูกต้อง ดังสมการที่ 29

$$\text{Accuracy rate} = \frac{Nc}{Nt} \times 100 \quad (29)$$

เมื่อ  $Nc$  คือ จำนวนรูปภาพที่รู้จำได้ถูกต้อง

$Nt$  คือ จำนวนรูปภาพที่ถูกทดสอบ

และทำการทดสอบโดยใช้ 10-fold cross validation เพื่อหลีกเลี่ยงปัญหา overfitting โดย รูปภาพทั้งหมดจะถูกสุ่มแบ่งกลุ่มทั้งหมด 10 กลุ่ม 9 กลุ่มสำหรับกระบวนการฝึกสอน และ 1 กลุ่ม สำหรับกระบวนการทดสอบ โดยประมาณผลผ่านโปรแกรม MATLAB R2018a ทำงานบน MSI Intel(R) Core(TM) i7-8750H 2.20 GH และ RAM 8 GB



## บทที่ 4

### ผลการวิจัย

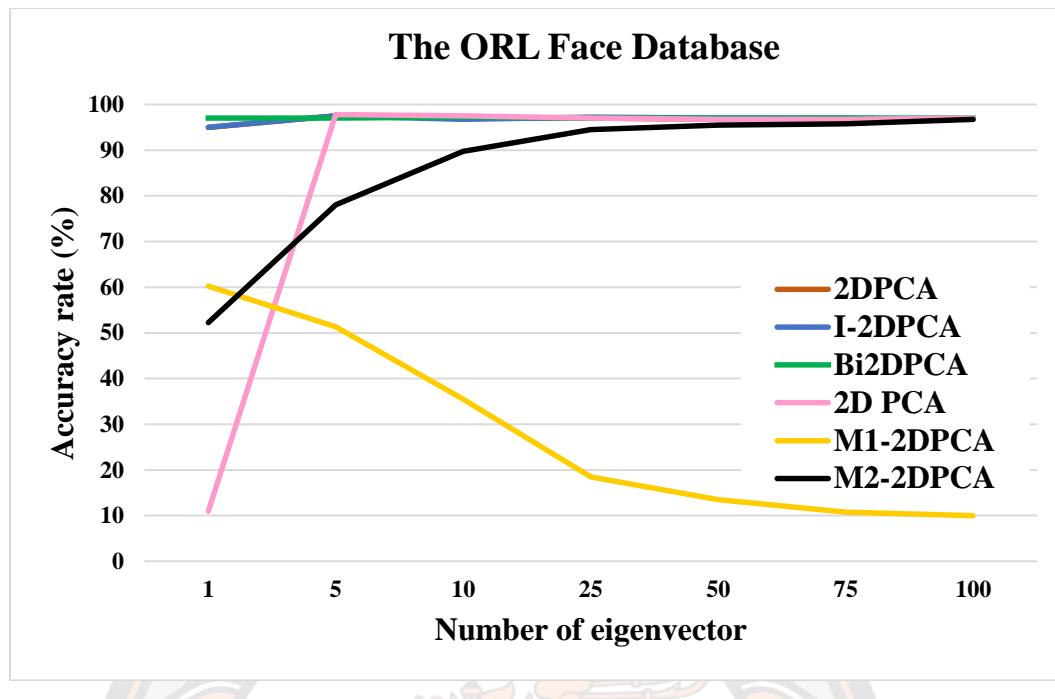
ในงานวิจัยได้พัฒนาวิธีการ M-2DPCA สำหรับการรูปจำใบหน้า แบ่งออกเป็น 3 หัวข้อดังนี้

- 4.1 การวัดประสิทธิภาพของจำนวนไอกenen เวกเตอร์ที่ใช้งาน
- 4.2 การวัดประสิทธิภาพของการรูปจำใบหน้า
- 4.3 การวัดประสิทธิภาพของเวลาที่ใช้ในการประมวลผล

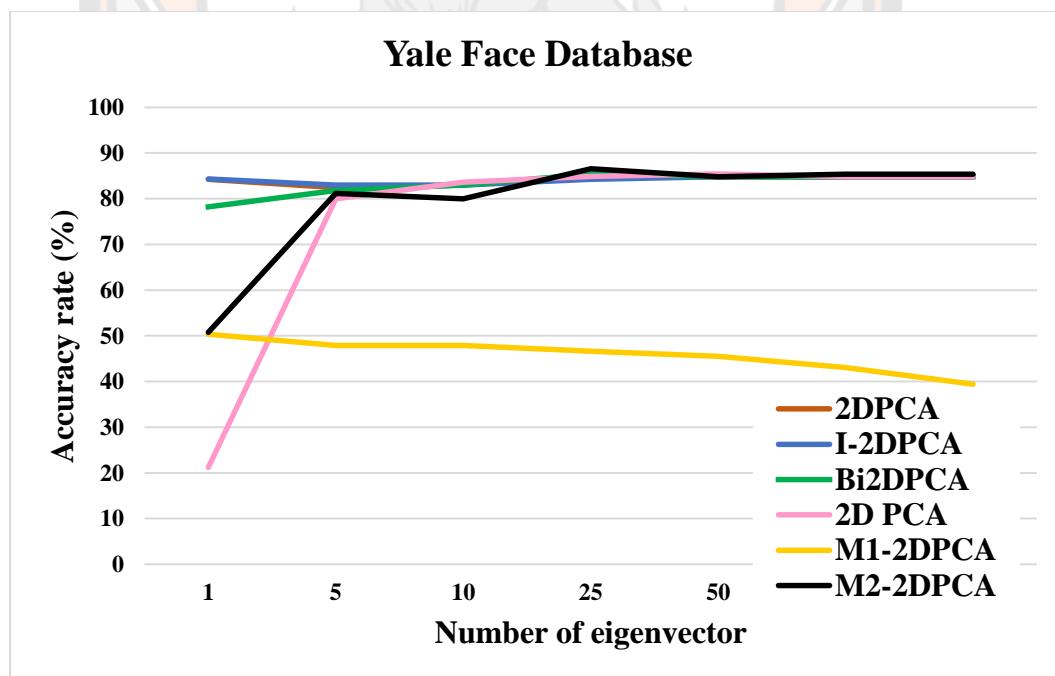
#### 4.1 การวัดประสิทธิภาพของจำนวนไอกenen เวกเตอร์ที่ใช้งาน

จำนวนไอกenen เวกเตอร์เป็นหนึ่งในพารามิเตอร์ที่สำคัญที่ส่งผลต่อประสิทธิภาพของการรูปจำใบหน้า โดยใช้ PCA ซึ่งแต่ละฐานข้อมูลจะมีพฤติกรรมการใช้ไอกenen เวกเตอร์ที่เหมาะสมแตกต่างกัน เพื่อจะหาจำนวนไอกenen เวกเตอร์ที่เหมาะสมของแต่ละฐานข้อมูลผู้วิจัยจึงจัดทำการทดลอง โดยปรับค่าพารามิเตอร์ของ วิธีการ M-2DPCA แบบที่ 1 (M1-2DPCA) M-2DPCA แบบที่ 2 (M2-2DPCA) วิธีการ 2DPCA แบบดั้งเดิม วิธีการ 2D<sup>2</sup>PCA วิธีการ Bi2DPCA และ วิธีการ I-2DPCA

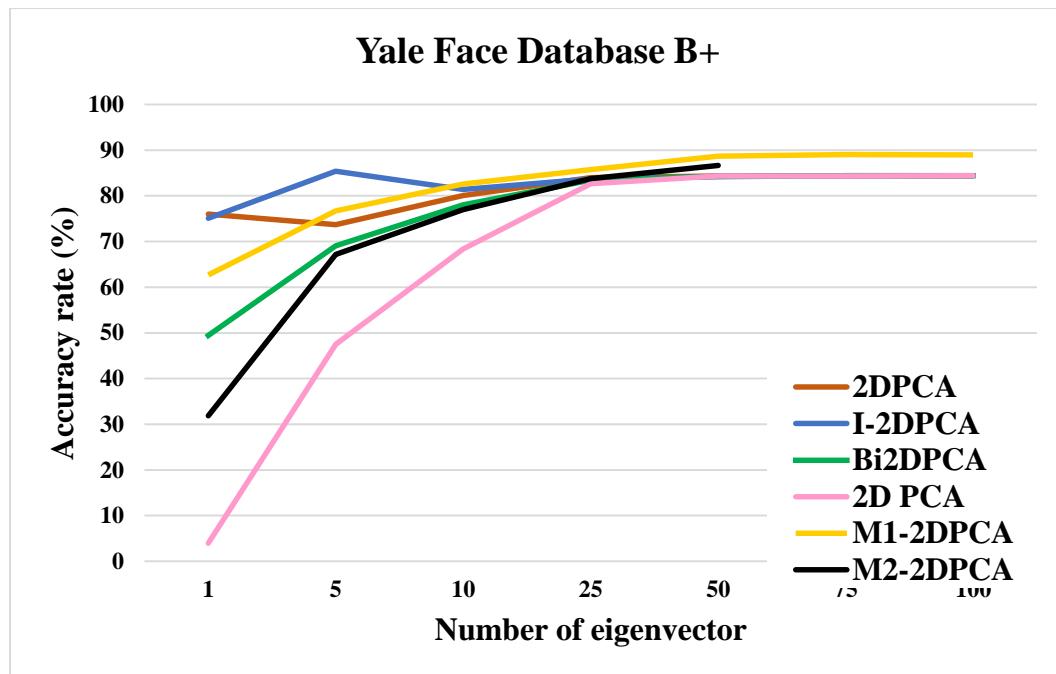
การเปรียบเทียบจำนวนไอกenen เวกเตอร์ที่ใช้กับประสิทธิภาพของการรูปจำใบหน้า แสดงดังภาพ 33-35 โดยเลือกจำนวนไอกenen เวกเตอร์ตัวที่ 1 ถึงตัวที่  $p$ ,  $\tilde{A} = \{a_1, a_2, \dots, a_p\}$ , เมื่อ  $p$  คือจำนวนของไอกenen เวกเตอร์ที่ต้องใช้ในการสร้างไอกenen เฟส และ  $\tilde{A}$  คือ เซตของไอกenen เวกเตอร์ที่เลือก โดยที่ค่า  $p$  ที่เหมาะสมจะถูกพิจารณาจากการทดลองโดยเริ่มจากเลือกไอกenen เวกเตอร์ตัวที่ 1 จากนั้นจะพิจารณาค่าความถูกต้องและเพิ่มค่า  $p$  ทีละ 1 สุดท้ายจะเลือกค่า  $p$  ที่มีค่าความถูกต้องที่สุด



ภาพ 33 กราฟแสดงค่าความถูกต้องของแต่ละวิธีการเมื่อเปรียบเทียบกับจำนวนไอกเนนเฟสที่ใช้ในฐานข้อมูล The ORL Face Database



ภาพ 34 กราฟแสดงค่าความถูกต้องของแต่ละวิธีการเมื่อเปรียบเทียบกับจำนวนไอกเนนเฟสที่ใช้ในฐานข้อมูล Yale Face Database



ภาพ 35 กราฟแสดงค่าความถูกต้องของแต่ละวิธีการเมื่อเปรียบเทียบกับจำนวนไอกenenเฟสที่ใช้ในฐานข้อมูล Yale Face Database B+

จากการ 33-35 โดยที่ภาพ 33 สำหรับฐานข้อมูล ORL Face ภาพ 34 สำหรับฐานข้อมูล Yale Face Database ภาพ 35 สำหรับฐานข้อมูล Yale Face Database B+ จะเห็นว่าการเลือกใช้ไอกenen เวกเตอร์ประมาณ 1-25 ตัว จะส่งผลให้ค่าความถูกต้องมีความเปลี่ยนแปลงค่อนข้างมาก แต่เมื่อเลือกใช้ไอกenen เวกเตอร์ประมาณ 50-100 ตัว ค่าความถูกต้องมีความเปลี่ยนแปลงค่อนข้างน้อย ซึ่งการเปลี่ยนแปลงค่าความถูกต้องจะมากขึ้นหรือลดลงก็ขึ้นอยู่กับการทำงานของแต่ละวิธีการ เพราะฉะนั้นเพื่อความสมอเท่าเทียมของทุก ๆ วิธีการจึงทำการเลือกไอกenen เวกเตอร์ที่ให้ค่าความถูกต้องสูงที่สุดของแต่ละวิธีการ

ผลการทดลองหาจำนวนไอกenen เวกเตอร์ที่เหมาะสมของแต่ละฐานข้อมูล แสดงดังตาราง 3 และผลการทดลองวัดประสิทธิภาพของจำนวนไอกenen เวกเตอร์ที่เหมาะสมของแต่ละฐานข้อมูล เปรียบเทียบกับค่าความถูกต้อง แสดงดังตาราง 4 โดยใช้วิธีการ M-2DPCA แบบที่ 1 (M1-2DPCA) วิธีการ M-2DPCA แบบที่ 2 (M2-2DPCA) วิธีการ 2DPCA แบบตั้งเดิม วิธีการ 2D<sup>2</sup>PCA วิธีการ Bi2DPCA และ วิธีการ I-2DPCA

ตาราง 2 แสดงผลการทดลองของจำนวนไอกเนกเตอร์ที่เหมาะสมของแต่ละฐานข้อมูล

Method	Number of eigenvectors			
	ORL Face	Yale Face	Yale Face B+	Average $\pm$ S.D.
2DPCA	5	25	75	35 $\pm$ 36.06
2D <sup>2</sup> PCA	5	50	100	52 $\pm$ 47.52
Bi2DPCA	10	25	75	37 $\pm$ 34.03
I-2DPCA	5	50	5	<b>20 + 25.98</b>
M1-2DPCA	<b>1</b>	<b>1</b>	75	26 $\pm$ 42.72
M2-2DPCA	105	25	50	60 $\pm$ 40.93

จะเห็นว่าวิธีการ M1-2DPCA ใช้จำนวนไอกเนกเตอร์น้อยที่สุดในฐานข้อมูลของ ORL Face และ Yale Face ใช้ไอกเนกเตอร์จำนวน 1 ตัว ในขณะที่วิธีการ I-2DPCA ใช้จำนวนไอกเนกเตอร์น้อยที่สุดในฐานข้อมูล Yale Face B+ ใช้ไอกเนกเตอร์จำนวน 5 ตัว และเมื่อพิจารณาภาพรวมของทั้ง 3 ฐานข้อมูลจะเห็นว่าวิธีการ M1-2DPCA และวิธีการ M2-2DPCA นั้นมีข้อจำกัดในการเลือกใช้จำนวนไอกเนกเตอร์ วิธีการ M1-2DPCA ใช้จำนวนไอกเนกเตอร์ประมาณ 26 ตัว ซึ่งมากกว่าวิธีการ I-2DPCA ที่มีภาพรวมการเลือกใช้ไอกเนกเตอร์ดีที่สุดประมาณ 6 ตัว และวิธีการ M2-2DPCA ใช้จำนวนไอกเนกเตอร์ประมาณ 60 ตัว ซึ่งค่อนข้างมากกว่าวิธีการอื่นๆ ในขณะที่วิธีการ I-2DPCA ใช้จำนวนไอกเนกเตอร์ค่อนข้างน้อยและมีความแปรปรวนน้อยที่สุดประมาณ 25.98 เนื่องจากวิธีการ I-2DPCA นั้นมีการเลือกจำนวนไอกเนกเตอร์เป็นช่วง ๆ ทำให้มีการใช้ไอกเนกเตอร์น้อยกว่าวิธีการอื่น ๆ ที่เลือกไอกเนกเตอร์ตั้งตัวที่ 1 ถึงจำนวนที่ต้องการ

ตาราง 3 แสดงผลการทดลองของจำนวนไอกเนกเตอร์ที่เหมาะสมของแต่ละฐานข้อมูล  
เปรียบเทียบกับค่าความถูกต้อง

Method	Number of eigenvectors (Accuracy rate (%))			
	ORL Face	Yale Face	Yale Face B+	Average $\pm$ S.D.
2DPCA	5.00 (97.50)	25.00 (84.82)	75.00 (84.43)	35.00 (88.92) $\pm$ 36.06
2D <sup>2</sup> PCA	5.00 (97.75)	50.00 (85.44)	100.00 (84.43)	51.67 (89.21) $\pm$ 47.52
Bi2DPCA	10.00 (97.25)	25.00 (85.44)	75.00 (84.43)	36.67 (89.04) $\pm$ 34.03
I-2DPCA	5.00 (97.50)	50.00 (84.82)	5.00 (85.35)	20.00 (89.22) $\pm$ 25.98
M1-2DPCA	1.00 (60.25)	1.00 (50.37)	75.00 (89.03)	25.67 (66.55) $\pm$ 42.72
M2-2DPCA	105.00 (97.00)	25.00 (86.56)	50.00 (86.62)	60.00 (90.06) $\pm$ 40.93

จากตาราง 4 การเปรียบเทียบจำนวนไอกเนกเตอร์ที่ใช้กับประสิทธิภาพของการรู้จำใบหน้าจะเห็นว่าในฐานข้อมูล ORL Face และฐานข้อมูล Yale face วิธีการ M1-2DPCA ใช้ไอกเนกเตอร์เพียง 1 ตัว ซึ่งใช้จำนวนไอกเนกเตอร์น้อยที่สุด และค่าความถูกต้องน้อยที่สุดเช่นกัน ส่วนฐานข้อมูล ORL Face B+ วิธีการที่ใช้จำนวนไอกเนกเตอร์น้อยที่สุด คือ วิธีการ I-2DPCA ใช้จำนวนไอกเนกเตอร์ 5 ตัว ให้ค่าความถูกต้องประมาณ 85.35%

หากพิจารณา ในฐานข้อมูล ORL Face วิธีการที่ใช้จำนวนไอกเนกเตอร์น้อยที่สุดคือวิธีการ M1-2DPCA ถึงแม้ว่าวิธีการ M1-2DPCA จะใช้จำนวนไอกเนกเตอร์น้อยที่สุดแต่มีประสิทธิภาพที่น้อยที่สุดเช่นกัน ในขณะที่วิธีการ 2PCA 2D<sup>2</sup>PCA และ I-2DPCA ใช้จำนวนไอกเนกเตอร์มากกว่าวิธีการ M1-2DPCA 4 ตัวแต่ได้ผลลัพธ์ที่ดีกว่า และวิธีการที่ใช้จำนวนไอกเนกเตอร์ที่มากที่สุดคือวิธีการ M2-2DPCA แต่ค่าความถูกต้องยังคงสูงกว่าวิธีการ M1-2DPCA ที่ใช้จำนวนไอกเนกเตอร์น้อยที่สุด ในทำนองเดียวกันกับฐานข้อมูล Yale Face วิธีการ M1-2DPCA จะใช้จำนวนไอกเนกเตอร์น้อยที่สุดแต่มีประสิทธิภาพที่น้อยที่สุดเช่นกัน ส่วนฐานข้อมูล Yale Face B+ วิธีการที่ใช้จำนวนไอกเนกเตอร์น้อยที่สุด คือ วิธีการ I-2DPCA มีค่าความถูกต้องประมาณ 85.35% จากตาราง 4 แสดงให้เห็นว่าจำนวนไอกเนกเตอร์ไม่สามารถบ่งบอกได้ถึงประสิทธิภาพในการรู้จำใบหน้า แต่การเลือกไอกเนกที่เหมาะสมจะส่งผลต่อค่าความถูกต้องที่ดี

#### 4.2 การวัดประสิทธิภาพของการรู้จำใบหน้า

การวัดประสิทธิภาพของการรู้จำใบหน้า โดยการประเมินผลความถูกต้องของวิธีการที่ผู้วิจัยได้นำเสนอวิธีการ M1-2DPCA และวิธีการ M2-2DPCA เปรียบเทียบกับวิธีการ 2DPCA แบบดั้งเดิม วิธีการ 2D<sup>2</sup>PCA วิธีการ Bi2DPCA และ วิธีการ I-2DPCA โดยคำนวนหาค่าความถูกต้องได้จากสมการที่ 29 ในบทที่ 3 หัวข้อที่ 3.3

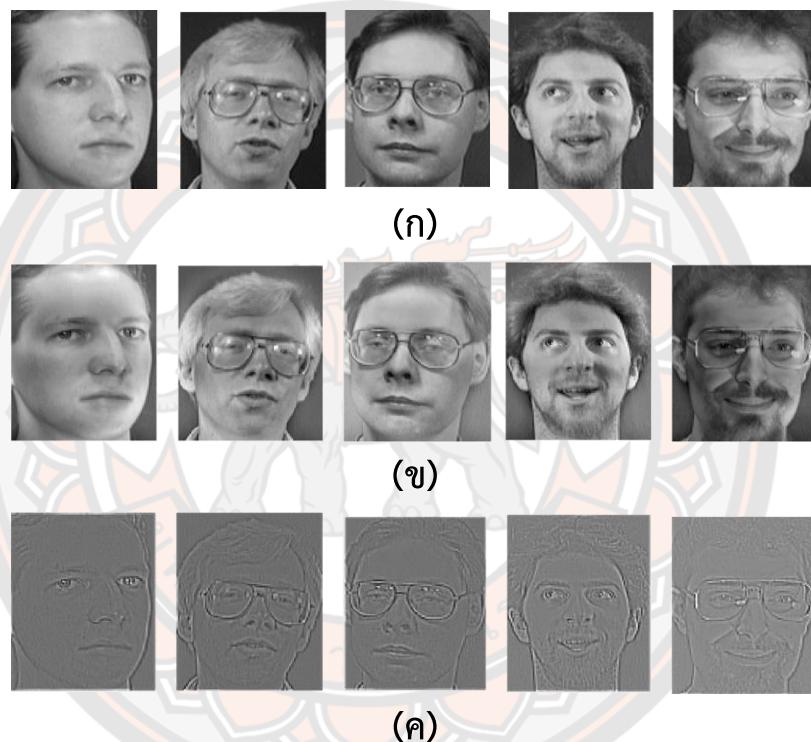
ผู้วิจัยได้ทำการทดลองกับ 3 ชุดข้อมูลได้แก่ 1) ชุดข้อมูลชื่อ ORL face database 2) ชุดข้อมูลชื่อ Yale face database และ 3) ชุดข้อมูลชื่อ Yale face database B+ โดยเปรียบเทียบประสิทธิภาพการทำงานของวิธีการที่ผู้วิจัยได้นำเสนอวิธีการ M1-2DPCA และวิธีการ M2-2DPCA กับวิธีการ 2DPCA แบบดั้งเดิม 2D<sup>2</sup>PCA Bi2DPCA และ I-2DPCA สำหรับการรู้จำใบหน้า แสดงดังตาราง 5

ตาราง 4 แสดงผลการทดลองวัดประสิทธิภาพของการรู้จำใบหน้า

Method	Accuracy rate (%) mean $\pm$ S.D.			
	ORL Face	Yale Face	Yale Face B+	Average
2DPCA	97.50 $\pm$ 2.04	84.82 $\pm$ 5.24	84.43 $\pm$ 12.28	88.92 $\pm$ 7.44
2D <sup>2</sup> PCA	<b>97.75 <math>\pm</math> 1.84</b>	85.44 $\pm$ 5.92	84.43 $\pm$ 12.28	89.21 $\pm$ 7.42
Bi2DPCA	97.25 $\pm$ 2.49	85.44 $\pm$ 5.92	84.43 $\pm$ 12.28	89.04 $\pm$ 7.13
I-2DPCA	97.50 $\pm$ 2.36	84.82 $\pm$ 5.24	85.35 $\pm$ 11.92	89.22 $\pm$ 7.17
M1-2DPCA	60.25 $\pm$ 12.50	50.37 $\pm$ 9.65	<b>89.03 <math>\pm</math> 9.67</b>	66.55 $\pm$ 20.08
M2-2DPCA	97.00 $\pm$ 2.30	<b>86.56 <math>\pm</math> 9.13</b>	86.62 $\pm$ 11.68	<b>90.06 <math>\pm</math> 6.01</b>

จากตาราง 5 การวัดประสิทธิภาพของการรู้จำใบหน้าจะเห็นว่าในฐานข้อมูล ORL Face วิธีการ 2D<sup>2</sup>PCA มีประสิทธิภาพที่ดีสุดมีค่าความถูกต้องประมาณ 97.75% และมีค่าความแปรปรวน 1.84 ส่วนฐานข้อมูล Yale Face วิธีการ M2-2DPCA มีประสิทธิภาพมากที่สุดมีค่าความถูกต้องประมาณ 86.56% และมีค่าความแปรปรวน 9.13 ในขณะที่วิธีการ M1-2DPCA มีประสิทธิภาพมากกว่าวิธีการอื่น ๆ เมื่อใช้ในฐานข้อมูล Yale Face B+ ซึ่งมีค่าความถูกต้องประมาณ 89.03% และมีค่าความแปรปรวน 9.67 หากเปรียบเทียบกับรวมของแต่ละวิธีการจะเห็นว่าวิธีการ M2-2DPCA นั้นมีภาพรวมที่ดีจึงเป็นตัวเลือกที่ดีสุดมีค่าความถูกต้องเฉลี่ยประมาณ 90.06% และมีค่าความแปรปรวนน้อยที่สุด 6.01

เมื่อพิจารณาฐานข้อมูล ORL Face จะเห็นว่าวิธีการ 2D<sup>2</sup>PCA นั้นมีประสิทธิภาพที่ดีสุดมีค่าความถูกต้องประมาณ 97.75% ส่วนวิธีการอื่น ๆ ก็มีประสิทธิภาพคล้ายกันมาก เนื่องจากวิธีการ 2DPCA 2D<sup>2</sup>PCA Bi2DPCA I-2DPCA และวิธีการ M2-2DPCA มีการคำนวณหารูปภาพเฉลี่ยเพียงรูปเดียวเหมือนกันจึงทำให้ได้ผลลัพธ์ใกล้เคียงกัน ขณะที่วิธีการ M1-2DPCA คำนวณหาค่าเฉลี่ยแบบท้องถิ่นทำให้สูญเสียรายละเอียดของรูปภาพซึ่งส่งผลต่อประสิทธิภาพของการรักษาใบหน้าดังแสดงในภาพ 36 ทำให้วิธีการ M1-2DPCA มีค่าความถูกต้องน้อยที่สุดประมาณ 60.25% เนื่องจาก M1-2DPCA ถูกพัฒนาเพื่อแก้ไขปัญหาผลกระทบจากการส่องสว่างของแสงโดยเฉพาะ



ภาพ 36 ตัวอย่างรูปภาพที่ปราศจากค่าเฉลี่ย

(ก) รูปภาพนำเข้า (ข) วิธีการ 2DPCA แบบดั้งเดิม (ค) วิธีการ M1-2DPCA

ส่วนฐานข้อมูล Yale Face ซึ่งเป็นฐานข้อมูลที่มีรูปแบบที่หลากหลาย เช่น รูปภาพใบหน้าที่แสดงอารมณ์ รูปภาพใบหน้าที่มีผลกระทบจากการส่องสว่างของแสง เป็นต้น และวิธีการที่มีประสิทธิภาพมากที่สุด คือ วิธีการ M2-2DPCA มีค่าความถูกต้องประมาณ 86.56% เนื่องจากวิธีการ M2-2DPCA มีการคำนวณหาความสัมพันธ์แบบ 2 ทิศทางจึงทำให้สามารถเก็บความสัมพันธ์ของรูปภาพได้ถึงแม้รูปภาพจะมีรูปแบบที่หลากหลายก็ตาม

ในขณะที่วิธีการ M1-2DPCA มีประสิทธิภาพมากกว่าวิธีการอื่น ๆ เมื่อใช้ในฐานข้อมูล Yale Face B+ ซึ่งมีค่าความถูกต้องประมาณ 89.03% เนื่องจากวิธีการ M1-2DPCA ถูกพัฒนาเพื่อแก้ไข

ปัญหาผลกระบทจากการส่องสว่างของแสงโดยเฉพาะ ซึ่งวิธีการ M1-2DPCA มีการคำนวณหาค่าเฉลี่ยแบบท้องถิ่นเพื่อกำจัดแสงเงาออกจากรูปภาพของแต่ละรูปภาพได้

หากเปรียบเทียบภาพรวมของแต่ละวิธีการจะเห็นว่าวิธีการ M2-2DPCA นั้นมีภาพรวมที่ดีจัง เป็นตัวเลือกที่ดีสุดมีค่าความถูกต้องเฉลี่ยประมาณ 90.06% และมีค่าความแปรปรวนน้อยที่สุด ประมาณ 6.01% เนื่องจากวิธีการ M2-2DPCA มีการคำนวณหาความสัมพันธ์แบบ 2 ทิศทางจึงทำให้สามารถเก็บความสัมพันธ์ของรูปภาพได้จึงเป็นตัวเลือกที่ดีสำหรับทุก ๆ ฐานข้อมูล

#### 4.3 การวัดประสิทธิภาพของเวลาที่ใช้ในการประมวลผล

ผู้วิจัยได้ทำการเปรียบเทียบเวลาในการคำนวณของแต่ละวิธีการ แสดงดังตาราง 6 โดยได้จับเวลาตั้งแต่ขั้นตอนการคำนวณหาค่าเฉลี่ยดังแสดงใน บทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 1 ข้อที่ 1 ถึง ขั้นตอนการได้รับໄอโเกนເງກເຕອຣັດັງแสดงใน บทที่ 2 หัวข้อที่ 2.2.2 ขั้นตอนที่ 2

ตาราง 5 แสดงผลการทดลองวัดประสิทธิภาพของเวลาที่ใช้ในการประมวลผล

Method	computing time for training (s)
2DPCA	0.1926
2D <sup>2</sup> PCA	0.3623
Bi2DPCA	0.3592
I-2DPCA	<b>0.0430</b>
M1-2DPCA	0.4286
M2-2DPCA	0.4521

จะเห็นว่าวิธีการ I-2DPCA นั้นใช้เวลาในการคำนวณน้อยที่สุด เนื่องจากวิธีการ I-2DPCA คำนวณรูปภาพเฉลี่ยเพียง 1 ภาพและทำการลบด้วยค่าเฉลี่ย โดยใช้รูปภาพเฉลี่ยลบกับค่าเฉลี่ย นอกจากนี้ยังทำการเลือกจำนวนໄอຟເກີນເຟເປັນໜ່ວງ ๆ จึงทำให้ใช้เวลาในการคำนวณน้อยกว่าวิธีการ อื่น ๆ ในขณะที่วิธีการ M1-2DPCA คำนวณรูปภาพเฉลี่ยของทุกรูปภาพและวิธีการ M2-2DPCA มีการคำนวณเมทริกซ์ระดับภูมิภาคและใช้เทคนิค ELSSP จึงทำให้วิธีการ M1-2DPCA และ M2-2DPCA ใช้เวลาในการคำนวณมาก

จากการทดลองและวัดประสิทธิภาพของวิธีการที่นำเสนอทั้ง 2 แบบพบว่า การปรับปรุงวิธีการ 2DPCA แบบที่ 1 มีประสิทธิภาพสูงสุดสำหรับการรู้จำใบหน้าภายใต้ผลตกระบทจากการส่องสว่างของแสงโดยใช้ฐานข้อมูลของ Yale face database B+

การปรับปรุงวิธีการ 2DPCA แบบที่ 2 มีประสิทธิภาพสูงสุดสำหรับภาพรวมเฉลี่ยของทั้ง 3 ฐานข้อมูลได้แก่ ORL face database Yale face database และ Yale face database B+ เมื่อเปรียบเทียบประสิทธิภาพกับวิธีการอื่นๆ ได้แก่ วิธีการ 2DPCA แบบดั้งเดิม 2D2PCA Bi2DPCA และ I-2DPCA



## บทที่ 5

### บทสรุป

งานวิจัยฉบับนี้มีวัตถุประสงค์เพื่อศึกษา และปรับปรุงวิธีการ 2DPCA สำหรับการรู้จำใบหน้าให้มีประสิทธิภาพ โดยมุ่งเน้นไปที่การพัฒนาหาความสัมพันธ์ของเมทริกซ์ความแปรปรวนร่วม ซึ่งผู้วิจัยได้ทำการปรับปรุงวิธีการ 2DPCA สำหรับการรู้จำใบหน้า 2 แบบ 1) ปรับปรุงวิธีการ 2DPCA สำหรับการรู้จำใบหน้าภายใต้ผลกระทบจากการส่องสว่างของแสง โดยอาศัยแนวคิดที่ว่า “ถ้าสามารถแก้ไขปัญหาผลกระทบจากการส่องสว่างของแสงในแต่ละรูปภาพได้ จะทำให้ได้รับโครงสร้างใบหน้าในแต่ละรูปภาพที่ชัดเจนขึ้น และสามารถรู้จำใบหน้าได้อย่างมีประสิทธิภาพมากขึ้น” และผู้วิจัยได้เสนอการหาค่าเฉลี่ยแบบเฉพาะถิ่น (Individual Local Mean) เพื่อกำจัดแสงเงาของแต่ละรูปภาพได้เนื่องจากรูปภาพแต่ละรูปได้รับผลกระทบจากการส่องสว่างของแสงไม่เท่ากัน ดังนั้นวิธีการ M1-2DPCA จึงตอบโจทย์สำหรับรูปภาพที่ได้รับผลกระทบจากการส่องสว่างของแสงโดยเฉลี่ย 2) ปรับปรุงวิธีการ 2DPCA สำหรับการรู้จำใบหน้าสำหรับใบหน้าที่มีรูปแบบที่หลากหลายให้มีประสิทธิภาพมากขึ้น โดยอ้างอิงจากแนวคิดที่กล่าวว่า “ถ้าสามารถคำนวณหาความสัมพันธ์ที่ดีในเมทริกซ์ความแปรปรวนร่วมได้ จะนำไปสู่ไอเกนเฟสที่ดี และเมื่อได้ไอเกนเฟสที่ดี ผลลัพธ์ที่ได้ก็จะมีประสิทธิภาพที่ดีเช่นกัน” และผู้วิจัยได้เสนอการปรับปรุง 2 ส่วนได้แก่ 1) การหาความสัมพันธ์แบบ 2 ทิศทาง ซึ่งการคำนวณสัมพันธ์แบบ 2 ทิศทางทำให้สามารถเก็บความสัมพันธ์ของรูปภาพได้ถึงแม้รูปภาพจะมีรูปแบบที่หลากหลายก็ตาม 2) การใช้เทคนิค ELSSP แทนการใช้เทคนิคการหาค่าเฉลี่ยในการคำนวณหาตัวแทนของเซตเมทริกซ์ความแปรปรวนร่วมเนื่องจากเทคนิคการหาค่าเฉลี่ยอาจทำให้สูญเสียข้อมูลบางส่วนที่สำคัญได้ การใช้เทคนิค ELSSP แทนจึงสามารถช่วยลดความเสียหายได้

### 5.2 อภิรายผล

จากการทดลองและวัดประสิทธิภาพของวิธีการที่นำเสนอทั้ง 2 แบบพบว่า การปรับปรุงวิธีการ 2DPCA แบบที่ 1 มีประสิทธิภาพสูงสุดสำหรับการรู้จำใบหน้าภายใต้ผลกระทบจากการส่องสว่างของแสงโดยใช้ฐานข้อมูลของ Yale face database B+ (Georghiades et al., 2001) และการ

ปรับปรุงวิธีการ 2DPCA แบบที่ 2 มีประสิทธิภาพสูงสุดสำหรับภาพรวมเฉลี่ยของทั้ง 3 ฐานข้อมูล ได้แก่ ORL face database (Samaria et al., 1994) Yale face database (Belhumeur et al., 1996) และ Yale face database B+ เมื่อเปรียบเทียบประสิทธิภาพกับวิธีการอื่น ๆ ได้แก่ วิธีการ 2DPCA แบบดั้งเดิม (Jian et al., 2004) วิธีการ 2D<sup>2</sup>PCA (Jian et al., 2004) วิธีการ Bi2DPCA (Kim et al., 2008) และวิธีการ I-2DPCA (Woraratpanya et al., 2015)

### 5.3 ข้อเสนอแนะ

ถึงแม้ว่าวิธีการที่นำเสนอจะมีค่าความคลุกต้องสูงกว่าวิธีการอื่น ๆ ได้แก่ วิธีการ 2DPCA แบบดั้งเดิม 2D<sup>2</sup>PCA Bi2DPCA และ I-2DPCA แต่วิธีการที่นำเสนอันมีการคำนวณที่เพิ่มขึ้น ทั้งการคำนวณหาค่าเฉลี่ยแบบห้องถัง การหาความสัมพันธ์แบบ 2 ทิศทาง และการใช้เทคนิค ELSSP ซึ่งทำให้วิธีการที่นำเสนอใช้เวลาในการคำนวณและใช้จานวนໄโอเกนเวกเตอร์สูงกว่าวิธีการอื่น ๆ



## បរវត្ថុក្រម

- Belhumeur, P. N., Hespanha, J. P., & Kriegman, D. J. (1996). **Eigenfaces vs. Fisherfaces: Recognition using class specific linear projection.**
- Georghiades, A. S., Belhumeur, P. N., & Kriegman, D. J. (2001). **From few to many: illumination cone models for face recognition under variable lighting and pose.** Paper presented at the IEEE Transactions on Pattern Analysis and Machine Intelligence.
- Hancherngchai, H., Titijaroonroj, T., & Rungrattanaubol, J. (2019). **An Individual Local Mean-based 2DPCA for Face Recognition under Illumination Effects.** Paper presented at the 2019 16th International Joint Conference on Computer Science and Software Engineering (JCSSE).
- Hancherngchai, H., Titijaroonroj, T., & Rungrattanaubol, J. (2020). **Regional Covariance Matrix-Based Two-Dimensional PCA for Face Recognition.** Paper presented at the 2020 12th International Conference on Knowledge and Smart Technology (KST).
- Jian, Y., Zhang, D., Frangi, A. F., & Jing-yu, Y. (2004). **Two-dimensional pca: a new approach to appearance-based face representation and recognition.** Paper presented at the IEEE Transactions on Pattern Analysis and Machine Intelligence.
- Kim, Y. G., Song, Y. J., Chang, U. D., Kim, D. W., Yun, T. S., & Ahn, J. H. (2008). **Face recognition using a fusion method based on bidirectional 2DPCA.** Paper presented at the Applied Mathematics and Computation.
- Samaria, F. S., Samaria, F. S., Harter, A., & Site, O. A. (1994). **Parameterisation of a stochastic model for human face identification**
- Seo, J., & Kim, S. D. (2013). **Novel PCA-based color-to-gray image conversion.** Paper presented at the 2013 IEEE International Conference on Image Processing.
- Sirovich, L., & Kirby, M. (1987). **Low-dimensional procedure for the characterization of human faces.** Paper presented at the Journal of the Optical Society of America. A, Optics and Image Science.
- Woraratpanya, K., Sornnoi, M., Leelaburanapong, S., Titijaroonroj, T., Varakulsiripunth, R.,

- Kuroki, Y., & Kato, Y. (2015). **An improved 2DPCA for face recognition under illumination effects.** Paper presented at the 2015 7th International Conference on Information Technology and Electrical Engineering (ICITEE).
- Zhang, D., & Zhou, Z.-H. (2005). : **Two-directional two-dimensional PCA for efficient face representation and recognition.**







ตาราง 6 แสดงผลการทดสอบประสิทธิภาพของเครื่องจำรูปหน้าที่อยู่ในชุด The ORL Face Database

Method	10-fold cross validation										Average (%)	$\pm$ S.D.	Number of Eigenvectors (%)
	1	2	3	4	5	6	7	8	9	10			
2DPCA	95.00	95.00	95.00	100.00	97.50	97.50	100.00	97.50	97.50	97.50	97.50	97.50 ± 2.04	5.43
2D2PCA	97.50	95.00	95.00	97.50	100.00	100.00	100.00	97.50	97.50	97.50	97.75	97.75 ± 1.84	5.43
Bi2DPCA	97.50	95.00	92.50	100.00	100.00	97.50	97.50	100.00	95.00	97.50	97.25	97.25 ± 2.49	10.87
I-2DPCA	97.50	95.00	95.00	100.00	97.50	100.00	100.00	95.00	95.00	95.00	97.50	97.50 ± 2.36	5.43
M1-2DPCA	40.00	57.50	45.00	65.00	72.50	75.00	70.00	52.50	52.50	72.50	60.25	60.25 ± 12.50	1.09
M2-2DPCA	95.00	97.50	92.50	100.00	97.50	97.50	97.50	95.00	97.50	97.50	97.00	97.00 ± 2.30	100.00

ตาราง 7 แสดงผลการทดสอบวัดประสมิทธิภาพของเครื่องจักรที่นำไปใช้สำหรับฐานข้อมูล Yale Face Database

Method	10-fold cross validation										Average (%) $\pm$ S.D.	Number of Eigenvectors (%)
	1	2	3	4	5	6	7	8	9	10		
2DPCA	87.50	82.35	82.35	82.35	88.24	94.12	87.50	75.00	87.50	81.25	84.82 $\pm$ 5.24	12.82
2D2PCA	87.50	82.35	82.35	82.35	88.24	94.12	93.75	75.00	87.50	81.25	85.44 $\pm$ 5.92	25.64
Bi2DPCA	87.50	82.35	82.35	82.35	88.24	94.12	93.75	75.00	87.50	81.25	85.44 $\pm$ 5.92	12.82
2DPCA	87.50	82.35	82.35	82.35	88.24	94.12	87.50	75.00	87.50	81.25	84.82 $\pm$ 5.24	25.64
M1-2DPCA	56.25	47.06	29.41	52.94	52.94	58.82	43.75	62.50	43.75	56.25	50.37 $\pm$ 9.65	0.51
M2-2DPCA	81.25	76.47	88.24	100.00	88.24	94.12	87.50	81.25	87.50	75.00	<b>86.56 <math>\pm</math> 9.13</b>	15.15

ตาราง 8 แสดงผลการทดสอบวัดประสิทธิภาพของการรักษาพื้นที่ของ Yale Face Database B+

Method	10-fold cross validation										Average (%) $\pm$ S.D.	Number of Eigenvectors (%)
	1	2	3	4	5	6	7	8	9	10		
2DPCA	71.93	97.81	90.35	93.42	64.91	85.53	79.82	68.86	95.61	96.05	84.43 $\pm$ 12.28	44.64
2D2PCA	71.93	97.81	90.35	93.42	64.91	85.53	79.82	68.86	95.61	96.05	84.43 $\pm$ 12.28	59.52
B12DPCA	71.93	97.81	90.35	93.42	64.91	85.53	79.82	68.86	95.61	96.05	84.43 $\pm$ 12.28	44.64
I-2DPCA	86.40	97.81	89.47	94.30	66.23	76.75	86.84	65.79	97.81	92.11	85.35 $\pm$ 11.92	2.98
M1-2DPCA	75.88	97.81	96.42	91.23	70.61	92.54	91.67	81.14	96.49	96.49	<u>89.03</u> + <u>9.67</u>	44.64
M2-2DPCA	71.49	98.25	89.47	94.30	68.42	87.72	89.47	71.93	97.81	97.37	86.62 $\pm$ 11.68	89.29



## บทความที่นำเสนอในงานประชุมวิชาการ

1. บทความเรื่อง “An Individual Local Mean-based 2DPCA for Face Recognition under Illumination Effects” นำเสนอในงานการประชุมวิชาการระดับนานาชาติ The 16<sup>th</sup> International Joint Conference on Computer Science and Software Engineering (JCSSE2019) จัดที่โรงแรม Amari Pattaya จังหวัดชลบุรี ประเทศไทย ระหว่างวันที่ 10-12 กรกฎาคม พ.ศ.2562 บทความนี้ตีพิมพ์ไว้ใน Proceeding of 2019 - 16<sup>th</sup> International Joint Conference on Computer Science and Software Engineering หน้า 207-211
2. บทความเรื่อง “Regional Covariance Matrix-Based Two-Dimensional PCA for Face Recognition” นำเสนอในงานการประชุมวิชาการระดับนานาชาติ The 12<sup>th</sup> International Conference on Knowledge and Smart Technology (KST’2020) จัดที่โรงแรม Amari Pattaya จังหวัดชลบุรี ประเทศไทย ระหว่างวันที่ 29 มกราคม - 1 กุมภาพันธ์ พ.ศ. 2563 บทความนี้ตีพิมพ์ไว้ใน Proceeding of 2020 - 12<sup>th</sup> International Conference on Knowledge and Smart Technology หน้า 6-11

# An Individual Local Mean-based 2DPCA for Face Recognition under Illumination Effects

Kangsadan Hancherngchai <sup>\*</sup>, Taravichet Titijaroonroj<sup>†</sup> and Jaratsri Rungrattanaubol<sup>‡</sup>

<sup>\*</sup><sup>†</sup>Faculty of Science, Department of Computer Science and Information Technology,  
Naresuan University, Phitsanulok, 65000, THAILAND

Email: kangsadanh61@email.nu.ac.th<sup>\*</sup> and jaratsrir@nu.ac.th<sup>†</sup>

<sup>‡</sup>Faculty of Information Technology, King Mongkut's Institute of Technology Ladkrabang,  
Bangkok, 10520, THAILAND. Email: taravichet@it.kmitl.ac.th<sup>‡</sup>

**Abstract**—Principal component analysis (PCA) is a classical technique in pattern recognition and computer vision. It is one of the most successful techniques for face recognition. The PCA consists of two main steps including (I) covariance matrix calculation and (II) eigenvector and eigenvalue extraction. In case of face recognition, the input image is converted to the vector form before forwarding to covariance matrix computation. Then, the matrix is used to extract the eigenvector and eigenvalue. Two-dimensional PCA (2DPCA) is introduced to reduce high-dimensional problems. The illumination effect problems in the face recognition is still needed to be resolved. In order to improve and solve the problems, this paper proposes an individual local mean-based 2DPCA (ILM-2DPCA), which replaces a single local mean in 2DPCA method. The individual local mean can provide more appropriate mean to each image, which can reduce the illumination effect effectively. The experimental study is set up on dataset Yale face database B+. The results indicate that the proposed method outperforms, based on the accuracy rate, all the baseline methods which are 2DPCA, I-2DPCA, Bi2DPCA and 2D<sup>2</sup>PCA.

**Keywords**—Individual local mean; principal component analysis (PCA); Two-dimensional PCA (2DPCA); face recognition; illumination effects

## I. INTRODUCTION

Principal component analysis (PCA) is one of the most powerful method used in image processing and pattern recognition applications to perform a specific task such as dimensionality reduction, image compression, and especially face recognition [1], [2]. The PCA method consists of two main steps—(I) computing covariance matrix and (II) extracting eigenvector and eigenvalue. In the first step, the covariance matrix is calculated from the data zero mean which is computed by the subtraction between input data and mean. In the second step, a set of eigenvectors and eigenvalues are extracted by using the covariance matrix based on linear transformation. The eigenvectors are sorted in descending order with respect to their corresponding eigenvalues. In case of face recognition, the eigenvectors selected from 1<sup>st</sup> to n<sup>th</sup> order are used to create the eigenface feature using the projection technique.

Afterwards, a two-dimensional principal component analysis (2DPCA) demonstrated in 2004 by Yang et al. [3] was modified from the original PCA in computing covariance matrix step by using the input image (matrix) instead of a vector from to reduce computational cost. In 2015, Woraratpanya et al. presented the modification of two-dimensional principal com-

ponent analysis (I-2DPCA) [4] for face recognition under illumination effects which is extended from the 2DPCA method in two main points including (I) modifying the covariance matrix computation and (II) selecting the set of the eigenvectors for eigenface construction. Although these extended 2DPCA methods are quite successful, they still extract the eigenvector and eigenvalue in a single direction (either row or column) from the covariance matrix. In 2005 and 2008, two-directional two-dimensional PCA (2D<sup>2</sup>PCA) [5] and bi-directional two-dimensional PCA (Bi2DCA) [6] were proposed by Zhang et al. and Kim et al, respectively, to extract a set of eigenvectors and eigenvalues in both column and row directions from the covariance matrix as a so-called column and row eigenvectors. These two methods are different in constructing eigenface step from the column and row eigenvectors. The Bi2DPCA uses a linear transformation to construct the eigenface while the 2D<sup>2</sup>PCA employs the projection technique.

As mentioned above, although these methods are successful in face recognition, in case of illumination effects, they are still needed to get improved on the performance of the input image as explained in [4]. In order to solve this problem, this paper proposes an individual local mean-based 2DPCA for face recognition, under illumination conditions. The main contribution to achieve this problem stems from the modification of the mean calculation in the covariance matrix computation by using the individual local mean image.

The rest of this paper includes four main sections. Problem formulation is described in section II. Proposed method is explained in section III. Experimental result and discussion are demonstrated in section IV. Finally, conclusion is presented in section V.

## II. PROBLEM FORMULATION

This section aims to explain the illumination condition problems on the face recognition when 2DPCA method applying.

In 2004, the 2DPCA was presented by Yang et al. to extract the eigenface, which is constructed from a set of eigenvector, for face recognition. The eigenvector and eigenvalue are obtained based on the variance between the pixels arranged in row or column image that can be extracted from the covariance matrix. If the variance extracted from the covariance matrix is inaccurate, the eigenvector and eigenvalue are also inaccurate. The covariance matrix is computed from

the subtraction between an input image with a mean image. In other words, the mean image directly affects the accuracy of the covariance matrix. As shown in Fig. 1, the zero-mean image under illumination effects cannot clearly represent the structure of the image as illustrated in the first three zero-mean images obtained by using 2DPCA, I-2DPCA and Bi2DPCA methods as displayed in Fig. 1(c). In 2002 and 2004, Wang et al. explained that the mean value of the image can be represented as an illumination component whereas the variance value of the image denoted the contrast and structure components as explained in [7], [8]. Therefore, in case of the illumination effect on face recognition, this effect is often located in the mean image. It means that the covariance matrix is inaccurate, if it is calculated from unactual zero-mean image since it cannot completely remove the illumination effect from the input image to obtain the actual variance.

A workflow of the covariance matrix construction step of the 2DPCA, I-2DPCA, 2D<sup>2</sup>PCA and Bi2DPCA methods is depicted as shown in Fig. 2(a-c). In the 2DPCA method, the zero-mean image is constructed from subtraction the input image with a single mean image. This is applied in 2D<sup>2</sup>PCA and Bi2DPCA methods while the zero-mean image of I-2DPCA method is defined from the mean image and mean value. From the study, we found that constructing zero-mean image using a single mean image cannot effectively remove the illumination effect for face recognition since one single mean image is not appropriately applied for all input images.

In order to solve this problem, an individual local mean image is proposed. It is employed here to generate the appropriate mean image for each individual image. Hence, it can reduce the illumination effect on each input image.

### III. PROPOSED METHOD

The method proposed here can be divided into two stages. The first stage is involved with applying an individual local mean instead of a single mean and the second stage explains how to apply this idea to face recognition.

#### A. An individual local mean-based 2DPCA method

Individual local mean-based 2DPCA method (ILM-2DPCA) is proposed to solve the illumination effects for face recognition in which its workflow is presented in Fig. 2(d). This proposed method is extended from the 2DPCA by replacing the single mean image to the individual local mean image. ILM-2DPCA consists of two main steps as follows.

*1) Computing covariance matrix:* A training image  $I_i$  with resolution  $M \times N$  is employed to compute an individual local mean image by using Eq. (1).

$$\bar{I}_i(m, n) = \frac{1}{(2w+1)^2} \sum_{u=m-w}^{m+w} \sum_{v=n-w}^{n+w} I_i(u, v) \quad (1)$$

where  $\bar{I}_i$  is an individual local mean image of the training image  $I_i$  and  $w$  is a window size. There is an individual local mean image for each training image.

Each individual local mean images is used to calculate the zero-mean image  $\Lambda_i$  by subtracting  $\bar{I}_i$  from training image  $I_i$  as defined in Eq. (2).

$$\Lambda_i = I_i - \bar{I}_i \quad (2)$$

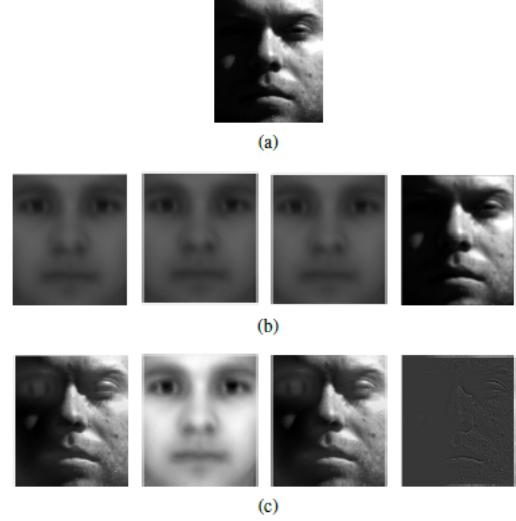


Fig. 1: The comparison of mean image and zero-mean image computed by using 2DPCA, I-2DPCA, Bi2DPCA, ILM-2DPCA methods, respectively: (a) an original image, (b) mean image and (c) zero-mean image.

After that, the zero-mean image is employed to generate its covariance matrix  $\Psi_i$  by using Eq. (3).

$$\Psi_i = \frac{1}{M-1} \sum_{m=1}^M \Lambda_i \Lambda_i^T \quad (3)$$

where  $T$  is a transpose operator. The equations (1) to (3) are applied to all training images to obtain the set of the covariance matrix. The mean of the covariance matrix  $\Psi$  is calculated from Eq. (4).

$$\Psi(m, n) = \frac{1}{S} \sum_{s=1}^S \Psi_s(m, n) \quad (4)$$

where  $S$  is a number of the training images.

*2) Extracting eigenvector and eigenvalue:* The set of eigenvector and eigenvalue are extracted from the mean of the covariance matrix as defined in Eq. (5).

$$AV = V\Psi \quad (5)$$

where  $V$  is the eigenvector with sizes  $M \times M$  and  $A$  is the eigenvalue with sizes  $M \times M$ .

#### B. ILM-2DPCA for face recognition

ILM-2DPCA method for face recognition includes two main steps—(1) eigenface construction and (2) face classification.

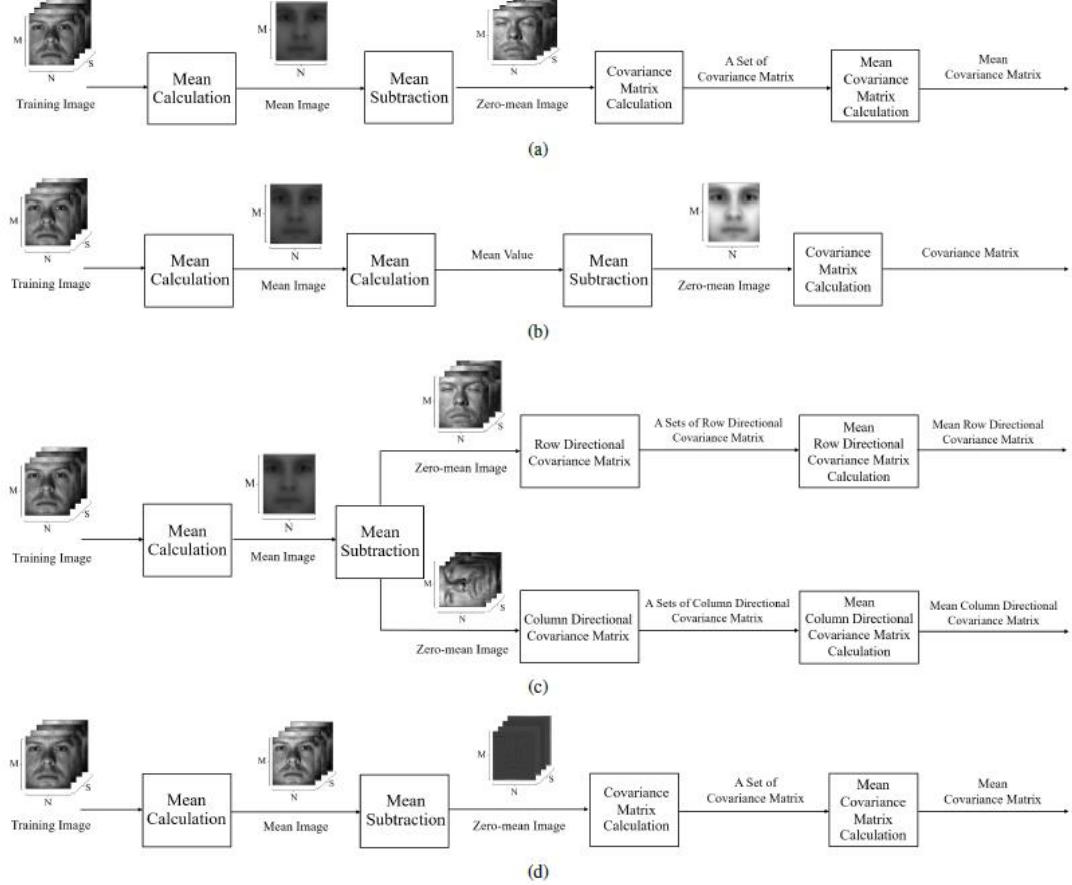


Fig. 2: The covariance matrix construction step for face recognition based on: (a) 2DPCA, (b) I-2DPCA, (c) 2D<sup>2</sup>PCA-and-Bi2DPCA and (d) ILM-2DPCA methods

*1) Eigenface Construction:* An eigenface  $\Upsilon_i$  is computed from the set of the eigenvector,  $V = [v_1, v_2, v_3, \dots, v_M]$ , with the input image by using the projection technique in Eq. (6).

$$\Upsilon_i = I_i \nu \quad (6)$$

where  $\nu$  is the selected first  $K$  eigenvectors as shown in Eq. (7).

$$\nu = [v_1, v_2, v_3, \dots, v_K] \quad (7)$$

*2) Face Classification:* An euclidean distance, which is a simple and useful method, is employed to classify a testing image into the correct group. The distance between two eigenfaces is computed by using Eq. (8).

$$d_{i,j} = \sqrt{\sum_{k=1}^K (\Upsilon_i(k) - \Upsilon_j(k))^2} \quad (8)$$

where  $\Upsilon_i$  and  $\Upsilon_j$  are the eigenface of the image  $i$  and  $j$ , respectively.

#### IV. EXPERIMENTAL RESULT AND DISCUSSION

This section aims to compare the performance of the proposed method with the selected baseline methods. The experimental preparation will be described, then followed by the results and discussions.

##### A. Experimental Preparation

In order to evaluate the performance of the proposed method by comparison with the baseline methods, the baseline methods selected here are 2DPCA [3], I-2DPCA [4], 2D<sup>2</sup>PCA [5] and Bi2DPCA [6] methods. The extended Yale face database B+ [9], which is a common standard dataset for face

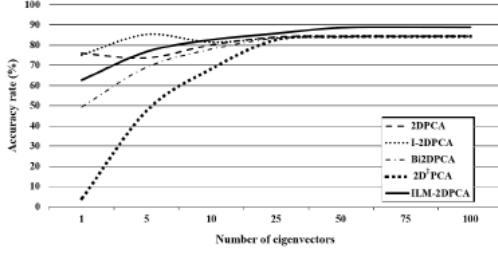


Fig. 3: A plotted graph of the average accuracy rate and the number of eigenvector used.

TABLE I: The average and standard deviation of the 2DPCA, I-2DPCA, Bi2DPCA, 2D<sup>2</sup>PCA and ILM-2DPCA methods.

Methods	Mean	S.D.
2DPCA	84.43	12.28
I-2DPCA	85.35	11.92
Bi2DPCA	84.43	12.28
2D <sup>2</sup> PCA	84.43	12.28
ILM-2DPCA	<b>89.03</b>	<b>9.67</b>

recognition, is used for the experiment. This dataset includes 2,280 images with resolution  $168 \times 192$  which are the image of 38 human faces with 60 different illumination conditions (i.e.  $38 \times 60 = 2,280$ ). Moreover,  $k$ -fold cross validation, which is a technique to separate all images to  $k$  groups to avoid an overfitting problem, is used. In this experiment,  $k$  is set to 10. To evaluate the efficiency in each method, an accuracy rate (Acc), which is a standard measurement, is defined in Eq. (9).

$$Acc = \frac{N_{correct}}{N_{total}} \times 100 \quad (9)$$

where  $N_{correct}$  and  $N_{total}$  are the number of the correct recognition and total images, respectively.  $Acc$  is an accuracy rate.

### B. Results and Discussions

Based on  $k$ -fold cross validation, Fig. 3 graphically depicts the relation between the average accuracy rate and the number of eigenvectors used of the proposed method and the baseline methods. It shows that the tendency of the accuracy rate increases when the number of eigenvectors used increases. The performance of all methods is nearly stable after the first twenty-five eigenvectors used. The accuracy rate line of the ILM-2DPCA method is higher than all baseline methods when the number of eigenvectors is larger than 10.

Table I displays the average and standard deviation of accuracy rate on the best performance of each method, in which the best performance is obtained from the different number of eigenvector used. The number of the eigenvector used in 2DPCA, I-2DPCA, Bi2DPCA, 2D<sup>2</sup>PCA and ILM-2DPCA are 75, 5, 150, 200 and 75 respectively. Based on the figures in Table I, our proposed method performs best at the average accuracy rate of 89.03. Moreover, the standard deviation of the accuracy rate obtained from the proposed method is lower than that of 2DPCA, I-2DPCA, Bi2DPCA



Fig. 4: The result of the face recognition under illumination effect by using 2DPCA, I-2DPCA, Bi2DPCA, 2D<sup>2</sup>PCA and ILM-2DPCA methods, respectively.

and 2D<sup>2</sup>PCA. It means that the ILM-2DPCA is a robust and stable method for face recognition under illumination conditions. In 2DPCA, Bi2DPCA and 2D<sup>2</sup>PCA methods, they obtain the identical zero-mean image which is used to calculate the covariance matrix, thus making its result to be similar when applying to the eigenface computation as shown in Table I. The performance of the proposed method is better than that of the baseline methods since it can calculate more accurate covariance matrix than the others by subtracting the actual mean image from the given image. This can reduce the illumination effect from the eigenface. The example results of the proposed and the baseline methods are shown in Fig. 4.

### V. CONCLUSION

In this paper, the individual local mean-based 2DPCA method as a so-called ILM-2DPCA method is proposed to reduce the effect from the illumination conditions for face recognition. As a result, when proposed method is evaluated with the extended Yale face database B+, the experimental results show that the proposed method outperforms all the baseline methods including the 2DPCA, I-2DPCA, Bi2DPCA and 2D<sup>2</sup>PCA methods in terms of the accuracy rate. The achievement of the ILM-2DPCA method comes from replacing individual local mean image to the single mean image in the covariance matrix construction step of the 2DPCA method. This leads to obtain the eigenface are less affected by the illumination conditions.

## REFERENCES

- [1] L. Sirovich and M. Kirby, "Low-dimensional procedure for the characterization of human faces," *Journal of the Optical Society of America A, Optics and Image Science*, vol. 4, no. 3, pp. 519–524, Mar. 1987.
- [2] M. Turk and A. Pentland, "Eigenfaces for recognition," *Journal of Cognitive Neuroscience*, vol. 3, no. 1, pp. 71–86, 1991.
- [3] D. Zhang and A. F. F. and, "Two-dimensional PCA: a new approach to appearance-based face representation and recognition," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 26, no. 1, pp. 131–137, Jan. 2004.
- [4] K. Woraratpanya, M. Sornnoi, S. Leelaburanapong, T. Titijaroonroj, R. Varakulsriruponth, Y. Kuroki, and Y. Kato, "An improved 2DPCA for face recognition under illumination effects," in *2015 7th International Conference on Information Technology and Electrical Engineering (ICITEE)*, Oct. 2015, pp. 448–452.
- [5] D. Zhang and Z. H. Zhou, "Two-directional two-dimensional PCA for efficient face representation and recognition," *Neurocomputing*, vol. 69, no. 1-3, pp. 224–231, Dec. 2005.
- [6] Y. G. Kim, Y. J. Song, U. D. Chang, D. W. Kim, T. S. Yun, and J. H. Ahn, "Face recognition using a fusion method based on bidirectional 2DPCA," *Applied Mathematics and Computation*, vol. 205, no. 2, pp. 601–607, Nov. 2008.
- [7] Z. Wang, A. C. Bovik, and L. Lu, "Why is image quality assessment so difficult?" in *2002 IEEE International Conference on Acoustics, Speech, and Signal Processing*, vol. 4, May 2002, pp. IV-3313–IV-3316.
- [8] A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, "Image quality assessment: from error visibility to structural similarity," *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600–612, Apr. 2004.
- [9] A. S. Georghiades, P. N. Belhumeur, and D. J. Kriegman, "From few to many: illumination cone models for face recognition under variable lighting and pose," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 23, no. 6, pp. 643–660, Jun. 2001.

# Regional Covariance Matrix-Based Two-Dimensional PCA for Face Recognition

Taravichet Titijaroonroj<sup>†</sup>, Kangsadan Hancherngchai<sup>\*</sup> and Jaratsri Rungrattanaubol<sup>‡</sup>

<sup>\*</sup><sup>‡</sup>Faculty of Science, Department of Computer Science and Information Technology,  
Naresuan University, Phitsanulok, 65000, THAILAND

Email: kangsadan61@email.nu.ac.th<sup>\*</sup> and jaratsrir@nu.ac.th<sup>‡</sup>

<sup>†</sup>Faculty of Information Technology, King Mongkut's Institute of Technology Ladkrabang,  
Bangkok, 10520, THAILAND. Email: taravichet@it.kmitl.ac.th<sup>†</sup>

**Abstract**—Two-dimensional principal component analysis (2DPCA) is widely used in many applications, especially, face recognition. A key factor to improve the performance of the 2DPCA method comes from the efficiency of the covariance matrix. This paper believes that the effective eigenvector can be extracted when the effective covariance matrix is given. Therefore, the computing covariance matrix is a focus point in this paper. The set of the covariance matrix in the 2DPCA and its extensions is usually represented with a single directional correlation, which is then used to obtain a mean covariance matrix by using the average technique. This causes in obtaining the ineffective eigenvector since the covariance matrix is ineffective. In order to obtain the effective eigenvector, a regional covariance matrix-based on 2DPCA method (RCM-2DPCA) is proposed here. The contribution of this paper consists of two main parts including (i) regional matrix calculation for computing the two directional correlations and (ii) ELSSP conversion for extracting the effective representation of the covariance matrix. The experimental results show that the performance of the proposed method is higher than the baseline methods including 2DPCA, I-2DPCA, Bi2DPCA, 2D2PCA and ILM-2DPCA methods on a basis of three well-known datasets—ORL Face, Yale Face, and Yale Face extended B+ datasets.

**Keywords**—regional matrix; ELSSP conversion; principal component analysis; Two-dimensional PCA (2DPCA); face recognition

## I. INTRODUCTION

Principal component analysis (PCA) is one of the most popular methods for face recognition. Moreover, PCA has been applied and widely used in many applications such as data compression [1], color transform [2] and image recognition [3], [4]. This paper focuses on applying and improving the PCA method on face recognition. The conventional PCA method for face recognition usually consists of two main steps (i) extracting eigenvector-and-eigenvalue from a covariance matrix which represents the correlation between each facial image as so-called an external correlation and (ii) constructing eigenface feature from a set of first  $k$  eigenvectors. Afterward, the PCA method is extended to support two dimensional data such as Yang and his colleague proposed the two-dimensional principal component analysis (2DPCA) for face recognition [5]. The 2DPCA method computes the covariance matrix from a single image by extracting the correlation between row or between column pixels, only in one direction. We can consider that the covariance matrix of the 2DPCA method representing an internal correlation. Then to obtain the correlation for all

given images, 2DPCA uses the average method to approximate the correlation between the given images from all covariance matrices, thus making some losses on correlation values. This is also because the correlation in its covariance matrix is a single direction (row-based or column-based) as reported in [6], [7]. In addition, some researches proposed a way to extract the correlation in both directions (both row and column) as discussed in the 2D<sup>2</sup>PCA [6] and Bi2DPCA [7] respectively. Both methods calculate row and column covariance matrices from input images in row and column direction, separately, which is still similar to the 2DPCA idea. Hence, the 2D<sup>2</sup>PCA and Bi2DPCA methods can extract the correlation in two directions, but with two separate covariance matrices for row and column. They use two covariance matrices, instead of a single covariance matrix. This may cause the performance ineffective.

In 2015, Woraratpanya et al. [8] presented the improved 2DPCA (I-2DPCA) for face recognition under illumination effects. This method aims to reduce the computational cost by using a single mean technique and to construct the eigenface which is robust to the lighting condition by using their proposed eigenvector selection technique. Recently, in 2019, the individual local mean-based 2DPCA (ILM-2DPCA) presented by Hancherngchai and her colleague [9], which replaced a single mean with the local mean technique for each image. This improvement could overcome the illumination effects on the facial image.

Nevertheless, all methods mentioned above are still lacking two main issues—(i) **one covariance matrix can only represents a single directional correlation** and (ii) **the mean of the covariance matrix computed by average technique may be ineffective**. In this paper, we believe that the effective eigenface can be obtained from a set of the eigenvectors, which are calculated from the effective covariance matrix. To extract the covariance matrix, which overcomes these two issues, we proposed the regional covariance matrix-based two-dimensional PCA as so-called RCM-2DPCA. Hence, the main contribution of this method consists of two main parts—(i) calculating regional matrix and standardizing input image before computing covariance matrix, which leads to a single covariance matrix representing the two directional correlations, and (ii) extracting the covariance matrix based on ELSSP conversion proposed by Seo et al. [2], which replaces the average technique as depicted in Fig. 1(a) and (b) that can prevent some correlation lost.

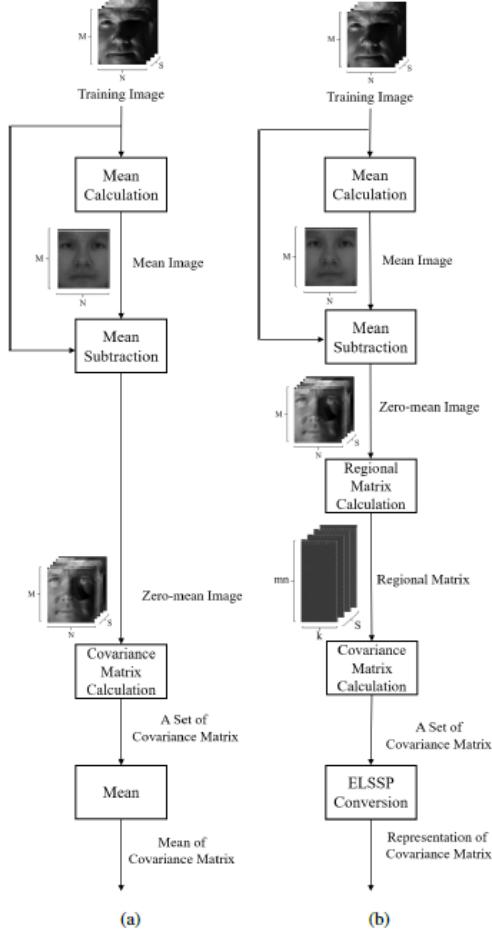


Fig. 1: The covariance matrix construction for face recognition based on (a) 2DPCA and (b) RCM-2DPCA methods

The rest of this paper consists of four main sections. Firstly, the problem formulation is defined in section II. Secondly, the proposed method is presented in section III. The experiment and discussion are shown and explained in section IV. Lastly, the conclusion is given in section V.

## II. PROBLEM FORMULATION

In this section, we will explain why the 2DPCA method and its extensions are lacking the two issues mentioned previously in section I as follows:

As described before, we believe that the PCA method and its extensions will return the effective eigenvector and eigenvalue, providing that the effective covariance matrix is

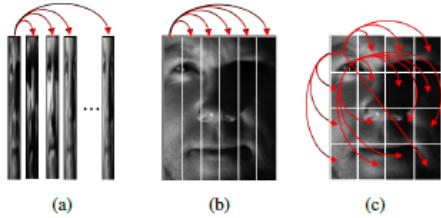


Fig. 2: The correlation in the covariance matrix based on (a) PCA, (b) 2DPCA and (c) RCM-2DPCA methods

given. It means that the covariance matrix is a key factor to improve performance. The covariance matrix can be defined by using Eq. (1).

$$\text{cov}(B) = \frac{1}{S-1} \sum_{i=1}^S BB^T \quad (1)$$

where  $T$  is a transpose operation and  $S$  is a total number of the training image.  $B$  is a data-zero matrix computed from a subtraction between the input data with its mean as written in Eq. (2).

$$B = [b_1, b_2, b_3, \dots, b_S] \quad (2)$$

where  $b_S$  is the training image in vector form when applied to the PCA method as shown in Fig. 2(a) whereas it is a set of pixels aligned in vertical or horizontal directions within a given image when applied to the 2DPCA method and its extensions as shown in Fig. 2(b). The covariance matrix computed from the conventional PCA method can represent the correlation between the training image while that of the 2DPCA method can represent the correlation within an image.

In the first issue, the way that 2DPCA computes covariance matrix may be inappropriate since the covariance matrix represents the correlation one direction, but the image is two dimensional. It means that we need at least two correlation matrices as reported in [6], [7]. Secondly, a set of covariance matrix or many matrices come out from the covariance matrix calculation as depicted in Fig. 1(a). The 2DPCA method uses the mean covariance matrix, based on averaging, to represent these matrices. This technique may not prevent discrimination among the facial image. In other words, the correlation between two any images is not equal, similar to the case of the RGB-to-Gray image. The weight of each color channel is not identical as explained in [2].

As mentioned above, this paper proposes (i) a regional matrix construction to compute the correlation in two directions as explained in section III(B) and (ii) ELSSP conversion to obtain the effective representation of the covariance matrix as described in section III(C).

## III. PROPOSED METHOD

This section will explain and describe the proposed method named RCM-2DPCA for face recognition. The content of this section can be divided into three parts including (i) RCM-2DPCA for face recognition, (ii) Regional Matrix Calculation, and (iii) ELSSP Conversion as follows:

### A. RCM-2DPCA for face recognition

Regional covariance matrix-based two-dimensional PCA method (RCM-2DPCA) is proposed to obtain the covariance matrix which can represent the two directional correlation instead of obtaining row and column covariance matrices, since existing two directional methods such as 2D<sup>2</sup>PCA and Bi2DPCA using a single direction that is calculated twice to obtain row and column covariance matrices but the proposed regional covariance matrix can present the row and column relations in a single matrix. Our proposed method, extended from the 2DPCA method, includes five stages—(1) regional matrix calculation, (2) covariance matrix calculation, (3) ELSSP Conversion, (4) eigenvector and eigenvalue extraction, and (5) eigenface generation.

1) *Regional Matrix Calculation*: a mean image  $\bar{I}$ , which is an average of all training images, is compute by Eq. (3).

$$\bar{I} = \sum_{i=1}^S I_i \quad (3)$$

where  $I_i$  is a training image with sizes  $M \times N$ .

The mean image is used to calculate zero-mean image ( $\Phi_i$ ) by subtraction  $\bar{I}$  from training image  $I_i$  as defined by Eq. (4).

$$\Phi_i = I_i - \bar{I} \quad (4)$$

After that regional matrix ( $R_i$ ) will be computed from the zero-mean image as described in section III-B.

2) *Covariance Matrix Calculation*: the covariance matrix ( $\Psi_i$ ) is calculated from the regional matrix ( $R_i$ ) by using Eq. (1),  $\Psi_i = cov(R_i)$ .

3) *ELSSP Conversion*: a representative of the covariance matrix ( $\Psi_{rep}$ ) is computed by using ELSSP method as described in section III-C.

4) *Eigenvector and Eigenvalue Extraction*: the set of eigenvector ( $A$ ) and eigenvalue ( $U$ ) are extracted from the representative of the covariance ( $\Psi_{rep}$ ) as defined in Eq. (5).

$$UA = A\Psi_{rep} \quad (5)$$

5) *Eigenface Generation*: eigenface ( $\Gamma$ ) is a feature for face recognising constructed by selecting first  $g$  eigenvectors  $A = \{a_1, a_2, a_3, \dots, a_g\}$ , and facial image ( $I_i$ ) with the projection technique as defined in Eq. (6).

$$\Gamma_i = I_i \tilde{A} \quad (6)$$

6) *Face Classification*: the Euclidean distance is used to measure a similarity between two eigenfaces as defined in Eq. (7).

$$d_{i,j} = \sqrt{\sum_{g=1}^G (\Gamma_i(g) - \Gamma_j(g))^2} \quad (7)$$

where  $d_{i,j}$  presents the similarity between eigenfaces of training ( $\Gamma_i$ ) and testing ( $\Gamma_j$ ) images.

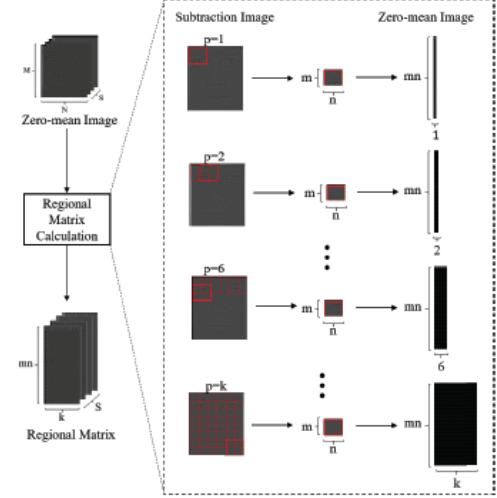


Fig. 3: An illustrative process of the regional matrix calculation

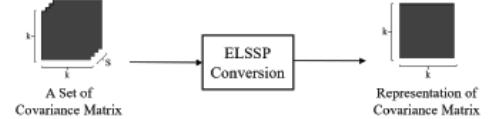


Fig. 4: The process of ELSSP conversion

### B. Regional Matrix Calculation

The regional matrix contains a set of the column vectors which is a rectangle region on the zero-mean image. Two directional correlations in the covariance matrix are obtained from the covariance matrix calculation step as shown in Fig. 2(c). It is the main idea that why our covariance matrix can represent the correlation in two directions. Regional matrix ( $R$ ) calculation aims to transform the zero-mean image ( $\Phi_i$ ) to the standard form before computing the covariance matrix. It can be written in an element form as shown in Eq. (8).

$$R = [r_1, r_2, r_3, \dots, r_K] \quad (8)$$

where  $K$  is the number of windows for each image and  $r_k$  is regional vectors compute in Eq. (9).

$$r_k = \{\Phi_i(m_x, n_y) \mid m_{x,start} \leq m_x \leq m_{x,stop} \text{ and } n_{y,start} \leq n_y \leq n_{y,stop}\} \quad (9)$$

where  $(m_{x,start}, n_{y,start})$  is a coordinate at top left corner of the windows and  $(m_{x,stop}, n_{y,stop})$  is a coordinate at bottom right corner of the windows. They are computed by using Eqs. (10) - (13).

$$m_{x,start} = \begin{cases} 1 & , x = 1 \\ m_{x-1,start} + m_{shift} & , 2 \leq x \leq p \end{cases} \quad (10)$$

$$n_{y,start} = \begin{cases} 1 & , y = 1 \\ n_{y-1,start} + n_{shift} & , 2 \leq y \leq q \end{cases} \quad (11)$$

$$m_{x,stop} = m_{x,start} + m_{shift} \quad (12)$$

$$n_{y,stop} = n_{y,start} + n_{shift} \quad (13)$$

where  $m_{shift}$  and  $n_{shift}$  are a shift window of  $m_{x,start}$  and  $n_{y,start}$ ,  $p$  is a breakpoints of  $m_x$ , and  $q$  is a breakpoints of  $n_y$  as shown in Fig. 3.

### C. ELSSP Conversion

Eigen-weighted linear sum of subspace projections (ELSSP) has been presented by Seo et al. [2]. It is a novel RGB-to-gray color transform. The convention of the RGB color to grayscale is done by applying the average technique to the red, green, and blue color channels. It is simple and the contrast-and-texture of image are lost. Therefore, the ELSSP method is presented to overcome this problem.

Similarly, the representative of the covariance matrix generated from the average of the set of the covariance matrix as reported in [5]–[9] has the same problem. In order to reduce the effect of this problem, the representative of the covariance matrix construction is proposed based on the ELSSP method as follows:

**Step 1:** Convert each covariance matrix to a vector form as so-called covariance vector ( $v_i$ ). The input data ( $V$ ) is constructed from the set of covariance vectors in Eq. (14).

$$V = [v_1, v_2, v_3, \dots, v_S] \quad (14)$$

where  $S$  is a number of covariance vectors.

**Step 2:** Calculate a mean vectors ( $\bar{v}$ ) in Eq. (15).

$$\bar{v} = \frac{1}{S} \sum_{i=1}^S v_i \quad (15)$$

**Step 3:** Compute the zero-mean covariance vectors ( $\tilde{v}_i$ ) by subtraction between covariance vector and mean vector in Eq. (16) before forwarding it to construct a set of zero-mean vectors  $\tilde{V}$  as written in Eq. (17).

$$\tilde{v}_i = v_i - \bar{v} \quad (16)$$

$$\tilde{V} = [\tilde{v}_1, \tilde{v}_2, \tilde{v}_3, \dots, \tilde{v}_S] \quad (17)$$

**Step 4:** Calculate the covariance matrix from  $\tilde{V}$  by using Eq. (1),  $\Psi_{ELSSP} = cov(\tilde{V})$ , and then extract eigenvector  $A_{ELSSP}$  and eigenvalue  $U_{ELSSP}$  in Eq. (18).

$$U_{ELSSP} A_{ELSSP} = A_{ELSSP} \Psi_{ELSSP} \quad (18)$$

**Step 5:** Create a vectorized image ( $X$ ) from eigenvector and eigenvalue by using Eq. (19). Further detail is explained in [2].

$$X = U_{ELSSP} \times (A_{ELSSP}^T \times \tilde{V}^T) \quad (19)$$

The vectorized image ( $X$ ) can be written in Eq. (20).

$$X = [\vec{x}_1, \vec{x}_2, \vec{x}_3, \dots, \vec{x}_S] \quad (20)$$

**Step 6:** Calculate the representative of the covariance matrix( $\Psi_{rep}$ ) by resizing  $\bar{X}$  with resolution  $kk \times 1$  to  $k \times k$  as defined in Eq. (21).

$$\Psi_{rep} = f_{resize}(\bar{X}) \quad (21)$$

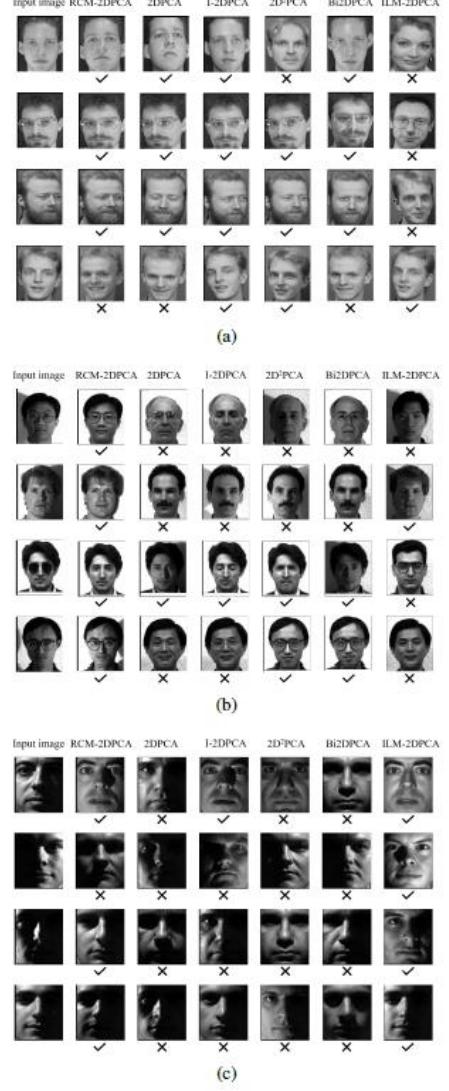


Fig. 5: The example of resulted images from each method on (a) ORL Face, (b) Yale Face, and (c) Yale Face B+ databases.

where  $\bar{X}$  is the representative of the covariance in vector form as computed by Eq. (22).

$$\bar{X} = \sum_{i=1}^S \vec{x}_i \quad (22)$$

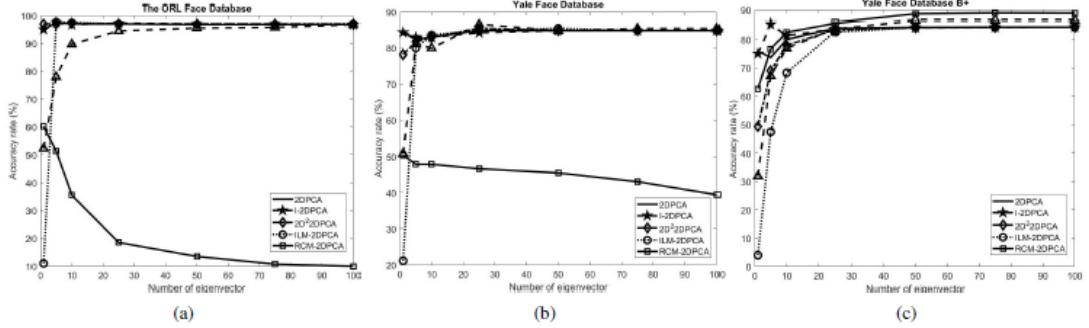


Fig. 6: The plotted graph of the number of eigenvector used against the average accuracy rate of (a) ORL Face Database, (b) Yale Face Database, and (c) Yale Face Database B+

TABLE I: The performance of the proposed RCM-2DPCA method when compared to I-2DPCA, 2D<sup>2</sup>PCA, Bi2DPCA, 2DPCA, and ILM-2DPCA methods.

Method	Accuracy rate (%)mean $\pm$ S.D.			
	ORL Face	Yale Face	Yale Face B+	Average
RCM-2DPCA	97.00 $\pm$ 2.30	<b>86.56<math>\pm</math> 9.13</b>	86.62 $\pm$ 11.68	<b>90.06<math>\pm</math> 6.01</b>
I-2DPCA	97.50 $\pm$ 2.36	84.82 $\pm$ 5.24	85.35 $\pm$ 11.92	89.22 $\pm$ 7.17
2D <sup>2</sup> PCA	<b>97.75<math>\pm</math> 1.84</b>	85.44 $\pm$ 5.92	84.43 $\pm$ 12.28	89.21 $\pm$ 7.42
Bi2DPCA	97.25 $\pm$ 2.49	85.44 $\pm$ 5.92	84.43 $\pm$ 12.28	89.04 $\pm$ 7.13
2DPCA	97.50 $\pm$ 2.04	84.82 $\pm$ 5.24	84.43 $\pm$ 12.28	88.92 $\pm$ 7.44
ILM-2DPCA	60.25 $\pm$ 12.50	50.37 $\pm$ 9.65	<b>89.03<math>\pm</math> 9.67</b>	66.55 $\pm$ 20.08

The design of the covariance matrix to extract the eigenvector and eigenvalue, instead of using the mean covariance matrix, is computed from the ELSSP conversion as shown in Fig. 4.

#### IV. EXPERIMENT AND DISCUSSION

This section aims to evaluate the performance of the proposed method for face recognition. It can be divided into two main parts as follows

##### A. Experimental Setup

In order to evaluate the performance of the proposed method, the baseline methods including 2DPCA, I-2DPCA, Bi2DPCA, 2D<sup>2</sup>PCA and ILM-2DPCA are selected for a comparison. All methods are tested on three well-known face image databases. The first dataset is the ORL Face database [10] which contains 400 images from 40 individuals, each providing 10 different variances in the pose i.e. facial expressions and with-or-without wearing glasses, with sizes 92 $\times$ 112 pixels as depicted in Fig. 5(a). Secondly, the Yale Face database [11] contains 165 images from 15 individuals, each providing 11 different lighting, facial expressions and with-or-without wearing glasses, with sizes 195 $\times$ 231 pixels as shown in Fig. 5(b). Lastly, Yale Face database B+ [12] contains 2,280 images from 38 individuals, each providing 60 different illumination effects images with resolutions 168 $\times$ 192 pixels as displayed in Fig. 5(c). The performance of each method is evaluated by

the accuracy rate ( $P$ ) as defined in Eq. (23).

$$P = \frac{P_{\text{correct}}}{P_{\text{total}}} \times 100 \quad (23)$$

where  $P_{\text{correct}}$  and  $P_{\text{total}}$  are the number of the corrected image and the total image, respectively. 10 fold cross validation is used to avoid an overfitting problem. All images are randomly divided into 10 groups—9 groups for training and 1 group for testing. The number of eigenvectors used in each method and each dataset to construct eigenface is displayed in Fig. 6.

##### B. Result and Discussion

In this section, the performance of the proposed method is evaluated with three databases when compared to the baseline methods including 2DPCA, I-2DPCA, Bi2DPCA, 2D<sup>2</sup>PCA, and ILM-2DPCA methods.

Based on Table I, the performance of the 2D<sup>2</sup>PCA method is higher than the RCM-2DPCA method around 0.75% in case of ORL Face database, but the efficiency of other methods, except ILM-2DPCA, is very similar, making the predictions very close. Whereas, in case of Yale Face B+ database, the performance of ILM-2DPCA method is higher than the proposed method around 2.41% because in this case there are the illumination effects which makes some images difficult to identify. However, ILM-2DPCA is not successful in the ORL and Yale Face databases. Although the performance of the proposed method is not higher than that of the 2D<sup>2</sup>PCA and ILM-2DPCA methods, it achieves in case of Yale Face database at 86.56 %. Moreover, the overall of the proposed method is 0.84%, 0.85%, 1.02%, 1.14%, and 23.51% higher than that of the baseline methods—I-2DPCA, 2D<sup>2</sup>PCA, Bi2DPCA, 2DPCA, and ILM-2DPCA methods, respectively. Furthermore, the overall standard deviation of the RCM-2DPCA method is 1.12, 1.16, 1.41, 1.43, and 14.07 lower than that of Bi2DPCA, I-2DPCA, 2D<sup>2</sup>PCA, 2DPCA, and ILM-2DPCA methods, respectively. This indicates that based on the overall performance the proposed RCM-2DPCA method is very effective and stable. It is corresponding to the given examples displayed in Fig. 5.

## V. CONCLUSION

In this paper, the regional covariance matrix-based two-dimensional PCA for face recognition method as so-called RCM-2DPCA is proposed. The achievement of the proposed method comes from (i) regional matrix calculation and (ii) ELSSP conversion. Firstly, the covariance matrix can represent the correlation in row and column directions when the regional matrix is used. It is appropriate to two dimensional data such as grayscale image. Secondly, using the ELSSP conversion instead of the average technique can prevent the discrimination between two any images, thus making our covariance matrix effective. The experimental results show that the performance of the proposed method is higher than the baseline methods—2DPCA, I-2DPCA, Bi2DPCA, 2D<sup>2</sup>PCA and ILM-2DPCA methods when tested in ORL Face database, Yale Face database, and Yale Face database B+.

## REFERENCES

- [1] L. Sirovich and M. Kirby, "Low-dimensional procedure for the characterization of human faces," *Journal of the Optical Society of America A, Optics and Image Science*, vol. 4, no. 3, pp. 519–524, Mar. 1987.
- [2] J. Seo and S. D. Kim, "Novel PCA-based color-to-gray image conversion," in *2013 IEEE International Conference on Image Processing*, Sep. 2013, pp. 2279–2283.
- [3] M. Turk and A. Pentland, "Eigenfaces for recognition," *Journal of Cognitive Neuroscience*, vol. 3, no. 1, pp. 71–86, 1991.
- [4] K. Woraratpanya and T. Titijaroonroj, "Printed Thai Character Recognition Using Standard Descriptor," in *The 9th International Conference on Computing and InformationTechnology (IC2IT2013)*, P. Meesad, H. Unger, and S. Boonkrong, Eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 2013, pp. 165–173.
- [5] Jian Yang, D. Zhang, A. Frangi, and Jing-yu Yang, "Two-dimensional PCA: a new approach to appearance-based face representation and recognition," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 26, no. 1, pp. 131–137, Jan. 2004.
- [6] D. Zhang and Z. Zhou, "Two-directional two-dimensional PCA for efficient face representation and recognition," *Neurocomputing*, vol. 69, no. 1-3, pp. 224–231, Dec. 2005.
- [7] Y. Kim, Y. Song, U. Chang, D. Kim, T. Yun, and J. Ahn, "Face recognition using a fusion method based on bidirectional 2DPCA," *Applied Mathematics and Computation*, vol. 205, no. 2, pp. 601–607, Nov. 2008.
- [8] K. Woraratpanya, M. Sornnoi, S. Leelaburapanpong, T. Titijaroonroj, R. VarakulSiripunth, Y. Kuroki, and Y. Kato, "An improved 2DPCA for face recognition under illumination effects," in *2015 7th International Conference on Information Technology and Electrical Engineering (ICITEE)*, Oct. 2015, pp. 448–452.
- [9] K. Hancharngchai, T. Titijaroonroj, and J. Rungrattanabut, "An individual local mean-based 2DPCA for face recognition under illumination effects," pp. 207–211, Jul 2019.
- [10] F. S. Samaria, F. S. Samaria, A. Harter, and O. A. Site, "Parameterisation of a stochastic model for human face identification," 1994.
- [11] P. N. Belhumeur, J. P. Hespanha, and D. J. Kriegman, "Eigenfaces vs. Fisherfaces: Recognition using class specific linear projection," in *Computer Vision ECCV '96*, ser. Lecture Notes in Computer Science, B. Buxton and R. Cipolla, Eds. Springer Berlin Heidelberg, 1996, pp. 43–58.
- [12] A. S. Georghiades, P. N. Belhumeur, and D. J. Kriegman, "From few to many: illumination cone models for face recognition under variable lighting and pose," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 23, no. 6, pp. 643–660, Jun. 2001.